



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر
سمینار کارشناسی ارشد گرایش هوش مصنوعی و رباتیکز

عنوان:
پیش‌بینی بیش‌برازش فاجعه‌بار در آموزش دشمنانه سریع
Predicting Catastrophic Overfitting in Fast Adversarial Training

نگارش:
فرزان رحمانی
۴۰۳۲۱۰۷۲۵

استاد راهنما:
دکتر محمدحسین رهبان

استاد ممتحن داخلی:
دکتر شهره کسائی

تیر ۱۴۰۵

چکیده: شبکه‌های عصبی ژرف^۱ در سال‌های اخیر در طیف گسترده‌ای از کاربردها به موفقیت‌های چشمگیری دست یافته‌اند، اما در برابر حملات دشمنانه^۲ بسیار آسیب‌پذیرند؛ آشفتگی‌هایی^۳ کوچک و معمولاً نامحسوس که می‌توانند خروجی مدل را با اطمینان بالا نادرست کنند. آموزش دشمنانه^۴ یکی از مؤثرترین دفاع‌ها در برابر این حملات است، اما نسخه‌های چندمرحله‌ای^۵ آن مانند روش مبتنی بر فرود گرادیان افکنش‌شده^۶ از نظر محاسباتی پرهزینه‌اند. آموزش دشمنانه سریع^۷ با استفاده از حملات تک‌مرحله‌ای^۸ مانند روش علامت گرادیان سریع^۹ این هزینه را کاهش می‌دهد، اما با پدیده‌ای به نام بیش‌برازش فاجعه‌بار^{۱۰} روبه‌روست؛ حالتی که در آن قوام^{۱۱} مدل در برابر حملات چندمرحله‌ای به‌طور ناگهانی فرو می‌ریزد. در این سمینار، نخست مفاهیم پایه‌ای حملات دشمنانه، آموزش دشمنانه، آموزش دشمنانه سریع و بیش‌برازش فاجعه‌بار معرفی می‌شوند و سپس کارهای پیشین در زمینه پیشگیری و پیش‌بینی^{۱۲} این پدیده مرور می‌گردد. این مرور نشان می‌دهد که روش‌های موجود عموماً راه‌حلی همه‌منظوره^{۱۳} نیستند: عملکرد آن‌ها اغلب به مجموعه‌داده^{۱۴} و معماری^{۱۵} خاصی وابسته است، به تنظیم پرهزینه ابرپارامتر نیاز دارند یا سربار محاسباتی قابل‌توجهی به آموزش تحمیل می‌کنند؛ ضمن آنکه تاکنون معیار کارآمدی برای پیش‌بینی زود هنگام این پدیده ارائه نشده است. در همین راستا، شاهدی تجربی از بیش‌برازش شعاع آشفتگی مجاز نیز ارائه می‌شود. در پایان، به اختصار به ایده‌ای برای پیش‌بینی کم‌هزینه بیش‌برازش فاجعه‌بار بر پایه سنج هم‌ترازی آشفتگی^{۱۶} و تنظیم پویای اندازه گام حمله بر اساس هندسه چشم‌انداز تابع اتلاف^{۱۷} اشاره می‌شود.

واژه‌های کلیدی: بیش‌برازش فاجعه‌بار، آموزش دشمنانه سریع، قوام دشمنانه، حملات دشمنانه

۱ مقدمه

شبکه‌های عصبی ژرف به ابزاری کلیدی در بسیاری از حوزه‌ها مانند بینایی ماشین^{۱۸}، پردازش زبان طبیعی^{۱۹} و سیستم‌های خودران تبدیل شده‌اند. با این حال، پژوهش‌ها نشان داده‌اند که این مدل‌ها در برابر **حملات دشمنانه** آسیب‌پذیرند [۱].

همان‌گونه که در شکل ۱.۱ نشان داده شده است، افزودن آشفتگی‌ای کوچک و تقریباً نامحسوس به ورودی می‌تواند پیش‌بینی مدل را به کلی تغییر دهد؛ به گونه‌ای که تصویر از نظر انسان همچنان به کلاس اصلی تعلق دارد، اما مدل با اطمینان بالا آن را در کلاسی نادرست دسته‌بندی^{۲۰} می‌کند. در این فصل، مسئله مورد بررسی در این سمینار، اهمیت آن، و ساختار کلی نوشتار معرفی می‌شود.




شکل ۱.۱: نمونه‌های دشمنانه^{۲۱} تولید شده برای شبکه *AlexNet* [۲]. (چپ) نمونه‌ای که به درستی دسته‌بندی شده است، (وسط) تفاوت میان تصویر صحیح و تصویری که به اشتباه دسته‌بندی شده با بزرگ‌نمایی ۱۰ برابر (مقادیر با ۱۲۸ جمع و برش داده شده‌اند)، (راست) نمونه دشمنانه. تمام تصاویر در ستون راست به عنوان «شترمرغ» پیش‌بینی شده‌اند. [۱]

۱.۱ تعریف مسئله

حمله دشمنانه به افزودن آشفتگی‌ای کوچک و معمولاً نامحسوس به ورودی گفته می‌شود که می‌تواند پیش‌بینی مدل را با اطمینان بالا نادرست کند. آموزش دشمنانه یکی از مؤثرترین راهکارها برای مقاوم‌سازی مدل در برابر چنین حملاتی است که در آن مدل به‌جای داده‌های تمیز، روی نمونه‌های دستکاری‌شده دشمنانه آموزش می‌بیند [۳]. اما نسخه‌های چندمرحله‌ای آموزش دشمنانه به‌دلیل نیاز به چندین گام محاسبه گرادیان در هر تکرار آموزش، هزینه محاسباتی بالایی دارند که مقیاس‌پذیری آن‌ها را محدود می‌کند.

برای کاهش این هزینه، آموزش دشمنانه سریع مبتنی بر حملات تک‌مرحله‌ای معرفی شد [۴]. این روش‌ها به‌مراتب کارآمدترند، اما چالش تازه‌ای به‌نام بیش‌برازش فاجعه‌بار را پدید می‌آورند: پس از چند دوره آموزشی^{۲۲}، درستی مقاوم^{۲۳} مدل در برابر حملات چندمرحله‌ای به‌طور ناگهانی به نزدیک صفر سقوط می‌کند، در حالی که درستی^{۲۴} آن در برابر همان حمله تک‌مرحله‌ای که در آموزش به‌کار رفته است، حتی افزایش می‌یابد.



شکل ۱.۲: پدیده‌ی بیش‌برازش فاجعه‌بار در آموزش دشمنانه سریع. نمودار درستی دسته‌بندی را برای داده‌های تمیز، حمله تک‌مرحله‌ای *FGSM*، و حمله چندمرحله‌ای *PGD-10* در ۱۰۰ دوره آموزشی برای مدل *ResNet18* روی مجموعه‌داده‌ی *CIFAR-10* نشان می‌دهد. همان‌گونه که مشاهده می‌شود، درستی در برابر حمله *FGSM* به‌سرعت افزایش می‌یابد، اما درستی مقاوم در برابر حمله قوی‌تر *PGD-10* به‌طور ناگهانی به نزدیک صفر سقوط می‌کند. [۵]

همان‌گونه که در شکل ۱.۲ نشان داده شده است، این پدیده بسیار نگران‌کننده است زیرا مدل در ظاهر عملکرد خوبی از خود نشان می‌دهد (درستی بالا در برابر حمله *FGSM*)، اما در عمل در برابر حملات قوی‌تر کاملاً شکننده است. مسئله اصلی مورد توجه در این سمینار، شناخت سازوکار بیش‌برازش فاجعه‌بار و به‌ویژه پیش‌بینی زمان وقوع آن به‌جای صرفاً واکنش پس از رخ دادن آن است.

۱.۲ اهمیت موضوع

اهمیت پرداختن به این مسئله از چند جنبه قابل بررسی است:

- قوام دشمنانه در کاربردهای حساس به امنیت مانند خودروهای خودران، تشخیص پزشکی و سیستم‌های مالی نقشی حیاتی دارد و شکست مدل در برابر حملات می‌تواند پیامدهای جدی به همراه داشته باشد.
- آموزش دشمنانه چندمرحله‌ای هرچند مؤثر است، هزینه محاسباتی بالایی دارد که مقیاس‌پذیری آن را روی مجموعه‌داده‌ها و معماری‌های بزرگ محدود می‌کند.

- آموزش دشمنانه سریع راه‌حلی کارآمد است، اما تا زمانی که مسئله بیش‌برازش فاجعه‌بار حل نشده باشد، قابل اعتماد نخواهد بود.

- بسیاری از روش‌های موجود برای جلوگیری از بیش‌برازش فاجعه‌بار به تنظیم پرهزینه ابرپارامترها یا محاسبات اضافی نیاز دارند که هدف اولیه‌ی آموزش دشمنانه سریع، یعنی قوام با کمترین هزینه، را تضعیف می‌کند.

از این رو، پیش‌بینی به‌موقع و کم‌هزینه بیش‌برازش فاجعه‌بار می‌تواند قابلیت اطمینان آموزش دشمنانه سریع را بدون افزایش هزینه محاسباتی ارتقا دهد.

۱.۳ اهداف و ساختار سمینار

هدف این سمینار، مرور مفاهیم پایه و کارهای پیشین در زمینه بیش‌برازش فاجعه‌بار در آموزش دشمنانه سریع، و معرفی مختصر یک رویکرد برای پیش‌بینی و کنترل آن است. ساختار ادامه نوشتار به این صورت است: در فصل ۲ مفاهیم اولیه شامل حملات دشمنانه، آموزش دشمنانه، آموزش دشمنانه سریع و بیش‌برازش فاجعه‌بار معرفی می‌شوند. در فصل ۳ کارهای پیشین مرتبط دسته‌بندی و بررسی می‌شوند. در فصل ۴ به‌اختصار به ایده روش مورد بررسی پرداخته می‌شود و در فصل ۵ جمع‌بندی ارائه می‌گردد.

۲ مفاهیم اولیه

در این فصل، مفاهیم بنیادینی که در ادامه سمینار به آن‌ها نیاز است معرفی می‌شوند. این مفاهیم شامل تعریف دقیق حملات دشمنانه، صورت‌بندی آموزش دشمنانه، گذار به آموزش دشمنانه سریع، و سرانجام معرفی پدیده بیش‌برازش فاجعه‌بار است.

۲.۱ حملات دشمنانه و قوام

فرض کنید f_θ یک دسته‌بند^{۲۵} با پارامترهای θ و (x, y) یک نمونه ورودی به‌همراه برچسب درست آن باشد. نمونه دشمنانه نمونه‌ای مانند $x + \delta$ است که در آن آشفتگی δ در یک کره‌ی ℓ_∞ به شعاع ϵ محدود شده است، یعنی $\|\delta\|_\infty \leq \epsilon$ ، و به‌گونه‌ای انتخاب می‌شود که مدل آن را نادرست دسته‌بندی کند.

ساده‌ترین و پرکاربردترین حمله تک‌مرحله‌ای، روش علامت‌گرادیان سریع است که آشفتگی را در جهت علامت‌گرادیان تابع اتلاف نسبت به ورودی می‌سازد [۶]:

$$\delta = \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(f_\theta(x), y)). \quad (۱)$$

در این رابطه، ϵ شعاع آشفتگی مجاز (معمولاً مقدار کوچکی مانند $\frac{1}{\sqrt{d}}$ برای تصاویر) است، $\mathcal{L}$ تابع اتلاف (معمولاً اتلاف بی‌نظمی متقاطع^{۲۶}) است، و $\text{sign}(\cdot)$ تابع علامت است که خروجی آن برای ورودی‌های مثبت $+1$ و برای ورودی‌های منفی -1 خواهد بود. بنابراین آشفتگی δ در هر بُعد، گامی به اندازه ϵ در جهت افزایش اتلاف برمی‌دارد.

در مقابل، حمله قوی‌تر و چندمرحله‌ای فرود‌گرادیان افکنش‌شده، با تکرار گام‌های کوچک و افکنش آشفتگی روی کره‌ی مجاز به دست می‌آید [۳]:

$$x^{t+1} = \Pi_{\|x'-x\|_\infty \leq \epsilon}(x^t + \alpha \cdot \text{sign}(\nabla_x \mathcal{L}(f_\theta(x^t), y))), \quad (۲)$$

که در آن x^t نمونه دشمنانه در گام t ام است (با شروع از $x^0 = x$)، x^{t+1} نمونه دشمنانه به روزرسانی شده در گام بعدی است، α اندازه گام در هر تکرار (معمولاً کوچکتر از ϵ ، مانند $\frac{\epsilon}{\sqrt{t}}$) است، و Π عملگر افکنش^{۲۷} روی ناحیه مجاز ϵ $\|x' - x\|_\infty \leq \epsilon$ است که تضمین می کند آشفتگی نهایی از شعاع ϵ فراتر نرود. این فرایند معمولاً برای چندین گام (برای مثال ۱۰ یا ۲۰ گام) تکرار می شود که با نماد PGD-10 یا PGD-20 نشان داده می شود. به درستی مدل در برابر چنین حملاتی، **درستی مقاوم**^{۲۸} گفته می شود.

۲.۲ آموزش دشمنانه

آموزش دشمنانه را می توان به صورت یک مسئله بهینه سازی^{۲۹} کمینه بیشینه^{۳۰} صورت بندی کرد، که در آن بیشینه سازی درونی به دنبال یافتن آشفتگی ای است که تابع اتلاف را بیشینه کند، و کمینه سازی بیرونی پارامترهای مدل را برای کاهش این اتلاف به روزرسانی می کند [۳]:

$$\min_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\max_{\|\delta\|_\infty \leq \epsilon} \mathcal{L}(f_{\theta}(x + \delta), y) \right]. \quad (۳)$$

در این فرمول، $\min_{\theta}$ کمینه سازی بیرونی را نشان می دهد که پارامترهای مدل θ را برای کاهش اتلاف بهینه می کند، $\mathbb{E}_{(x,y) \sim \mathcal{D}}$ امید ریاضی روی توزیع داده ای $\mathcal{D}$ است (یعنی میانگین روی تمام نمونه های مجموعه داده آموزشی)، و $\max_{\|\delta\|_\infty \leq \epsilon}$ بیشینه سازی درونی است که به دنبال یافتن بدترین آشفتگی δ در همسایگی ℓ_∞ به شعاع ϵ است. تابع اتلاف $\mathcal{L}$ نیز معمولاً اتلاف بی نظمی متقاطع است. بنابراین، هدف نهایی یافتن پارامترهایی است که مدل را در برابر بدترین حمله ممکن در همسایگی هر نمونه مقاوم سازد.

در روش استاندارد چندمرحله ای، بیشینه سازی درونی با حمله فرود گرادیان افکنش شده حل می شود. این رویکرد مؤثر است، اما به دلیل نیاز به چندین گام محاسبه گرادیان (مانند ۱۰ گام در PGD-10) در هر تکرار آموزش، هزینه محاسباتی آموزش را برای مدل ها و مجموعه داده های بزرگ به شدت افزایش می دهد. برای مثال، آموزش دشمنانه با PGD-10 روی یک مدل متوسط می تواند تا ۱۰ برابر آموزش استاندارد زمان ببرد.


۲.۳ آموزش دشمنانه سریع

برای کاهش این هزینه، خانواده ای از روش ها با عنوان آموزش دشمنانه سریع معرفی شدند که بیشینه سازی درونی را تنها با یک گام (مانند حمله علامت گرادیان سریع) تقریب می زنند [۴]. این روش ها هزینه آموزش را به کسری از حالت چندمرحله ای کاهش می دهند. یکی از مشاهدات کلیدی آن بوده که افزودن یک **شروع تصادفی**^{۳۱} به آشفتگی اولیه، می تواند پایداری آموزش را بهبود بخشد. با این حال، آموزش تک مرحله ای مستعد یک حالت شکست مشخص است که در ادامه معرفی می شود.

۲.۴ بیش برآزش فاجعه بار

بیش برآزش فاجعه بار پدیده ای است که عمدتاً در آموزش دشمنانه تک مرحله ای رخ می دهد و در آن، درستی مقاوم مدل در برابر حملات چندمرحله ای مانند فرود گرادیان افکنش شده، تنها در عرض چند دوره آموزشی به طور ناگهانی به نزدیک صفر سقوط می کند، در حالی که درستی در برابر حمله تک مرحله ای به سرعت افزایش می یابد.

ویژگی قابل توجه بیش برآزش فاجعه بار آن است که درستی تمیز مدل را کاهش نمی دهد و گاه درستی در برابر حمله تک مرحله ای حتی از درستی تمیز نیز فراتر می رود. این موضوع نشان می دهد که مدل به جای کسب قوام واقعی، صرفاً به حمله خاص به کاررفته در آموزش بیش برآزش کرده است و در برابر حملات قوی تر شکننده می شود.



شکل ۲.۳: فرایند اعوجاج مرز تصمیم‌گیری در اثر بیش‌برازش فاجعه‌بار. (چپ) سطح اتلاف پیش از وقوع بیش‌برازش فاجعه‌بار، به‌همراه جهت دشمنانه FGSM با بردار v_1 و یک جهت تصادفی v_2 . نقطه قرمز، نمونه دشمنانه $x + v_1$ تولیدشده از تصویر اصلی x با برجسب «سگ» را نشان می‌دهد. (وسط) تغییر سطح اتلاف پس از یادگیری نمونه دشمنانه $x + v_1$ بردار v_1 همان بردار شکل سمت چپ است. ناحیه‌ی اعوجاج‌یافته برای نخستین بار ظاهر می‌شود. (راست) با ادامه‌ی آموزش، مرز تصمیم‌گیری مخدوش به‌طور کنترل‌نشده‌ای رشد می‌کند، به‌گونه‌ای که قوام در برابر حملات دشمنانه چندمرحله‌ای کاهش می‌یابد. [۷]

یک دیدگاه پذیرفته‌شده، بیش‌برازش فاجعه‌بار را به تغییر در هندسه‌ی چشم‌انداز تابع اتلاف^{۳۲} نسبت می‌دهد؛ به‌گونه‌ای که در آستانه وقوع آن، سطح اتلاف به‌شدت غیرخطی و مخدوش می‌شود [۷، ۸]. این غیرخطی‌شدن باعث می‌شود آشفتگی تک‌مرحله‌ای دیگر نتواند بیشینه محلی واقعی اتلاف را هدف بگیرد و در نتیجه نمونه‌های دشمنانه نامناسبی تولید شوند.


همان‌گونه که در شکل ۲.۳ نشان داده شده است، پیش از وقوع بیش‌برازش فاجعه‌بار (تصویر سمت چپ)، سطح اتلاف نسبتاً هموار است و جهت حمله FGSM (بردار v_1) به‌درستی به سمت ناحیه‌ای با اتلاف بالا اشاره می‌کند. اما با ادامه‌ی آموزش (تصویر وسط)، سطح اتلاف در اطراف نمونه دشمنانه شروع به اعوجاج می‌کند و نواحی غیرخطی و معوج^{۳۳} پدیدار می‌شوند. در نهایت (تصویر راست)، این اعوجاج به‌طور کنترل‌نشده‌ای گسترش می‌یابد و مرز تصمیم‌گیری را چنان مخدوش می‌کند که حمله تک‌مرحله‌ای دیگر نمی‌تواند بیشینه واقعی اتلاف را هدف قرار دهد و قوام در برابر حملات چندمرحله‌ای از بین می‌رود.

۲.۵ انحنا و دیدگاه مرتبه دوم

ارتباط نزدیکی میان **انحنای**^{۳۴} چشم‌انداز تابع اتلاف و قوام مدل وجود دارد. هرچه سطح اتلاف در اطراف یک نمونه هموارتر (کم‌انحناتر) باشد، حمله تک‌مرحله‌ای تقریب بهتری از بیشینه واقعی اتلاف ارائه می‌دهد. از همین رو، اطلاعات مرتبه دوم (مانند ماتریس هسی^{۳۵}) می‌توانند در تحلیل و کنترل بیش‌برازش فاجعه‌بار سودمند باشند؛ هرچند محاسبه مستقیم آن‌ها برای مسائل بزرگ‌مقیاس پرهزینه است. این مشاهده انگیزه‌ای برای روش‌هایی است که می‌کوشند اطلاعات انحنا را به‌صورت غیرمستقیم و کم‌هزینه تقریب بزنند.

۲.۶ معیارهای ارزیابی^{۳۶}

برای ارزیابی قوام مدل‌ها معمولاً از درستی در برابر حملات گوناگون استفاده می‌شود. درستی در برابر حمله تک‌مرحله‌ای به‌تنهایی می‌تواند گمراه‌کننده باشد، زیرا در حضور بیش‌برازش فاجعه‌بار بالا می‌ماند. بنابراین ارزیابی قابل‌اعتماد معمولاً با حملات چندمرحله‌ای و به‌ویژه با مجموعه‌حمله استاندارد و بدون پارامتر AutoAttack انجام می‌شود [۹]. افزون بر این، **بده‌بستان درستی مقاوم**–**تمیز**^{۳۷} یکی از معیارهای مهم در مقایسه‌ی روش‌هاست [۱۰].



شکل ۳.۴: مقایسه‌ی تصویری حملات $FGSM$ [۶]، $RS-FGSM$ [۴] و $N-FGSM$ [۱۱]. در روش $FGSM$ ، آشفتگی مستقیماً در جهت علامت گرادیان و بدون تصادفی‌سازی اعمال می‌شود. در روش $RS-FGSM$ ، نویز تصادفی در یک کره‌ی ℓ_1 به شعاع ϵ به نمونه اضافه و سپس برش داده می‌شود. اما در روش $N-FGSM$ ، نویز از یک کره‌ی ℓ_1 با شعاع دلخواه k (معمولاً بزرگ‌تر از ϵ) نمونه‌برداری می‌شود و گام برش نیز حذف می‌گردد، که منجر به تنوع بیشتر آشفتگی و قوام بهتر می‌شود.

۳ کارهای پیشنهادی

پژوهش‌های فراوانی به تبیین و رفع بیش‌برازش فاجعه‌بار پرداخته‌اند. در این فصل، مهم‌ترین آن‌ها بر اساس راهبرد اصلی مقابله با این پدیده دسته‌بندی و بررسی می‌شوند.

۳.۱ روش‌های مبتنی بر تصادفی‌سازی

این دسته از روش‌ها با تزریق تصادفی‌بودن به فرایند تولید نمونه دشمنانه می‌کوشند از بیش‌برازش مضر جلوگیری کنند. نشان داده شده است که افزودن یک شروع تصادفی به آموزش مبتنی بر علامت گرادیان سریع می‌تواند تا حد زیادی از بیش‌برازش فاجعه‌بار جلوگیری کند [۴]. این ایده بعدها با افزایش دامنه نویز تصادفی و حذف گام برش^{۳۸} گسترش یافت و روشی موسوم به $N-FGSM$ ارائه شد که هم قوام و هم درستی بهتری به دست می‌دهد [۱۱].

همان‌گونه که در شکل ۳.۴ مشاهده می‌شود، تفاوت اصلی $N-FGSM$ با نسخه‌های پیشنهادی در دو جنبه است: نخست، استفاده از نویز تصادفی با دامنه بزرگ‌تر (شعاع k به جای ϵ) که تنوع آشفتگی را افزایش می‌دهد، و دوم، حذف گام برش که به آشفتگی اجازه می‌دهد آزادانه‌تر در فضای ورودی جستجو کند. این دو تغییر ساده اما مؤثر، باعث می‌شوند $N-FGSM$ بتواند بدون گرفتار شدن در دام بیش‌برازش فاجعه‌بار، قوام بهتری نسبت به روش‌های پیشنهادی کسب کند.

۳.۲ روش‌های مبتنی بر منظم‌سازی

روش‌های مبتنی بر منظم‌سازی^{۳۹} با افزودن جمله‌ای محدودکننده به تابع هدف، رفتار مدل را به گونه‌ای مقید می‌کنند که از بیش‌برازش فاجعه‌بار جلوگیری شود. یکی از روش‌های شناخته‌شده، بیشینه‌سازی هم‌راستایی گرادیان^{۴۰} میان نمونه تمیز و نمونه آشفته^{۴۱} در مجموعه‌ی آشفتگی است (روش GradAlign [۱۲]). برخی روش‌ها با استفاده از منظم‌سازی مبتنی بر نرم، هموارسازی تابع را در همسایگی نمونه‌ها تقویت می‌کنند [۱۳]. دسته‌ای دیگر، نمونه‌های دشمنانه ناهنجار^{۴۲} را به عنوان منشأ بیش‌برازش فاجعه‌بار

شناسایی کرده و آن‌ها را با منظم‌سازی مهار می‌کنند (روش AAER) [۱۴]. همچنین برخی پژوهش‌ها با تشویق خطی بودن محلی^{۴۳} سطح اتلاف، به صورت کارآمد از این پدیده جلوگیری می‌کنند (روش ELLE) [۱۵].

۳.۳ روش‌های مبتنی بر اندازه گام تطبیقی

این روش‌ها اندازه گام حمله را بر اساس دینامیک آموزش تنظیم می‌کنند. برخی از یادگیری تقویتی برای تعیین اندازه گام بهره گرفته‌اند [۱۶]، برخی دیگر اندازه گام را با استفاده از نُرم گرادیان تطبیق داده‌اند [۱۷]، و در پژوهشی دیگر اندازه گام برای هر نمونه بر پایه‌ی شباهت میان نویز ورودی و جهت گرادیان تعیین شده است [۱۸]. ایده مشترک این دسته آن است که با پرهیز از درونیابی در نواحی به شدت غیرخطی، می‌توان از تولید نمونه‌های دشمنانه نامناسب و در نتیجه از بیش‌برازش فاجعه‌بار جلوگیری کرد.

۳.۴ سایر رویکردها

برخی روش‌ها از منظرهای دیگری به مسئله می‌نگرند. به عنوان نمونه، حذف به‌روزرسانی‌هایی با اندازه گرادیان ناچیز برای پایدارسازی آموزش پیشنهاد شده است [۱۹]. همچنین روش آموزش دشمنانه رایگان^{۴۴} با استفاده هم‌زمان از گرادیان تولید نمونه دشمنانه برای به‌روزرسانی وزن‌ها، سربار محاسباتی حمله را حذف می‌کند [۲۰].

۳.۵ بهینه‌سازی مرتبه دوم و قوام

دسته‌ای از پژوهش‌ها با الهام از ارتباط میان انحنا و قوام، از منظم‌سازی انحنا برای آموزش مدل‌های مقاوم استفاده کرده‌اند [۲۱]. این رویکردها نشان می‌دهند که کنترل اطلاعات مرتبه دوم سطح اتلاف می‌تواند در بهبود قوام مؤثر باشد، هرچند تاکنون کمتر در چارچوب آموزش دشمنانه سریع و کم‌هزینه به کار رفته‌اند.

۳.۶ معیارهای پیش‌بینی بیش‌برازش فاجعه‌بار

تاکنون معیار مشخصی که صرفاً برای پیش‌بینی کم‌هزینه بیش‌برازش فاجعه‌بار طراحی شده باشد ارائه نشده است؛ با این حال چند سنجه می‌توانند به صورت غیرمستقیم نشانه‌ای زود هنگام از وقوع آن باشند، مانند هم‌راستایی گرادیان [۱۲]، نرخ نمونه‌های دشمنانه ناهنجار [۱۴] و معیارهای غیرخطی بودن سطح اتلاف [۱۵].

هم‌راستایی گرادیان که در کار آندریوشچنکو و همکاران [۱۲] معرفی شده است، میزان خطی بودن موضعی تابع اتلاف را به کمک شباهت کسینوسی میان گرادیان نمونه تمیز و گرادیان نمونه آشفته با نویز تصادفی η اندازه‌گیری می‌کند:

$$\mathbb{E}_{(x,y) \sim \mathcal{D}, \eta \sim \mathcal{U}([- \epsilon, \epsilon]^d)} [\cos(\nabla_x \mathcal{L}(x, y; \theta), \nabla_x \mathcal{L}(x + \eta, y; \theta))]. \quad (۴)$$

در این رابطه، $\mathbb{E}$ امید ریاضی روی تمام نمونه‌های داده و نویز تصادفی است، $\eta \sim \mathcal{U}([- \epsilon, \epsilon]^d)$ نویزی است که به طور یکنواخت از بازه‌ی $[- \epsilon, \epsilon]$ در هر بُعد نمونه‌برداری می‌شود، و $\cos(\cdot, \cdot)$ شباهت کسینوسی میان دو بردار گرادیان را محاسبه می‌کند که اگر دو بردار هم‌جهت باشند ۱ و اگر عمود باشند ۰ خواهد بود. هرچه این مقدار به ۱ نزدیک‌تر باشد، سطح اتلاف در همسایگی ϵ خطی‌تر است و حمله FGSM تقریب دقیق‌تری از بیشینه واقعی اتلاف ارائه می‌دهد. کاهش ناگهانی این معیار می‌تواند هشدار برای وقوع قریب‌الوقوع بیش‌برازش فاجعه‌بار باشد، اما محاسبه آن نیازمند یک پس‌انتشار اضافی برای گرادیان $\nabla_x \mathcal{L}(x + \eta, y; \theta)$ است.

نمونه‌های دشمنانه ناهنجار نیز توسط لین و همکاران [۱۴] به عنوان نشانه‌ای از اعوجاج دسته‌بند معرفی شده‌اند. اگر $x + \eta$ نمونه آغشته به نویز تصادفی و δ آشفتگی FGSM محاسبه شده روی آن باشد، نمونه‌ای ناهنجار (AAE) خوانده می‌شود که در آن افزودن آشفتگی، برخلاف انتظار، اتلاف را کاهش دهد:

$$\mathcal{L}(x + \eta, y; \theta) > \mathcal{L}(x + \eta + \delta, y; \theta). \quad (5)$$

در این نامساوی، $\mathcal{L}(x + \eta, y; \theta)$ اتلاف مدل روی نمونه نویزدار پیش از اعمال آشفتگی، $\delta = \text{sign}(\nabla_{x+\eta} \mathcal{L}(x + \eta, y; \theta))$ آشفتگی FGSM محاسبه شده روی همان نمونه، و $\mathcal{L}(x + \eta + \delta, y; \theta)$ اتلاف پس از افزودن آشفتگی است. در حالت عادی انتظار می‌رود افزودن آشفتگی دشمنانه اتلاف را افزایش دهد، اما در نمونه‌های ناهنجار این رابطه برعکس می‌شود که نشانه‌ای از غیرخطی شدن شدید سطح اتلاف است. پیش از وقوع بیش‌برازش فاجعه‌بار، شمار اندکی AAE در داده‌های آموزشی ظاهر می‌شوند که نشان‌دهنده‌ی آغاز اعوجاج مرز تصمیم‌گیری است؛ اما ردیابی آن‌ها نیز مستلزم ارزیابی اتلاف روی هر دو نقطه پیش و پس از اعمال آشفتگی است. مشکل مشترک این سنجه‌ها آن است که اغلب به محاسبات اضافی مانند پس‌انتشار یا عبور روبه‌جلو بیشتر نیاز دارند و در نتیجه هزینه محاسباتی آموزش را افزایش می‌دهند؛ چالشی که انگیزه‌ی اصلی پژوهش حاضر برای یافتن معیاری دقیق اما کم‌هزینه است.

۳.۷ محدودیت‌های روش‌های پیشین

علی‌رغم پیشرفت‌های قابل توجه، روش‌های پیشین همچنان با چالش‌های مهمی روبرو هستند:

۱. **وابستگی به مجموعه داده و معماری:** اکثر روش‌ها برای مجموعه داده‌های استاندارد مثل CIFAR-10 تنظیم شده‌اند و عملکرد آن‌ها در مجموعه داده‌های دیگر یا معماری‌های متفاوت قابل اطمینان نیست.
 ۲. **نیاز به تنظیم ابرپارامتر:** بسیاری از روش‌ها برای هر مجموعه داده یا معماری نیاز به جستجوی مستقل ابرپارامتر دارند، که این امر هزینه کلی را افزایش می‌دهد.
 ۳. **هزینه محاسباتی اضافی:** برخی رویکردها مانند GradAlign و ELLE برای پیشگیری از بیش‌برازش فاجعه‌بار، هزینه محاسباتی قابل توجهی نسبت به روش‌های پایه اضافه می‌کنند.
 ۴. **نبود معیار پیش‌بینی کارآمد:** تاکنون، هیچ معیاری که بتواند به‌طور کارآمد وقوع قریب‌الوقوع بیش‌برازش فاجعه‌بار را پیش‌بینی کند وجود نداشته است. معیارهای موجود مانند GradAlign اگرچه می‌توانند نشانه‌هایی از شروع بیش‌برازش فاجعه‌بار بدهند، اما هزینه محاسباتی بالایی دارند.
- برای جمع‌بندی و مقایسه روشن‌تر روش‌های مرور شده در این فصل، جدول ۳.۱ راهبرد اصلی، ویژگی کلیدی، مزیت و محدودیت هر یک از روش‌های پیشین را در کنار هم ارائه می‌دهد. همان‌گونه که از این جدول برمی‌آید، هرچند هر دسته از روش‌ها توانسته است بیش‌برازش فاجعه‌بار را تا حدی مهار کند، اما هیچ‌یک به‌طور هم‌زمان هر چهار چالش برشمرده شده در بالا (یعنی وابستگی به مجموعه داده و معماری، نیاز به تنظیم ابرپارامتر، هزینه محاسباتی اضافی و نبود معیار پیش‌بینی کارآمد) را برطرف نکرده است؛ شکافی که انگیزه اصلی رویکرد ارائه شده در فصل بعد است.

جدول ۳.۱: مقایسه روش‌های پیشین در پیشگیری و پیش‌بینی بیش‌برازش فاجعه‌بار.


روش	راهبرد	ویژگی کلیدی	مزیت	محدودیت
FGSM-RS [۴]	تصادفی‌سازی	افزودن شروع تصادفی پیش از آشفته‌گی FGSM	ساده و تقریباً بدون سربار محاسباتی	در مقیاس‌های بزرگ‌تر € همچنان مستعد بیش‌برازش فاجعه‌بار است
N-FGSM [۱۱]	تصادفی‌سازی	نویز با دامنه بزرگ‌تر از € و حذف گام برش	قوام و درستی بهتر نسبت به FGSM-RS	دامنه نویز نیازمند تنظیم و وابسته به مجموعه داده
GradAlign [۱۲]	منظم‌سازی	بیشینه‌سازی هم‌راستایی گرادیان نمونه تمیز و آشفته	پایه نظری روشن؛ معیاری برای پیش‌بینی نیز فراهم می‌کند	نیازمند پس‌انتشار اضافی و هزینه محاسباتی قابل توجه
NuAT [۱۳]	منظم‌سازی	هموارسازی تابع اتلاف با منظم‌سازی نرم اتمی	بهبود پایداری آموزش	هزینه محاسباتی و حافظه اضافی
AAER [۱۴]	منظم‌سازی	شناسایی و مهار نمونه‌های دشمنانه ناهنجار	ریشه‌یابی مستقیم یکی از علل بیش‌برازش فاجعه‌بار	نیازمند ارزیابی اتلاف در چند نقطه؛ حساس به تنظیم آستانه
ELLE [۱۵]	منظم‌سازی	تشویق خطی‌بودن محلی سطح اتلاف	قوام بالا و اثربخشی در مجموعه داده‌های چالش‌برانگیز	سربار محاسباتی و حافظه‌ای بالاتر از روش‌های پایه
RL-based [۱۶]	گام تطبیقی	تعیین اندازه گام با یادگیری تقویتی	تطبیق پویا با دینامیک آموزش	پیچیدگی پیاده‌سازی و هزینه آموزش عامل تقویتی
ATAS [۱۷]	گام تطبیقی	تطبیق اندازه گام بر اساس نرم گرادیان	کارآمد و بدون نیاز به مؤلفه یادگیری جداگانه	عملکرد وابسته به کیفیت تخمین نرم گرادیان در هر نمونه
روش تشابه گرادیان [۱۸]	گام تطبیقی	تعیین گام برای هر نمونه بر پایه شباهت نویز و جهت گرادیان	توجه ویژه به سطح نمونه به جای کل دسته	نیازمند محاسبات اضافی به ازای هر نمونه
ZeroGrad [۱۹]	سایر رویکردها	حذف به‌روزرسانی‌های با گرادیان ناچیز	پیاده‌سازی بسیار ساده و کم‌هزینه	اثربخشی محدودتر روی مجموعه داده‌های دشوارتر
Free AT [۲۰]	سایر رویکردها	بازاستفاده از گرادیان حمله برای به‌روزرسانی وزن‌ها	حذف کامل سربار محاسباتی حمله جداگانه	درستی تمیز و قوام معمولاً پایین‌تر از روش‌های تخصصی‌تر
منظم‌سازی انحنای [۲۱]	مرتبه دوم	کنترل مستقیم انحنای سطح اتلاف	پیوند نظری قوی میان انحنای و قوام	کمتر در چارچوب آموزش دشمنانه سریع و کم‌هزینه به کار رفته است

۴ روش ارائه شده

با تکیه بر مفاهیم و کارهای پیشین مرور شده، رویکرد مورد بررسی در این سمینار بر سه ایده به هم پیوسته استوار است: مشاهده تجربی نقش ثابت بودن اندازه و جهت آشفتگی در پیدایش بیش‌برازش فاجعه‌بار، طراحی یک سنجه کم‌هزینه برای پیش‌بینی زودهنگام این پدیده، و در نهایت تعیین پویای اندازه گام حمله بر پایه دیدگاه مرتبه دوم. در ادامه، برای هر یک از دو ایده نخست، آزمایشی تجربی نیز ارائه می‌شود.

۴.۱ بیش‌برازش شعاع آشفتگی مجاز (ϵ)

برای بررسی این فرضیه که ثابت و نسبتاً بزرگ بودن اندازه آشفتگی حمله (بدون تنوع در اندازه یا جهت آن) می‌تواند زمینه‌ساز بیش‌برازش فاجعه‌بار باشد، آزمایشی روی مدل PreActResNet18 در مجموعه داده CIFAR10 انجام شد که با آشفتگی ثابت $\epsilon = \frac{\Delta}{255}$ آموزش دیده و دچار بیش‌برازش فاجعه‌بار شده است. درستی این مدل در برابر حمله FGSM و حمله PGD-10 برای بازه‌ای از مقادیر قدرت حمله (از $-\frac{16}{255}$ تا $+\frac{16}{255}$) اندازه‌گیری و در شکل ۴.۵ گزارش شده است.



شکل ۴.۵: درستی یک مدل دچار بیش‌برازش فاجعه‌بار (آموزش‌دیده با FGSM و $\epsilon = \frac{\Delta}{255}$) در برابر حمله FGSM و PGD-10، به ازای مقادیر مختلف قدرت حمله. خط چین، درستی تمیز مدل را نشان می‌دهد.


همان‌گونه که در شکل ۴.۵ دیده می‌شود، درستی FGSM رفتاری بسیار نامنظم دارد: برای برخی مقادیر ϵ (از جمله همان مقداری که در آموزش به کار رفته) به شدت بالا می‌ماند، در حالی که برای مقادیر دیگر، حتی نزدیک به همان بازه، به طرز غیرمنتظره‌ای افت می‌کند. این نوسان شدید نشان می‌دهد که سطح اتلاف، حتی در طول همان جهت آشفتگی‌ای که در آموزش استفاده شده، به شدت غیرخطی و ناهموار شده است؛ به بیان دیگر، مدل به جای کسب قوام واقعی، تنها به مقادیر مشخصی از اندازه آشفتگی بیش‌برازش کرده است، پدیده‌ای که آن را بیش‌برازش اپسیلون^{۴۵} می‌نامیم. در مقابل، درستی در برابر PGD-10 تقریباً تمام این بازه پایین و نزدیک صفر باقی می‌ماند، که تأیید می‌کند نوسانات درستی FGSM بازتابی از قوام واقعی مدل نیست، بلکه صرفاً برازشی موضعی و شکننده به شکل خاصی از آشفتگی است. این مشاهده، انگیزه اصلی افزودن تنوع به توزیع اندازه و جهت آشفتگی حمله است.

۴.۲ سنجه پیش‌بینی: هم‌ترازی آشفتگی

برای پیش‌بینی کم‌هزینه بیش‌برازش فاجعه‌بار، پیش از افت محسوس درستی مقاوم، سنجه‌ای مبتنی بر گرادیان تعریف می‌شود که آن را هم‌ترازی آشفتگی می‌نامیم. این سنجه، شباهت کسینوسی میان دو گرادیان را اندازه می‌گیرد: گرادیان اتلاف نسبت به نمونه دارای شروع تصادفی و گرادیان اتلاف پس از برداشتن یک گام اضافی در جهت حمله روی همان نمونه. در واقع:

$$\text{هم‌ترازی آشفته‌گی} = \cos(\nabla_x \mathcal{L}(f_\theta(x'), y), \nabla_x \mathcal{L}(f_\theta(x' + \delta), y)), \quad (6)$$

که در آن $x' = x + \eta$ نمونه دارای شروع تصادفی $\eta \sim \mathcal{U}([- \epsilon, \epsilon]^d)$ است و $\delta = \alpha \cdot \text{sign}(\nabla_x \mathcal{L}(f_\theta(x'), y))$ به گامی به اندازه α در جهت حمله است. اگر سطح اتلاف در همسایگی نمونه به‌طور محلی خطی باشد، گرادینان اتلاف در طول این دو نقطه نزدیک به هم تغییر چندانی نمی‌کند و در نتیجه هم‌ترازی آشفته‌گی به ۱ نزدیک می‌ماند. اما در آستانه بیش‌برازش فاجعه‌بار که سطح اتلاف به‌شدت غیرخطی می‌شود، جهت گرادینان میان این دو نقطه به‌سرعت تغییر می‌کند و هم‌ترازی آشفته‌گی به سمت صفر میل می‌کند. نکته مهم آن است که هر دو گرادینان مورد نیاز این سنجه، در روند معمول تولید نمونه دشمنانه و به‌روزرسانی وزن‌ها در آموزش تک‌مرحله‌ای، از پیش محاسبه می‌شوند؛ بنابراین محاسبه این سنجه عملاً سربار محاسباتی اضافه‌ای در بر ندارد.



شکل ۴.۶: روند درستی FGSM، درستی PGD-10 و مقدار هم‌ترازی آشفته‌گی در طول آموزش دشمنانه تک‌مرحله‌ای با معماری *PreActResNet18* روی مجموعه‌داده‌ی *CIFAR-10*. افت هم‌ترازی آشفته‌گی، پیش از واگرایی محسوس درستی FGSM و PGD-10 (یعنی پیش از وقوع آشکار بیش‌برازش فاجعه‌بار) رخ می‌دهد.

همان‌گونه که در شکل ۴.۶ مشاهده می‌شود، افت هم‌ترازی آشفته‌گی زودتر از واگرایی درستی FGSM و PGD-10 رخ می‌دهد و می‌تواند به‌عنوان هشدار زود هنگام برای وقوع قریب‌الوقوع بیش‌برازش فاجعه‌بار عمل کند، بدون آنکه هزینه محاسباتی محسوسی به آموزش تحمیل شود.

۴.۳ ایده کلی برای تنظیم پویای اندازه گام

با نگرستن به مسئله بیشینه‌سازی اتلاف از دیدگاه بهینه‌سازی مرتبه دوم و تقریب محلی سطح اتلاف با یک مدل درجه دوم، می‌توان اندازه گام بهینه‌ی حمله را به‌صورت پویا و متناسب با هندسه محلی چشم‌انداز تابع اتلاف تعیین کرد؛ اندازه گامی که با استفاده از همان اطلاعات به‌کاررفته در محاسبه هم‌ترازی آشفته‌گی و تقریباً بدون هزینه اضافه به دست می‌آید. ترکیب این سه ایده (تنوع‌بخشی به توزیع آشفته‌گی برای جلوگیری از بیش‌برازش، پیش‌بینی کم‌هزینه با هم‌ترازی آشفته‌گی و تعیین پویای اندازه گام) می‌تواند به روشی بینجامد که از وقوع بیش‌برازش فاجعه‌بار جلوگیری کند و با یک مجموعه ثابت از ابرپارامترها در دامنه‌ها و معماری‌های گوناگون قابل استفاده باشد. جزئیات کامل چنین روشی، به‌همراه ارزیابی گسترده آن روی مجموعه‌داده‌ها و معماری‌های متعدد، موضوع پایان‌نامه آینده خواهد بود.

۵ نتیجه‌گیری

در این سمینار، مسئله بیش‌برازش فاجعه‌بار به‌عنوان اصلی‌ترین مانع در مسیر آموزش دشمنانه سریع و کارآمد بررسی شد. ابتدا مفاهیم پایه‌ای حملات دشمنانه، آموزش دشمنانه، آموزش دشمنانه سریع و خود پدیده بیش‌برازش فاجعه‌بار به‌همراه پیوند آن با هندسه و انحنا، چشم‌انداز تابع اتلاف معرفی شدند. سپس کارهای پیشین در قالب چند دسته اصلی از جمله تصادفی‌سازی، منظم‌سازی، اندازه گام تطبیقی، سایر رویکردها و بهینه‌سازی مرتبه دوم مرور و نقاط ضعف آن‌ها، به‌ویژه نیاز به تنظیم پرهزینه ابرپارامترها و محاسبات اضافی، برجسته شد.

مرور انجام‌شده نشان می‌دهد که بیشتر روش‌های موجود یا تنها پس از وقوع بیش‌برازش فاجعه‌بار به آن واکنش نشان می‌دهند، یا برای پیش‌بینی آن به سنج‌های پرهزینه متکی‌اند. بر این اساس، جهت‌گیری امیدوارکننده، طراحی سنج‌های کم‌هزینه برای پیش‌بینی زودهنگام این پدیده و تنظیم پویای فرایند حمله بر پایه هندسه محلی سطح اتلاف است؛ رویکردی که می‌تواند قابلیت اطمینان آموزش دشمنانه سریع را بدون افزایش هزینه محاسباتی ارتقا دهد و شکافی مهم در ادبیات دفاع دشمنانه را پر کند. شاهد تجربی ارائه‌شده در فصل ۴ (هم‌روز آشکار بیش‌برازش اپسیلون در نوسانات درستی FGSM، و هم توانایی سنج هم‌ترازی آشفستگی در هشدار دادن پیش از واگرایی درستی FGSM و PGD-10) پشتوانه اولیه‌ای بر امکان‌پذیر بودن این جهت‌گیری فراهم می‌کند. بررسی دقیق، طراحی کامل روش و ارزیابی گسترده آن روی مجموعه‌داده‌ها و معماری‌های متنوع، موضوع کار آینده در پایان‌نامه خواهد بود.

- [1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, "Intriguing properties of neural networks," in *International Conference on Learning Representations (ICLR)*, 2014.
- [2] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Advances in Neural Information Processing Systems (NeurIPS)*, vol.25, pp.1106–1114, 2012.
- [3] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu, "Towards deep learning models resistant to adversarial attacks," in *International Conference on Learning Representations (ICLR)*, 2018.
- [4] E. Wong, L. Rice, and J. Z. Kolter, "Fast is better than free: Revisiting adversarial training," in *International Conference on Learning Representations (ICLR)*, 2020.
- [5] Z. Wang, H. Wang, C. Tian, and Y. Jin, "Preventing catastrophic overfitting in fast adversarial training: A bi-level optimization perspective," in *European Conference on Computer Vision (ECCV)*, pp.144–160, Springer, 2024.
- [6] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and harnessing adversarial examples," in *International Conference on Learning Representations (ICLR)*, 2015.
- [7] H. Kim, W. Lee, and J. Lee, "Understanding catastrophic overfitting in single-step adversarial training," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol.35, pp.8119–8127, 2021.
- [8] P. Kang and S.-M. Moosavi-Dezfooli, "Understanding catastrophic overfitting in adversarial training," 2021. arXiv preprint arXiv:2105.02942.
- [9] F. Croce and M. Hein, "Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks," in *International Conference on Machine Learning (ICML)*, pp.2206–2216, 2020.
- [10] D. Tsipras, S. Santurkar, L. Engstrom, A. Turner, and A. Madry, "Robustness may be at odds with accuracy," in *International Conference on Learning Representations (ICLR)*, 2019.
- [11] P. de Jorge Aranda, A. Bibi, R. Volpi, A. Sanyal, P. Torr, G. Rogez, and P. Dokania, "Make some noise: Reliable and efficient single-step adversarial training," *Advances in Neural Information Processing Systems (NeurIPS)*, vol.35, pp.12881–12893, 2022.
- [12] M. Andriushchenko and N. Flammarion, "Understanding and improving fast adversarial training," *Advances in Neural Information Processing Systems (NeurIPS)*, vol.33, pp.16048–16059, 2020.
- [13] G. Sriramanan, S. Addepalli, A. Baburaj, and R. V. Babu, "Towards efficient and effective adversarial training," *Advances in Neural Information Processing Systems (NeurIPS)*, vol.34, pp.11821–11833, 2021.
- [14] R. Lin, C. Yu, and T. Liu, "Eliminating catastrophic overfitting via abnormal adversarial examples regularization," *Advances in Neural Information Processing Systems (NeurIPS)*, vol.36, pp.67866–67885, 2023.
- [15] E. A. Rocamora, F. Liu, G. Chrysos, P. M. Olmos, and V. Cevher, "Efficient local linearity regularization to overcome catastrophic overfitting," in *International Conference on Learning Representations (ICLR)*, 2024.
- [16] Z. Nie, Y. Lin, S. Ren, and L. Zhang, "Adaptive perturbation adversarial training: Based on reinforcement learning," *arXiv preprint arXiv:2108.13239*, 2021.
- [17] Z. Huang, Y. Fan, C. Liu, W. Zhang, Y. Zhang, M. Salzmann, S. Süssstrunk, and J. Wang, "Fast adversarial training with adaptive step size," *IEEE Transactions on Image Processing*, vol.32, pp.6102–6114, 2023.
- [18] J.-C. Zhao, J. Ding, Y.-Z. Sun, P. Tan, J.-E. Ma, and Y.-T. Fang, "Avoiding catastrophic overfitting in fast adversarial training with adaptive similarity step size," *PLOS ONE*, vol.20, no.1, pp.1–22, 2025.
- [19] Z. Golgooni, M. Saberi, M. Eskandar, and M. H. Rohban, "Zerograd: Costless conscious remedies for catastrophic overfitting in the fgsm adversarial training," *Intelligent Systems with Applications*, vol.19, p.200258, 2023.
- [20] A. Shafahi, M. Najibi, M. A. Ghiasi, Z. Xu, J. Dickerson, C. Studer, L. S. Davis, G. Taylor, and T. Goldstein, "Adversarial training for free!," *Advances in Neural Information Processing Systems (NeurIPS)*, vol.32, 2019.
- [21] S.-M. Moosavi-Dezfooli, A. Fawzi, J. Uesato, and P. Frossard, "Robustness via curvature regularization, and vice versa," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

^{۳۱} Random Start
^{۳۲} Loss Function Landscape
^{۳۳} Distorted Intervals
^{۳۴} Curvature
^{۳۵} Hessian
^{۳۶} Evaluation Metrics
^{۳۷} Robustness-Accuracy Trade-off
^{۳۸} Clipping
^{۳۹} Regularization
^{۴۰} Gradient Alignment
^{۴۱} Perturbed
^{۴۲} Abnormal Adversarial Examples
^{۴۳} Local Linearity
^{۴۴} Free Adversarial Training
^{۴۵} Epsilon Overfitting

^{۱۶} Perturbation Alignment
^{۱۷} Loss
^{۱۸} Computer Vision
^{۱۹} Natural Language Processing
^{۲۰} Classification
^{۲۱} Adversarial Examples
^{۲۲} Training Epoch
^{۲۳} Robust Accuracy
^{۲۴} Accuracy
^{۲۵} Classifier
^{۲۶} Cross-Entropy Loss
^{۲۷} Projection Operator
^{۲۸} Robust Accuracy
^{۲۹} Optimization
^{۳۰} Min-Max

^۱ Deep Neural Network
^۲ Adversarial Attacks
^۳ Perturbation
^۴ Adversarial Training
^۵ Multi-Step
^۶ Projected Gradient Descent
^۷ Fast Adversarial Training
^۸ Single-Step
^۹ Fast Gradient Sign Method
^{۱۰} Catastrophic Overfitting
^{۱۱} Robustness
^{۱۲} Prediction
^{۱۳} Universal
^{۱۴} Dataset
^{۱۵} Architecture