دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی ارشد
مهندسی کامپیوتر، گرایش هوش مصنوعی و رباتیک

پیش‌بینی بیش‌برازش فاجعه‌بار در آموزش تخاصمی سریع

نگارش

فرزان رحمانی

استاد راهنما

دکتر محمدحسین رهبان

تاریخ دفاع: ...

سپاس

از استاد راهنمای خود، دکتر محمدحسین رهبان، برای راهنمایی علمی در این پژوهش سپاسگزارم.

همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

از پدر و مادر و خواهرم، برای مهر، همراهی و حمایت همیشگی‌شان در سراسر مسیر تحصیل و انجام این پژوهش، با تمام وجود سپاسگزاری می‌کنم.

چکیده

آموزش هم‌آورد از روش‌های مؤثر برای افزایش ستبری شبکه‌های عصبی در برابر آشفتگی‌های هدفمند ورودی است؛ بااین‌حال، ساخت نمونه‌های هم‌آورد با حملات چندگامی هزینه محاسباتی زیادی دارد. روش‌های سریع با تقریب تک‌گامی مسئله بیشینه‌سازی درونی این هزینه را کاهش می‌دهند، اما ممکن است به بیش‌برازش فاجعه‌بار دچار شوند: درستی در برابر حملات چندگامی به‌طور ناگهانی فرو می‌ریزد، درحالی‌که درستی در برابر حمله تک‌گامی همچنان زیاد است. این پایان‌نامه مسئله پیش‌بینی و پیشگیری کم‌هزینه از این پدیده را با بررسی هندسه تابع هزینه مطالعه می‌کند.

نخست، بیش‌برازش اپسیلون به‌عنوان حساسیت مدل به اندازه‌ها و جهت‌های محدود آشفتگی بررسی می‌شود. این دیدگاه توضیح می‌دهد چگونه آموزش روی نقاط حاصل از یک گام ثابت می‌تواند ناحیه‌های آسیب‌پذیر میان ورودی و نمونه هم‌آورد را پنهان کند. سپس شاخص هم‌راستایی آشفتگی، موسوم به PertAlign، از شباهت کسینوسی شیب ورودی پیش و پس از حمله تعریف می‌شود. تحلیل تیلور نشان می‌دهد افت این شاخص با مؤلفه عمود بر شیبِ اثر هسین در جهت آشفتگی ارتباط دارد. استفاده مجدد از شیب‌های موجود در آموزش، پایش این شاخص را بدون محاسبه صریح هسین و با سربار اندک ممکن می‌سازد.

بر پایه این تحلیل، روش تطبیقی مرتبه دوم SORA معرفی می‌شود که با تخمین خمیدگی جهتی، میانگین‌گیری نمایی و نمونه‌برداری مؤلفه‌ای اندازه گام، توزیع آشفتگی را در طول آموزش تنظیم می‌کند. نتایج منتشرشده پژوهش روی دادگان تصویری طبیعی و زیست‌پزشکی و معماری‌های گوناگون، بهبود بده‌بستان درستی پاک، ستبری و هزینه را نشان می‌دهند. برای نمونه، در ارزیابی AutoAttack با بودجه ۸/۲۵۵ روی PreActResNet-18، درستی SORA در PathMNIST برابر ٪۳۲/۹۱ و در ImageNet-100 برابر ٪۱۸/۵۶ گزارش شده است. این اعداد بازگویی نتایج مقاله مشترک منتشرشده در ICML 2026 هستند. همچنین، محدودیت تقریب محلی، تفاوت دامنه آشفتگی آموزش و ارزیابی، و نیاز به بررسی آماری هشدار زودهنگام تشریح می‌شود.

کلیدواژه‌ها: آموزش هم‌آورد سریع، بیش‌برازش فاجعه‌بار، بیش‌برازش اپسیلون، هم‌راستایی آشفتگی، خمیدگی، ستبری شبکه عصبی.

فهرست مطالب

۱ مقدمه ۱

۱-۱ مسئله اعتماد به شبکه‌های عصبی ۱

۱-۲ از آموزش چندگامی تا آموزش سریع ۲

۱-۳ بیش‌برازش فاجعه‌بار و شکاف ارزیابی ۲

۱-۴ پرسش‌ها و اهداف پژوهش ۳

۱-۵ دستاوردها و نسبت آن‌ها با مقاله مشترک ۳

۱-۶ دامنه و حدود ادعاها ۴

۱-۷ ساختار پایان‌نامه ۵

۲ مبانی و تعریف مسئله ۶

۲-۱ دسته‌بندی و تابع هزینه ۶

۲-۲ مدل تهدید و مجموعه آشفتگی ۷

۲-۳ حمله علامت شیب سریع ۷

۲-۴ حمله چندگامی با تصویرشدن ۸

۲-۵ آموزش هم‌آورد به‌عنوان بهینه‌سازی تودرتو ۹

۲-۶ درستی پاک و درستی هم‌آورد ۹

۲-۷ شیب، هسین و هندسه محلی ۱۰

۲-۸ دو نوع بیش‌برازش ۱۱

۳ پژوهش‌های مرتبط **۱۲**

۳-۱ چارچوب مقایسه روش‌ها ۱۲

۳-۲ آموزش چندگامی و بده‌بستان ستبری ۱۲

۳-۳ استفاده مجدد از محاسبات ۱۳

۳-۳-۱ آموزش هم‌آورد رایگان ۱۳

۳-۳-۲ یک گام همراه با آغاز تصادفی ۱۳

۳-۴ روش‌های مبتنی بر تنوع آشفتگی ۱۴

۳-۵ منظم‌سازی هندسه محلی ۱۵

۳-۵-۱ هم‌راستایی شیب ۱۵

۳-۵-۲ هموارسازی خروجی و خطی‌بودن محلی ۱۵

۳-۵-۳ نمونه‌های هم‌آورد غیرعادی ۱۵

۳-۶ انتخاب تطبیقی اندازه گام ۱۶

۳-۷ حذف مؤلفه‌های نامطمئن و استفاده از سابقه ۱۶

۳-۸ اطلاعات مرتبه دوم در دفاع هم‌آورد ۱۷

۳-۹ جایگاه پژوهش حاضر ۱۷

۴ هندسهٔ هزینه و هم‌راستایی آشفتگی **۱۹**

۴-۱ از شکست حملهٔ تک‌گامی تا تفسیر هندسی ۱۹

۴-۲ بیش‌برازش به اندازهٔ آشفتگی ۲۰

۴-۲-۱ نمونه‌های هم‌آورد غیرعادی ۲۲

۴-۳ تعریف و محاسبهٔ هم‌راستایی آشفتگی ۲۲

۴-۴ رابطهٔ محلی با هسین ۲۳

۴-۴-۱ چه چیزی از هم‌راستایی زیاد نتیجه نمی‌شود؟ ۲۴

۴-۵ مقایسه با هم‌راستایی شیب ۲۵

۵ روش تطبیقی مرتبهٔ دوم برای آموزش سریع ۲۷

۵-۱ هدف و دامنهٔ تحلیل ۲۷

۵-۲ بیشینه‌سازی اسکالر در جهت علامت شیب ۲۸

۵-۲-۱ بازیابی خمیدگی از یک گام کاوش ۲۹

۵-۳ از همانی دقیق تا کنترل‌کنندهٔ عملی ۳۰

۵-۳-۱ دامنه‌های تصادفی مؤلفه‌ای ۳۱

۵-۴ میانگین نمایی و ترتیب زمانی الگوریتم ۳۱

۵-۵ مرز آموزش و مجموعهٔ تهدید ارزیابی ۳۲

۵-۶ پیچیدگی، اجرای مشتق و حدود اعتبار ۳۴

۶ ارزیابی تجربی و تحلیل نتایج ۳۶

۶-۱ دامنه و منشأ شواهد ۳۶

۶-۲ مدل تهدید و پروتکل ارزیابی ۳۷

۶-۳ دادگان، معماری‌ها و تنظیمات آموزش ۳۸

۶-۳-۱ تنوع مسائل دسته‌بندی ۳۸

۶-۳-۲ تنظیمات مشترک و تفاوت‌های ضروری ۳۹

۶-۳-۳ مقایسهٔ منصفانه و معنای تنظیم ثابت ۳۹

۶-۴ نتایج اصلی روی دو مسئلهٔ دشوار ۴۰

۶-۵ خوانش تفصیلی نتایج و حدود تعمیم ۴۱

۶-۶ حذف مؤلفه‌ها و حساسیت ابرپارامترها ۴۴

۶-۶-۱ سهم سازگاری و تنوع آشفتگی ۴۴

۶-۶-۲ حساسیت به سقف و ضریب گام ۴۵

۶-۷ بودجهٔ آشفتگی و اندازهٔ دسته ۴۶

۶-۸ کارایی محاسباتی و حافظه ۴۷

۶-۹ اعتبار شاخص هشدار و زمان پیش‌آگاهی ۴۸

۶-۱۰ برداشت نهایی از شواهد ۴۸

۷ جمع‌بندی و مسیرهای آینده ۵۰

۷-۱ پاسخ به پرسش پژوهش ۵۰

۷-۲ از پایش تا اصلاح آموزش ۵۱

۷-۳ برداشت از نتایج ۵۱

۷-۴ محدودیت‌های باقی‌مانده ۵۱

۷-۵ پیشنهادهای ادامه پژوهش ۵۲

مراجع ۵۳

واژه‌نامه ۵۶

آ مشخصات فنی، بازتولید و ردگیری منابع ۶۰

آ-۱ کارکرد پیوست و قرارداد گزارش ۶۰

آ-۲ نمادها و کمیت‌های قابل مشاهده ۶۰

آ-۳ مشخصات عملی گام سازگار ۶۲

آ-۴ تنظیمات آموزش و استثناهای خطوط مبنا ۶۳

آ-۵ هزینهٔ محاسبات و معنای کم‌هزینه‌بودن ۶۴

آ-۶ نگاشت آزمایش‌ها به منابع ۶۵

آ-۷ تفاوت گزارش‌ها و مسائل حل‌نشده ۶۶

آ-۸ الزامات بازتولید آینده و حدود استنتاج ۶۷

فهرست جداول

۳-۱ مقایسه سازوکارهای آموزش هم‌آورد سریع ۱۸

۶-۱ دادگان، ابعاد ورودی و بودجه ارزیابی ۳۸

۶-۲ نتایج اصلی روی دادگان بافت‌شناسی و صدکلاسه ۴۰

۶-۳ گزیده نتایج مطلق روی دادگان تصویری طبیعی ۴۲

۶-۴ وابستگی نتایج به معماری و دادگان ۴۳

۶-۵ مقایسه تفصیلی با روش‌های چندگامی روی دادگان بافت‌شناسی ۴۴

۶-۶ آزمایش حذف مؤلفه‌های روش پیشنهادی ۴۴

۶-۷ حساسیت به ابرپارامترهای کنترل گام ۴۵

۶-۸ حساسیت روش‌ها به بودجه آموزش ۴۶

آ-۱ نمادها و کمیت‌های روش ۶۱

آ-۲ تنظیمات مستند برای بازتولید آزمایش‌ها ۶۳

آ-۳ انتقال‌پذیری تنظیم خطوط مبنا ۶۴

آ-۴ مقایسه شمار گذرهای شبکه و مرتبه حافظه ۶۵

آ-۵ نگاشت آزمایش‌ها به صفحه و شناسه منبع ۶۶

آ-۶ تفکیک گزارش اصلی، حذف مؤلفه‌ها و گزارش تجمیعی ۶۶

فهرست تصاویر

۴-۱ تحول هندسه هزینه پیش و پس از بیش‌برازش فاجعه‌بار ۲۰

۴-۲ درستی در برابر تغییر اندازه حمله و بیش‌برازش اپسیلون ۲۱

۴-۳ پایش هم‌راستایی آشفتگی و هشدار پیش از فروپاشی ۲۳

۵-۱ تفسیر هندسی اصلاح اندازه گام و نمونه‌های غیرعادی ۳۰

۵-۲ تغییرات هم‌راستایی آشفتگی و سقف تطبیقی گام ۳۳

۶-۱ تعمیم تنظیمات میان دادگان و معماری‌ها ۴۱

۶-۲ بده‌بستان زمان، حافظه و درستی هم‌آورد ۴۷

فصل ۱

مقدمه

۱-۱ مسئله اعتماد به شبکه‌های عصبی

شبکه‌های عصبی عمیق در دسته‌بندی تصویر، پردازش زبان و تحلیل داده‌های پیچیده به ابزارهایی پرکاربرد تبدیل شده‌اند. بااین‌حال، درستی زیاد روی نمونه‌های آزمون معمول لزوماً به معنای پایداری تصمیم در همسایگی همان نمونه‌ها نیست. پژوهش‌های آغازین نشان دادند می‌توان با تغییری کوچک و هدفمند در ورودی، خروجی یک شبکه را تغییر داد؛ تغییری که گاه برای مشاهده‌گر انسانی به‌آسانی تشخیص‌پذیر نیست [۱، ۲]. چنین ورودی‌ای نمونه هم‌آورد نامیده می‌شود. در این نوشتار، برابر «هم‌آورد» برای adversarial و «آشفتگی» برای perturbation به کار می‌رود. عنوان پایان‌نامه مطابق پیشنهاد اولیه حفظ شده است و «تخاصمی» در آن به همین مفهوم اشاره دارد.

آسیب‌پذیری هم‌آورد یک پرسش بنیادی درباره آنچه مدل از داده آموخته است مطرح می‌کند: آیا تصمیم مدل در یک ناحیه معنادار پیرامون نمونه پایدار است یا تنها در خود نقاط آزمون درست به نظر می‌رسد؟ این پرسش به‌ویژه هنگامی مهم می‌شود که خروجی مدل بخشی از یک سامانه تصمیم‌گیری باشد. البته وجود یک دفاع تجربی در برابر آشفتگی‌های محدود پیکسلی به‌تنهایی ایمنی یک سامانه پزشکی یا خودمختار را اثبات نمی‌کند؛ ارزش این چارچوب، فراهم‌کردن مسئله‌ای دقیق و سنجش‌پذیر برای مطالعه بخشی از آسیب‌پذیری است.

در میان دفاع‌های پیشنهادی، آموزش هم‌آورد جایگاه ویژه‌ای دارد. در این روش، شبکه تنها با ورودی پاک آموزش نمی‌بیند؛ نمونه‌هایی که برای افزایش هزینه مدل ساخته شده‌اند نیز در فرایند یادگیری حضور دارند. هدف آن است که مدل در دشوارترین نقاط یک مجموعه آشفتگی ازپیش‌تعریف‌شده نیز عملکرد قابل‌قبولی داشته باشد [۳]. مشکل عملی آن است که یافتن این نقاط دشوار معمولاً به چند بار محاسبه

شیب نسبت به ورودی نیاز دارد و هزینه آموزش را افزایش می‌دهد.

۱-۲ از آموزش چندگامی تا آموزش سریع

صورت متداول آموزش هم‌آورد یک مسئله کمینه‌سازی و بیشینه‌سازی تودرتو است. مسئله درونی، ورودی نامطلوب را برای پارامترهای فعلی می‌جوید و مسئله بیرونی پارامترها را با توجه به آن بهبود می‌دهد. در روش چندگامی، حمله‌ای مانند PGD چند بار در جهت افزایش هزینه حرکت می‌کند و پس از هر حرکت به مجموعه مجاز تصویر می‌شود. این تکرار، تقریب قوی‌تری از مسئله درونی فراهم می‌کند، اما زمان و منابع بیشتری می‌طلبد.

آموزش هم‌آورد سریع با جایگزین‌کردن حمله چندگامی با حمله تک‌گامی، این هزینه را کاهش می‌دهد [۴]. جذابیت این ایده روشن است: اگر یک گام مبتنی بر شیب بتواند نمونه‌ای به‌اندازه کافی دشوار بسازد، بخش عمده هزینه حمله حذف می‌شود. بااین‌حال، کیفیت این تقریب به هندسه تابع هزینه وابسته است. یک گام ممکن است در ناحیه‌ای تقریباً خطی مناسب باشد، اما پس از تغییر شکل تابع هزینه از یک ناحیه آسیب‌پذیر عبور کند و به نقطه‌ای با هزینه کمتر برسد.

بنابراین، «سریع» بودن تنها با شمردن گام‌های حمله تعریف نمی‌شود. روشی که یک اجرای آن ارزان است ولی برای یافتن تنظیم پایدار به چندین اجرای ناموفق نیاز دارد، ممکن است در عمل هزینه زیادی داشته باشد. همچنین، کاهش زمان همراه با سقوط درستی پاک یا شکست روی یک دادگان دیگر، پاسخ کاملی به مسئله آموزش قابل‌اتکا نیست. در این پژوهش، هزینه هر اجرا، پایداری، درستی پاک و درستی هم‌آورد هم‌زمان بررسی می‌شوند.

۱-۳ بیش‌برازش فاجعه‌بار و شکاف ارزیابی

بیش‌برازش فاجعه‌بار به حالتی گفته می‌شود که در طول آموزش سریع، درستی مدل در برابر حملات چندگامی در زمانی کوتاه به‌شدت افت می‌کند، درحالی‌که درستی در برابر حمله تک‌گامی آموزش ممکن است همچنان زیاد یا حتی رو به افزایش باشد [۴، ۵]. این ناهمخوانی نشان می‌دهد مدل در برابر روش خاص تولید نمونه آموزشی سازگار شده است، اما این سازگاری به تمام ناحیه تهدید تعمیم پیدا نکرده است.

ویژگی خطرناک پدیده آن است که شاخص‌های ظاهراً مطلوب آموزش می‌توانند هم‌زمان با ازبین‌رفتن ستبری دیده شوند. کاهش هزینه روی نمونه‌های تولیدشده با FGSM لزوماً به معنای کاهش بیشینه هزینه

در کره آشفتگی نیست. اگر خود مولد نمونه هم‌آورد شکست خورده باشد، بهینه‌سازی بیرونی روی مسئله‌ای آسان‌تر از مسئله واقعی ادامه می‌یابد. ارزیابی با همان حمله آموزش، این شکست را پنهان می‌کند.

این وضعیت دو نیاز مرتبط ایجاد می‌کند. نخست، باید نشانه‌ای از نامعتبرشدن تقریب تک‌گامی را پیش از فروپاشی آشکار درستی چندگامی مشاهده کرد. دوم، باید از اطلاعات همان نشانه برای اصلاح ساخت نمونه آموزشی استفاده کرد. پایش دائمی یک حمله قوی راهی مستقیم برای مشاهده افت است، اما ممکن است با هدف کم‌هزینه‌بودن آموزش سریع ناسازگار شود. مسئله اصلی پایان‌نامه، دستیابی به اطلاعات هشداردهنده از محاسباتی است که از قبل در آموزش انجام می‌شوند.

۱-۴ پرسش‌ها و اهداف پژوهش

پرسش نخست این است که محدودبودن اندازه و جهت آشفتگی آموزش چگونه با تغییر هندسه تابع هزینه و بیش‌برازش فاجعه‌بار مرتبط می‌شود. برای پاسخ، باید رفتار مدل را نه‌فقط در اندازه آشفتگی آموزش، بلکه در نقاط میانی همان جهت نیز بررسی کرد. اگر مدل تنها در چند فاصله خاص عملکرد مطلوبی داشته باشد، درستی بالای حمله آموزش می‌تواند تصویری ناقص از ستبری ارائه دهد.

پرسش دوم به پیش‌بینی مربوط است: آیا مقایسه شیب ورودی پیش و پس از حمله، افت کیفیت تقریب تک‌گامی را پیش از جدایی آشکار درستی تک‌گامی و چندگامی نشان می‌دهد؟ پاسخ کاربردی باید هم از نظر هندسی تفسیرپذیر باشد و هم برای محاسبه به گذرهای متعدد اضافی نیاز نداشته باشد. ارتباط با خمیدگی مهم است، اما محاسبه کامل هسین در ابعاد تصاویر گزینه مناسبی برای روش سریع نیست.

پرسش سوم، ساخت یک سازوکار اصلاحی است. اگر از اختلاف دو شیب بتوان اطلاعاتی درباره خمیدگی جهتی به دست آورد، آیا می‌توان اندازه گام حمله را با آن تنظیم کرد؟ چنین سازوکاری باید نوسان دسته‌های آموزشی را نیز تحمل کند و از وابستگی شدید به تنظیم جداگانه برای هر دادگان یا معماری بکاهد. ارزیابی تجربی باید نشان دهد این هدف در چه تنظیم‌هایی برآورده شده و در چه مواردی محدودیت باقی مانده است.

۱-۵ دستاوردها و نسبت آن‌ها با مقاله مشترک

هسته علمی پایان‌نامه بر پژوهش مشترک با عنوان SORA: Free Second-Order Attacks in Fast Adversarial Training استوار است که در ICML 2026 منتشر شده است [۶]. نویسندگان مقاله، به

ترتیب، Mazdak Teymourian، Ramtin Moslemi، فرزان رحمانی و دکتر محمدحسین رهبان هستند. مطالب مربوط به آزمایش‌ها و روش SORA در این نوشتار به این کار مشترک ارجاع داده می‌شوند؛ ترتیب نویسندگان، به‌تنهایی مبنایی برای نسبت‌دادن بخش خاصی از پژوهش به یک فرد نیست.

سه محور اصلی پژوهش عبارت‌اند از:

۱. بررسی بیش‌برازش اپسیلون و نشان‌دادن اهمیت پوشش اندازه‌ها و جهت‌های متنوع آشفتگی در آموزش سریع؛

۲. تعریف شاخص هم‌راستایی آشفتگی یا PertAlign با استفاده از دو شیب موجود در فرایند آموزش و تحلیل ارتباط محلی آن با هسین؛

۳. طراحی روش SORA برای انتخاب تطبیقی توزیع اندازه گام و ارزیابی آن روی دادگان و معماری‌های گوناگون.

گزارش سمینار پیشین، مسئله و کارهای مرتبط را مرور کرده و ایده هم‌راستایی آشفتگی و تنظیم گام را در مرحله اولیه مطرح کرده بود. پیشنهاد پایان‌نامه نیز بر پیش‌بینی کم‌هزینه بیش‌برازش تمرکز داشت. مقاله نهایی، این مسیر را با تحلیل و ارزیابی گسترده‌تر تکمیل کرده است. بنابراین، ایده‌های آینده در متن سمینار در این پایان‌نامه صرفاً زمانی به‌عنوان نتیجه ارائه می‌شوند که مقاله برای آن‌ها شواهد مشخص داشته باشد.

۱-۶ دامنه و حدود ادعاها

دامنه اصلی مطالعه، دسته‌بندی تصویر و آشفتگی‌های محدود با نرم ℓ_∞ است. نتایج اصلی بر ارزیابی‌های تجربی با حملات مشخص متکی هستند و گواهی ریاضی ستبری برای تمام ورودی‌های مجاز محسوب نمی‌شوند. همچنین، تفسیر مرتبه دوم بر تقریب محلی و فرض‌های همواری متکی است؛ در یک شبکه واقعی با تابع‌های فعال‌سازی تکه‌ای و برش پیکسل، این تفسیر باید با احتیاط به کار رود.

تمام اعداد گزارش‌شده در فصل آزمایش‌ها از نسخه مقاله و پیوست ارائه‌شده استخراج شده‌اند. در آماده‌سازی این نوشتار، آموزش شبکه یا آزمایش آماری تازه‌ای اجرا نشده است. هرجا متن اصلی و پیوست، عدد یا تنظیم متفاوتی ارائه می‌کنند، محل گزارش مشخص می‌شود. این تفکیک برای جلوگیری از ترکیب نادرست آزمایش‌ها و برای بازسازی دقیق‌تر نتایج ضروری است.

همچنین، مشاهده هشدار زودتر در یک نمودار با ساخت یک پیش‌بین کالیبره‌شده یکسان نیست. تعیین آستانه عمومی، نرخ هشدار کاذب و توزیع زمان پیش‌آگاهی به ارزیابی جداگانه نیاز دارد. پایان‌نامه، شواهد

موجود درباره هشدار را تفسیر می‌کند و این ارزیابی‌های تکمیلی را به‌عنوان مسیر ادامه پژوهش مشخص می‌سازد.

۱-۷ ساختار پایان‌نامه

فصل دوم مفاهیم دسته‌بندی، مدل تهدید، حملات و آموزش هم‌آورد را تعریف می‌کند. فصل سوم کارهای مرتبط را بر پایه سازوکار مقابله با بیش‌برازش مرور می‌کند. فصل چهارم به بیش‌برازش اپسیلون و شاخص PertAlign اختصاص دارد. در فصل پنجم، استخراج اندازه گام مرتبه دوم و الگوریتم عملی SORA ارائه می‌شود. فصل ششم نتایج، تنظیم آزمایش‌ها و محدودیت‌های مقایسه را بررسی می‌کند. فصل هفتم به جمع‌بندی و پیشنهادهای آینده می‌پردازد. پیوست، نمادها و اطلاعات لازم برای دنبال‌کردن منبع و بازتولید پژوهش را گردآوری می‌کند و واژه‌نامه، معادل‌های فارسی و انگلیسی اصطلاحات را در دسترس قرار می‌دهد.

فصل ۲

مبانی و تعریف مسئله

۲-۱ دسته‌بندی و تابع هزینه

فرض می‌کنیم $x \in [۰, ۱]^d$ یک تصویر با d مؤلفه و $y \in \{۱, \dots, C\}$ برچسب آن باشد. شبکه $f_\theta : \mathbb{R}^d \to \mathbb{R}^C$ با پارامتر θ، بردار امتیازهای پیش از نرمال‌سازی را تولید می‌کند. دسته پیش‌بینی‌شده برابر است با

$$\widehat{y}_\theta(x) = \arg\max_{c \in \{۱,\dots,C\}} f_\theta(x)_c. \tag{۱-۲}$$

برای تبدیل امتیازها به توزیع احتمال از بیشینه هموار استفاده می‌شود:

$$q_\theta(c \mid x) = \frac{\exp(f_\theta(x)_c)}{\sum_{j=۱}^{C} \exp(f_\theta(x)_j)}. \tag{۲-۲}$$

تابع هزینه آنتروپی متقاطع برای برچسب درست به شکل

$$\mathcal{L}(f_\theta(x), y) = -\log q_\theta(y \mid x) \tag{۳-۲}$$

تعریف می‌شود. در ادامه، هنگامی که θ و y ثابت‌اند، از نماد کوتاه $\ell(x)$ برای همین هزینه استفاده می‌کنیم. تمایز میان هزینه و درستی ضروری است: هزینه به اطمینان پیش‌بینی نیز حساس است، اما درستی تنها درست یا نادرست‌بودن دسته نهایی را می‌شمارد.

در آموزش معمول، امید هزینه روی توزیع داده $\mathcal{D}$ کمینه می‌شود. در عمل، این امید با میانگین روی داده آموزشی و سپس روی دسته‌های کوچک تقریب زده می‌شود. اگر B یک دسته باشد، هزینه دسته برابر است با

$$\mathcal{L}_B(\theta) = \frac{۱}{|B|} \sum_{(x,y) \in B} \mathcal{L}(f_\theta(x), y). \tag{۴-۲}$$

یک دوره آموزش، معمولاً یک پیمایش داده آموزشی است؛ یک به‌روزرسانی دسته تنها بخشی از آن است. ازاین‌رو، زمان هشدار برحسب دسته را نمی‌توان بدون دانستن تعداد دسته‌ها به دوره تبدیل کرد.

۲-۲ مدل تهدید و مجموعه آشفتگی

تعریف ۲-۱ (آشفتگی مجاز) *برای تصویر x و بودجه $\epsilon > ۰$، مجموعه تهدید نرم بی‌نهایت را به صورت*

$$\Delta_\infty(x,\epsilon) = \{\delta \in \mathbb{R}^d : \|\delta\|_\infty \leqslant \epsilon, \quad x+\delta \in [۰,۱]^d\} \tag{۵-۲}$$

تعریف می‌کنیم که در آن $\|\delta\|_\infty = \max_j |\delta_j|$ است.

این قید بیشینه تغییر هر مؤلفه را محدود می‌کند. برای تصویر با مقیاس $[۰,۱]$، بودجه ۸/۲۵۵ به معنای حداکثر تغییر هشت سطح از مقیاس هشت‌بیتی در هر مؤلفه است. این تعریف، یک قرارداد ریاضی برای ارزیابی است و به‌تنهایی تضمین نمی‌کند که هر آشفتگی مجاز از نظر ادراکی نامحسوس باشد. اهمیت یک بودجه ثابت می‌تواند برای دو دادگان با بافت و تفکیک‌پذیری متفاوت، یکسان نباشد.

حمله بدون هدف می‌کوشد مدل را از دسته درست خارج کند و معمولاً هزینه برچسب درست را افزایش می‌دهد. حمله هدفمند، خروجی را به دسته‌ای مشخص هدایت می‌کند. تمرکز این پژوهش بر حالت بدون هدف است. در ارزیابی جعبه سفید، حمله به پارامترها و شیب مدل دسترسی دارد؛ بنابراین، افت عملکرد را نمی‌توان صرفاً به محدودبودن اطلاعات مهاجم نسبت داد.

باید میان «اندازه گام» و «بودجه تهدید» تفاوت گذاشت. بودجه، مجموعه مجاز ارزیابی را تعریف می‌کند، اما اندازه گام، حرکت الگوریتم حمله را کنترل می‌کند. یک حمله تکراری می‌تواند گامی بزرگ‌تر از بودجه بردارد و سپس به مجموعه مجاز تصویر شود. در مقابل، اگر تصویرشدن به کره حذف شود، دامنه ورودی‌های آموزشی می‌تواند از کره ارزیابی بزرگ‌تر باشد. این تفاوت در تفسیر SORA نقش دارد و در فصل روش تصریح می‌شود.

۲-۳ حمله علامت شیب سریع

با ثابت‌گرفتن پارامترها، بسط مرتبه اول هزینه در x می‌دهد

$$\ell(x+\delta) \approx \ell(x) + g^\top \delta, \qquad g = \nabla_x \ell(x). \tag{۶-۲}$$

بیشینه جمله خطی تحت قید $\|\delta\|_\infty \leqslant \epsilon$ با انتخاب مؤلفه‌ای علامت شیب به دست می‌آید:

$$\delta_{\mathrm{FGSM}} = \epsilon \ \mathrm{sign}(g), \qquad x_{\mathrm{adv}} = \Pi_{[۰,۱]^d}\big(x + \delta_{\mathrm{FGSM}}\big). \tag{۲-۷}$$

این روش، حمله علامت شیب سریع یا FGSM نام دارد [۲]. دلیل انتخاب علامت آن است که هر مؤلفه مستقل از مؤلفه‌های دیگر، سهم خود را در ضرب داخلی بیشینه می‌کند. اگر $g_j > ۰$ باشد، انتخاب $\delta_j = \epsilon$ و اگر $g_j < ۰$ باشد، انتخاب $\delta_j = -\epsilon$ مناسب است. مؤلفه صفر شیب در تقریب خطی جهت ترجیحی ندارد.

این استدلال برای تابع خطی دقیق است، اما تابع هزینه یک شبکه عمیق در یک ناحیه بزرگ الزاماً خطی نیست. حمله تک‌گامی تنها شیب نقطه آغاز را می‌بیند. اگر جهت شیب یا خمیدگی در طول مسیر به‌شدت تغییر کند، نقطه انتهایی گام لزوماً بدترین نقطه مسیر نیست. بنابراین، شکست FGSM در یافتن نمونه نامطلوب نمی‌تواند به‌تنهایی نشانه ستبری مدل باشد.

آغاز تصادفی یکی از راه‌های افزایش تنوع است. ابتدا η از یک توزیع روی همسایگی ورودی نمونه‌برداری می‌شود و شیب در $x + \eta$ محاسبه می‌شود. بااین‌حال، انتخاب دامنه نویز، اندازه گام و وجود یا نبود تصویرشدن به کره، روش‌های متفاوتی می‌سازد. همه روش‌های دارای آغاز تصادفی یک حمله واحد نیستند.

۲-۴ حمله چندگامی با تصویرشدن

در حمله PGD، تخمین آشفتگی به‌طور تکراری به‌روزرسانی می‌شود [۳]:

$$\delta^{(۰)} \sim \mathcal{U}([-\epsilon, \epsilon]^d), \tag{۲-۸}$$

$$\delta^{(t+۱)} = \Pi_{\Delta_\infty(x,\epsilon)}\left(\delta^{(t)} + a \ \mathrm{sign}\big(\nabla_x \mathcal{L}(f_\theta(x + \delta^{(t)}), y)\big)\right). \tag{۲-۹}$$

در این رابطه، a اندازه گام و t شماره گام است. نام تاریخی روش به نزول شیب اشاره دارد، ولی برای افزایش هزینه در مسئله درونی، جهت صعود به کار می‌رود. در قید نرم بی‌نهایت، تصویرشدن را می‌توان با برش مؤلفه‌ای پیاده‌سازی کرد:

$$\delta_j \leftarrow \min\{\epsilon, ۱ - x_j, \max\{-\epsilon, -x_j, \delta_j\}\}. \tag{۲-۱۰}$$

برش به دامنه پیکسل و برش به بودجه آشفتگی دو قید مستقل هستند.

افزایش تعداد گام‌ها و استفاده از چند آغاز تصادفی می‌تواند احتمال یافتن نقاط دشوارتر را افزایش دهد، اما موفقیت حمله به تنظیم درست اندازه گام و تابع هدف نیز وابسته است. بنابراین، نام PGD-10

به‌تنهایی تمام پروتکل ارزیابی را مشخص نمی‌کند. بودجه، اندازه گام، تعداد بازآغازها، تعداد نمونه آزمون و شیوه انتخاب نقطه کنترل نیز برای مقایسه لازم‌اند.

۲-۵ آموزش هم‌آورد به‌عنوان بهینه‌سازی تودرتو

صورت اصلی مسئله مورد مطالعه چنین است:

$$\min_{\theta} \ \mathbb{E}_{(x,y)\sim\mathcal{D}} \left[\max_{\delta\in\Delta_\infty(x,\epsilon)} \mathcal{L}(f_\theta(x+\delta), y) \right]. \tag{۲-۱۱}$$

در هر به‌روزرسانی، ابتدا برای پارامترهای فعلی نمونه هم‌آورد ساخته می‌شود و سپس هزینه همان نمونه نسبت به پارامترها کمینه می‌شود. در پیاده‌سازی رایج، مسیر تولید آشفتگی از نمودار مشتق‌گیری به‌روزرسانی وزن‌ها جدا می‌شود؛ به‌عبارت دیگر، به‌روزرسانی پارامتر معمولاً مشتق کامل همه گام‌های مولد حمله را محاسبه نمی‌کند.

اگر مسئله درونی ضعیف حل شود، مسئله بیرونی روی هزینه‌ای کمتر از بیشینه واقعی آموزش می‌بیند. این خطا صرفاً یک تقریب عددی ثابت نیست؛ مدل ممکن است در طول آموزش شکل تابع هزینه را طوری تغییر دهد که حل‌کننده درونی بیشتر دچار خطا شود. بیش‌برازش فاجعه‌بار نمونه برجسته این برهم‌کنش میان مدل و مولد نمونه آموزشی است.

در آموزش سریع، هدف کاهش هزینه حل درونی است. اگر ساخت حمله K بار مشتق نسبت به ورودی بخواهد، بخش حمله تقریباً با K رشد می‌کند؛ بااین‌حال، زمان کل دقیقاً K برابر نمی‌شود، زیرا بارگذاری داده، گذر پیشرو، به‌روزرسانی پارامتر و ویژگی‌های سخت‌افزار نیز مؤثرند. مقایسه هزینه باید با اندازه‌گیری روی شرایط یکسان یا با شمارش روشن گذرهای محاسباتی انجام شود.

۲-۶ درستی پاک و درستی هم‌آورد

برای مجموعه آزمون $\{(x_i, y_i)\}_{i=1}^n$، درستی پاک برابر است با

$$\widehat{A}_{\text{clean}} = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}\{\widehat{y}_\theta(x_i) = y_i\}. \tag{۲-۱۲}$$

درستی ستبر واقعی در مدل تهدید مشخص، مستلزم درست‌بودن پیش‌بینی برای تمام آشفتگی‌های مجاز است:

$$\widehat{A}_{\text{rob}} = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}\{\forall \delta \in \Delta_\infty(x_i, \epsilon) : \widehat{y}_\theta(x_i+\delta) = y_i\}. \tag{۲-۱۳}$$

در عمل، حمله تنها برخی نقاط را می‌جوید. درستی تجربی در برابر یک حمله، معمولاً کران بالایی بر درستی ستبر واقعی است، زیرا شکست حمله در یافتن خطا به معنای نبود خطا نیست. چون صفر در مجموعه آشفتگی حضور دارد، درستی ستبر واقعی از درستی پاک بیشتر نمی‌شود؛ ولی درستی یک حمله خاص می‌تواند از درستی پاک بیشتر شود، زیرا حمله ممکن است برخی نمونه‌های ابتدا نادرست را به دسته درست جابه‌جا کند.

AutoAttack مجموعه‌ای از حملات مکمل را برای ارزیابی پایاتر گرد می‌آورد [۷]. هدف آن کاهش اتکا به یک حمله یا یک انتخاب حساس ابرپارامتر است. بااین‌حال، این ارزیابی نیز تجربی است. در این پایان‌نامه، هرگاه «درستی هم‌آورد» با نام حمله گزارش می‌شود، منظور درستی تجربی تحت همان پروتکل است و نه گواهی جامع ستبری.

۲-۷ شیب، هسین و هندسه محلی

برای تابع هزینه هموار، شیب $g = \nabla_x \ell(x)$ جهت بیشترین افزایش مرتبه اول در هندسه اقلیدسی را نشان می‌دهد و هسین $H = \nabla_x^2 \ell(x)$ تغییر شیب در همسایگی را توصیف می‌کند. بسط مرتبه دوم چنین است:

$$\ell(x+\delta) = \ell(x) + g^\top \delta + \frac{1}{2}\delta^\top H \delta + R(\delta). \tag{۱۴-۲}$$

اگر هسین در همسایگی لیپشیتس باشد، باقی‌مانده هزینه از مرتبه $\|\delta\|^3$ است. روی مسیر ثابت $\delta = \alpha v$، جمله درجه دوم تنها به کمیت اسکالر $v^\top H v$ وابسته می‌شود. این کمیت، خمیدگی جهتی است و با کل هسین یکسان نیست.

محاسبه و نگهداری صریح یک ماتریس $d \times d$ برای تصاویر بزرگ پرهزینه است. در مقابل، دو شیب در نقاط نزدیک حاوی اطلاعاتی درباره Hv هستند:

$$\nabla_x \ell(x + \alpha v) - \nabla_x \ell(x) \approx \alpha H v. \tag{۱۵-۲}$$

این رابطه اساس استفاده غیرمستقیم از اطلاعات مرتبه دوم است. مزیت آن زمانی بیشتر می‌شود که هر دو شیب، به دلایل دیگری در آموزش محاسبه شده باشند.

شباهت کسینوسی دو بردار ناصفر a و b برابر است با

$$\cos(a,b) = \frac{a^\top b}{\|a\|_2 \|b\|_2}. \tag{۱۶-۲}$$

این کمیت جهت را مقایسه می‌کند و نسبت به ضرب هر بردار در یک اسکالر مثبت ناورداست. در نتیجه، تغییر بزرگی شیب بدون تغییر جهت ممکن است در آن دیده نشود. این ویژگی هم برای تفسیر PertAlign

مفید است و هم حد اطلاعاتی آن را نشان می‌دهد. در پیاده‌سازی، شیب صفر و مخرج بسیار کوچک باید با قاعده عددی روشن مدیریت شوند.

۲-۸ دو نوع بیش‌برازش

بیش‌برازش متداول به افت تعمیم از داده آموزشی به داده آزمون اشاره دارد. بیش‌برازش ستبر در آموزش چندگامی نیز می‌تواند پس از مدتی به افت تدریجی درستی هم‌آورد آزمون منجر شود [۸]. در مقابل، بیش‌برازش فاجعه‌بار معمولاً یک فروپاشی سریع همراه با شکاف میان حمله تک‌گامی و چندگامی است. یکسان‌گرفتن این پدیده‌ها سبب می‌شود راه‌حل‌هایی مانند توقف زودهنگام یا انتخاب نقطه کنترل بدون توجه به علت شکست به کار روند.

در این پژوهش، تمرکز بر نامعتبرشدن حل درونی تک‌گامی و نشانه‌های هندسی آن است. جلوگیری از این شکست، به‌تنهایی همه مسائل تعمیم، نامتوازن‌بودن دسته‌ها یا حساسیت به جابه‌جایی توزیع را حل نمی‌کند. تفکیک این اهداف کمک می‌کند نتایج تجربی با پرسش علمی مناسب سنجیده شوند.

فصل ۳

پژوهش‌های مرتبط

۳-۱ چارچوب مقایسه روش‌ها

روش‌های آموزش هم‌آورد سریع را می‌توان بر پایه نقطه‌ای که در زنجیره آموزش تغییر می‌دهند مقایسه کرد. برخی روش‌ها توزیع آغاز حمله را عوض می‌کنند، برخی شکل تابع هزینه را با منظم‌سازی محدود می‌کنند و گروهی اندازه گام یا اطلاعات انتقال‌یافته از گذشته را تغییر می‌دهند. این دسته‌بندی کاملاً جدا از هم نیست؛ برای نمونه، یک روش می‌تواند هم آغاز تصادفی داشته باشد و هم از منظم‌سازی استفاده کند.

در این فصل، معیار اصلی مقایسه تنها بیشترین درستی روی یک دادگان نیست. یک روش سریع باید کیفیت حل درونی، هزینه گذرهای اضافی، حافظه، حساسیت ابرپارامتر و قابلیت استفاده در تنظیم‌های مختلف را نیز در نظر بگیرد. این نگاه با هدف پیشنهاد پایان‌نامه، یعنی پیش‌بینی کم‌هزینه بیش‌برازش، سازگار است. بخش مهمی از مرور زیر در سمینار پیشین نیز بررسی شده بود؛ در اینجا ارتباط آن با نتایج نهایی SORA روشن‌تر می‌شود.

۳-۲ آموزش چندگامی و بده‌بستان ستبری

آموزش مبتنی بر PGD مسئله درونی را با چند حرکت در جهت افزایش هزینه حل می‌کند [۳]. مزیت آن این است که پس از هر حرکت، شیب دوباره محاسبه می‌شود؛ بنابراین، الگوریتم می‌تواند با تغییر جهت محلی تابع هزینه سازگار شود. این انعطاف در برابر هندسه غیرخطی، یکی از دلایلی است که ارزیابی چندگامی می‌تواند شکست پنهان‌شده در حمله تک‌گامی را آشکار کند. هزینه آن نیز از همین محاسبات تکراری ناشی

می‌شود.

روش TRADES رابطه میان خطای طبیعی و خطای مرزی را با یک هدف آموزشی متشکل از هزینه پاک و واگرایی خروجی پاک و آشفته بررسی می‌کند [۹]. یک صورت متداول هدف آن چنین است:

$$\mathbb{E}_{(x,y)}\left[\mathcal{L}(f_\theta(x),y)+\lambda\max_{\delta\in\Delta_\infty(x,\epsilon)}D_{\mathrm{KL}}\big(q_\theta(\cdot\mid x)\|q_\theta(\cdot\mid x+\delta)\big)\right]. \qquad (۱-۳)$$

ضریب λ در این نوشتار وزن جمله ستبری است؛ در برخی منابع از معکوس آن استفاده می‌شود. مقایسه تنظیم‌ها بدون توجه به این قرارداد می‌تواند گمراه‌کننده باشد. این روش در مقاله SORA در کنار PGD-2 و PGD-10 به‌عنوان مرجع چندگامی به کار رفته است.

پژوهش‌های مربوط به بده‌بستان درستی پاک و ستبری نشان می‌دهند افزایش یکی الزاماً بدون هزینه برای دیگری نیست [۱۰]. بنابراین، برتری یک دفاع باید با هر دو معیار سنجیده شود. از سوی دیگر، این بده‌بستان یک دلیل برای پذیرفتن هر مقدار افت پاک نیست؛ مقایسه روش‌ها می‌تواند نشان دهد یک سازوکار کاراتر، برای سطح مشابه ستبری درستی پاک بیشتری حفظ می‌کند.

۳-۳ استفاده مجدد از محاسبات

۳-۳-۱ آموزش هم‌آورد رایگان

روش Free AT از یک گذر پس‌انتشار برای به‌روزرسانی هم‌زمان آشفتگی و پارامترهای شبکه استفاده می‌کند [۱۱]. برای مؤثربودن این استفاده مشترک، دسته آموزشی چند بار بازپخش می‌شود. این راهبرد هزینه تولید حمله را با آموزش وزن‌ها درهم می‌آمیزد و نشان می‌دهد تفکیک کامل «محاسبه حمله» از «محاسبه آموزش» همواره ضروری نیست.

واژه رایگان در این زمینه نسبی است. بازپخش دسته همچنان محاسبه دارد و مقایسه تعداد دوره‌های اسمی بدون دانستن تعداد بازپخش‌ها کافی نیست. در مطالعه SORA، این روش با تنظیمی متمایز از بسیاری از روش‌های دیگر گزارش شده است. ازاین‌رو، هم تعداد گذر و هم زمان واقعی باید با درنظرگرفتن پروتکل کامل تفسیر شوند.

۳-۳-۲ یک گام همراه با آغاز تصادفی

وونگ و همکاران نشان دادند آغاز تصادفی می‌تواند آموزش تک‌گامی را به‌طور چشمگیری بهبود دهد [۴]. نمونه ابتدا در همسایگی تصویر جابه‌جا می‌شود و سپس یک گام علامت شیب اعمال می‌شود.

این تصادفی‌سازی، وابستگی مولد حمله به یک نقطه آغاز ثابت را کاهش می‌دهد. بااین‌حال، همان پژوهش مسئله بیش‌برازش فاجعه‌بار را نیز برجسته کرد.

نکته مرتبط با پایان‌نامه آن است که تصادفی‌کردن نقطه آغاز الزاماً تمام اندازه‌ها و جهت‌های مؤثر را با کیفیت یکسان پوشش نمی‌دهد. تصویرشدن به کره و یک گام نسبتاً بزرگ می‌تواند بخش زیادی از نمونه‌ها را به مرز ببرد. در نتیجه، توزیع نهایی آشفتگی حاصل ترکیب نویز، جهت شیب و برش است؛ تنها دانستن توزیع نویز برای توصیف آن کافی نیست.

۳-۴ روش‌های مبتنی بر تنوع آشفتگی

روش N-FGSM دامنه نویز آغازین را افزایش می‌دهد و از برش نهایی آشفتگی به کره آموزشی صرف‌نظر می‌کند [۱۲]. هدف آن افزایش تنوع و کاهش شکست آموزش تک‌گامی است. این روش از نظر تعداد گذرهای اصلی در گروه روش‌های واقعاً سریع قرار می‌گیرد و در بسیاری از معیارهای طبیعی عملکرد رقابتی دارد.

این نتیجه به معنای یکسان‌بودن دامنه آشفتگی آموزش و ارزیابی نیست. استفاده از ورودی‌های آموزشی بیرون از کره ارزیابی یک انتخاب طراحی است و باید هنگام توضیح روش تصریح شود. همچنین، افزایش نویز ممکن است در یک دادگان به پایداری کمک کند و در دادگان دیگر درستی پاک را کاهش دهد. این مسئله انگیزه‌ای برای انتخاب وابسته به وضعیت مدل، به‌جای اتکا به یک مقدار ثابت بزرگ، فراهم می‌کند.

از دیدگاه بیش‌برازش اپسیلون، تصادفی‌سازی می‌تواند احتمال تمرکز مدل بر چند فاصله محدود را کاهش دهد. بااین‌حال، این تفسیر یک توضیح سازوکاری است و نه اثبات اینکه هر نوع نویز مستقل از توزیع داده، بیش‌برازش را حذف می‌کند. نتایج گسترده مقاله نشان می‌دهد ارزیابی خارج از CIFAR-10 برای تشخیص این تفاوت‌ها ضروری است [۶].

۳-۵ منظم‌سازی هندسه محلی

۳-۵-۱ هم‌راستایی شیب

روش GradAlign از کاهش هم‌راستایی شیب در همسایگی ورودی به‌عنوان نشانه نامطلوب استفاده می‌کند و آن را در تابع هدف جریمه می‌کند [۵]. شکل مفهومی جمله منظم‌ساز عبارت است از

$$R_{\mathrm{GA}} = \mathbb{E}_{\eta}\left[1 - \cos\big(\nabla_x \ell(x), \nabla_x \ell(x+\eta)\big)\right]. \tag{۳-۲}$$

کمینه‌کردن این جمله، مدل را به حفظ جهت شیب در یک همسایگی تصادفی تشویق می‌کند. این انتخاب به‌طور مستقیم با ایده محلی‌بودن تقریب تک‌گامی ارتباط دارد.

تفاوت آن با PertAlign در نقش و نقاط مقایسه است. GradAlign یک قید آموزشی است و برای مشتق‌گیری جمله منظم‌ساز نسبت به وزن‌ها، محاسبات بیشتری لازم می‌شود. PertAlign شیب ابتدا و انتهای همان حمله جاری را مقایسه می‌کند و نخست به‌عنوان ابزار پایش تعریف می‌شود. دو شاخص ممکن است رفتار هشدار مشابهی داشته باشند، اما یکسان‌بودن مقدار یا هزینه آن‌ها از این شباهت نتیجه نمی‌شود.

۳-۵-۲ هموارسازی خروجی و خطی‌بودن محلی

روش NuAT از منظم‌سازی مبتنی بر نرم هسته‌ای برای بهبود رفتار محلی خروجی بهره می‌گیرد [۱۳]. هدف کلی این خانواده آن است که آموزش تنها به نقطه انتهایی حمله محدود نماند و نوعی سازگاری در اطراف داده ایجاد شود. بااین‌حال، جمله اضافی تابع هدف می‌تواند به گذر پیشرو، ذخیره‌سازی یا مشتق‌گیری بیشتری نیاز داشته باشد.

روش ELLE بر سنجش و منظم‌سازی خطای تقریب خطی تابع هزینه تمرکز می‌کند [۱۴]. این دیدگاه به مسئله‌ای نزدیک است که در FGSM رخ می‌دهد: اگر تقریب خطی محلی معتبر نباشد، اندازه و جهت حرکت حاصل از آن نیز ممکن است نامناسب شود. مزیت روش، ارتباط روشن با هندسه است؛ محدودیت عملی آن باید با هزینه واقعی و حساسیت تنظیم‌ها سنجیده شود، نه فقط با تعداد گام اسمی حمله.

۳-۵-۳ نمونه‌های هم‌آورد غیرعادی

در روش AAER، نمونه‌ای که پس از حمله هزینه کمتری از ورودی آغازین دارد، نمونه هم‌آورد غیرعادی در نظر گرفته می‌شود [۱۵]. وجود چنین نمونه‌ای نشان می‌دهد حمله با هدف افزایش هزینه، دست‌کم در

نقطه انتهایی به نتیجه مورد انتظار نرسیده است. فراوانی آن‌ها می‌تواند با بیش‌برازش فاجعه‌بار افزایش یابد.

این شاخص از نظر مفهومی مستقیم است، اما زمان ظهور آن اهمیت دارد. ممکن است جهت شیب پیش از آنکه هزینه انتهایی از هزینه اولیه کمتر شود، به‌شدت تغییر کند. در این حالت، یک سنجه شیب‌محور می‌تواند زودتر واکنش نشان دهد. مقاله SORA این تفاوت را در نمودارهای زمانی مقایسه می‌کند، ولی برای نتیجه‌گیری درباره نرخ عمومی هشدار، ارزیابی آماری جداگانه لازم است.

۳-۶ انتخاب تطبیقی اندازه گام

ثابت‌گرفتن اندازه گام فرض می‌کند هندسه مناسب حمله در طول آموزش تغییر اساسی نمی‌کند. روش‌های تطبیقی این فرض را تضعیف می‌کنند و از نشانه‌های مدل برای کنترل حرکت بهره می‌برند. ATAS اندازه گام را با اطلاعات بزرگی شیب تنظیم می‌کند [۱۶]. این راهبرد می‌تواند از حرکت نامناسب در نمونه‌هایی با ویژگی‌های متفاوت بکاهد، اما بزرگی شیب و خمیدگی جهتی دو کمیت متفاوت‌اند.

روش‌های دیگری از یادگیری تقویتی برای تعیین آشفتگی یا از شباهت نویز و شیب برای تنظیم گام استفاده کرده‌اند [۱۷، ۱۸]. مزیت عمومی آن‌ها، واکنش به وضعیت جاری است. در مقابل، هر سازوکار تطبیقی ممکن است خودش به انتخاب آستانه، دامنه عمل یا پارامترهای کنترلی نیاز داشته باشد. بنابراین، «تطبیقی» بودن به‌تنهایی به معنای بی‌نیازی از تنظیم نیست.

تمایز SORA آن است که قانون کنترل گام از تقریب درجه دوم هزینه در جهت حرکت استخراج می‌شود. نسبت میان شیب آغاز و شیب پایان، تخمینی از خمیدگی جهتی فراهم می‌کند. سپس برای استفاده عملی، این تخمین هموار و با تأخیر به دسته بعد منتقل می‌شود. نسخه عملی، به دلیل ثابت‌کردن صورت کسر و تصادفی‌کردن گام مؤلفه‌ها، عین حل دقیق یک مسئله درجه دوم ثابت نیست؛ این تمایز در فصل روش حفظ می‌شود.

۳-۷ حذف مؤلفه‌های نامطمئن و استفاده از سابقه

روش‌های ZeroGrad و MultiGrad با حذف یا بررسی پایداری مؤلفه‌های شیب می‌کوشند از اثر جهت‌های نامطمئن بکاهند [۱۹]. در یک تابع تقریباً خطی، انتظار می‌رود علامت شیب در همسایگی پایدارتر باشد. مؤلفه‌های کوچک‌تر نیز ممکن است نسبت به تغییر محلی حساس‌تر باشند؛ بنابراین، کنارگذاشتن بخشی از آن‌ها می‌تواند نقش یک اصلاح کم‌هزینه را ایفا کند.

بااین‌حال، حذف مؤلفه با تنظیم بزرگی حرکت در تمام مؤلفه‌ها یکسان نیست. همچنین، بررسی چند آغاز یا چند شیب ممکن است هزینه را افزایش دهد. مقاله SORA این روش‌ها را هم از نظر ستبری و هم از نظر زمان و حافظه مقایسه می‌کند. نتیجه یک تنظیم خاص نباید به همه ترکیب‌های دادگان و معماری تعمیم داده شود.

۳-۸ اطلاعات مرتبه دوم در دفاع هم‌آورد

رابطه میان خمیدگی مرز تصمیم و آسیب‌پذیری، انگیزه روش‌های منظم‌سازی خمیدگی بوده است [۲۰]. این خانواده به‌جای کنترل تنها یک حمله، تلاش می‌کند هندسه مدل را تغییر دهد. رویکردهای دیگر نیز از تقریب‌های هسین یا اطلاعات مرتبه دوم برای تولید حمله یا دفاع استفاده می‌کنند. چالش اصلی برای آموزش سریع، به‌دست‌آوردن این اطلاعات با هزینه مناسب است.

دو نکته باید تفکیک شوند. نخست، کم‌بودن تغییر جهت شیب در یک مسیر، به معنای کوچک‌بودن تمام مقادیر ویژه هسین نیست. دوم، کوچک‌بودن یک مؤلفه خمیدگی، به‌تنهایی ستبری دسته‌بند را تضمین نمی‌کند؛ فاصله از مرز تصمیم و بزرگی شیب نیز مؤثرند. تحلیل PertAlign در همین دامنه محلی و جهت‌وابسته تفسیر می‌شود.

۳-۹ جایگاه پژوهش حاضر

پژوهش حاضر از سه ایده شناخته‌شده بهره می‌گیرد: اهمیت هندسه محلی، سودمندی تنوع آشفتگی و امکان استفاده مجدد از محاسبات آموزش. پیوند این ایده‌ها در SORA چنین است: دو شیب لازم برای تولید نمونه و آموزش وزن‌ها، برای پایش تغییر جهت و تخمین خمیدگی جهتی نیز استفاده می‌شوند؛ اندازه گام به وضعیت مدل واکنش نشان می‌دهد؛ و نمونه‌برداری مؤلفه‌ای از تمرکز بر یک اندازه ثابت می‌کاهد.

جدول ۳-۱ خلاصه‌ای مفهومی ارائه می‌کند. قضاوت نهایی درباره کارایی باید بر نتایج فصل آزمایش‌ها متکی باشد. به‌ویژه، ثابت‌بودن ابرپارامترهای اختصاصی SORA در مجموعه ارزیابی‌شده، ادعایی تجربی درباره همان تنظیم‌هاست و تضمین نمی‌کند هر دادگان تازه نیز بدون تنظیم به همان کیفیت برسد.

جدول ۳-۱: مقایسه سازوکارهای مرتبط؛ تلفیق مرور سمینار و مقاله، بدون ادعای برتری عددی.

روش	اطلاعات یا تغییر اصلی	نکته مرتبط با این پژوهش
FGSM-RS	آغاز تصادفی و یک گام	وابستگی کیفیت به توزیع نهایی
N-FGSM	نویز بزرگ‌تر، حذف برش به کره	دامنه آموزشی متفاوت از ارزیابی
GradAlign	منظم‌سازی هم‌راستایی شیب	کنترل هندسه با محاسبه اضافی
AAER	کنترل نمونه‌های غیرعادی	بررسی نقطه انتهایی حمله
ELLE	منظم‌سازی خطی‌بودن محلی	کنترل خطای تقریب مرتبه اول
ATAS	گام وابسته به بزرگی شیب	تطبیق با اطلاعات مرتبه اول
SORA	دو شیب موجود و گام تطبیقی	تخمین خمیدگی جهتی با تأخیر

فصل ۴

هندسهٔ هزینه و هم‌راستایی آشفتگی

۴-۱ از شکست حملهٔ تک‌گامی تا تفسیر هندسی

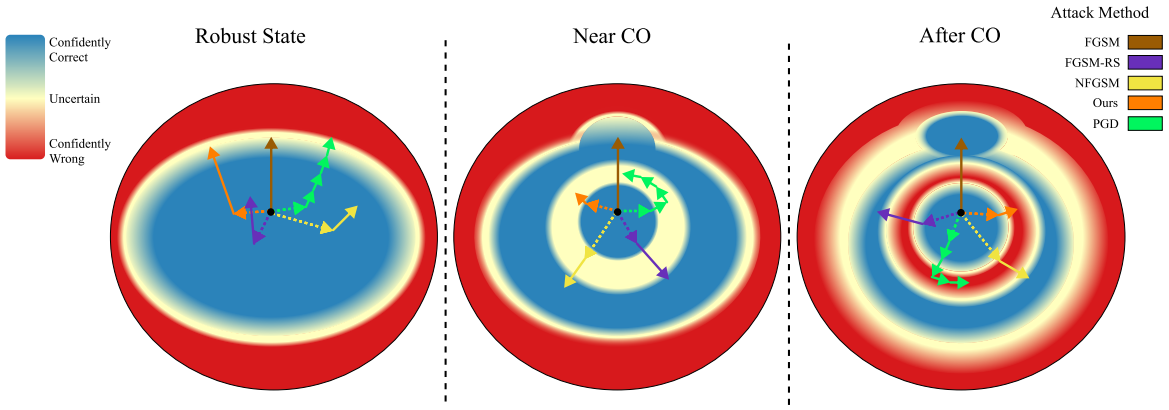
آموزش هم‌آورد، ستبری مدل دسته‌بندی را از راه یادگیری روی ورودی‌هایی دنبال می‌کند که هزینه را افزایش می‌دهند. ستبری، که در بخشی از ادبیات فارسی با تعبیر مقاوم بودن مدل نیز بیان می‌شود، به عملکرد در برابر مجموعه‌ای از تغییرات مجاز مربوط است؛ بنابراین موفقیت در برابر یک مولد مشخص نمونه، به‌تنهایی بیانگر ستبری نیست. در صورت‌بندی کمینه‌سازی و بیشینه‌سازی، کیفیت پاسخ تقریبی مسئلهٔ درونی مستقیماً بر معنای آموزشی مسئلهٔ بیرونی اثر می‌گذارد [۳]. اگر حمله نقاط پرهزینه را پیدا نکند، کاهش هزینهٔ آموزشی ممکن است همراه با باقی ماندن آسیب‌پذیری در همان همسایگی باشد. این تمایز در آموزش سریع اهمیت بیشتری دارد، زیرا یک گام مبتنی بر شیب تنها تصویری محلی از هندسهٔ هزینه در اختیار دارد.

برای ورودی $x \in \mathbb{R}^d$، برچسب y و پارامترهای θ، در این فصل از نگارش کوتاه

$$\ell_\theta(z) = \mathcal{L}(f_\theta(z), y), \qquad g(z) = \nabla_z \ell_\theta(z) \tag{۱-۴}$$

استفاده می‌شود. در هر تحلیل محلی، y و θ ثابت‌اند. روش علامت شیب سریع، یعنی FGSM، از تقریب خطی هزینه و جهت $\operatorname{sign}(g(x))$ استفاده می‌کند [۲]. این جهت برای بیشینه‌سازی جملهٔ خطی روی کرهٔ ℓ_∞ مناسب است، اما دربارهٔ تغییر شیب در طول مسیر اطلاعاتی ندارد. شروع تصادفی در آموزش سریع، تنوع نقاط آغاز را افزایش می‌دهد، ولی اعتبار تقریب خطی را برای هر اندازهٔ گام تضمین نمی‌کند [۴].

بیش‌برازش فاجعه‌آمیز، با نماد CO، زمانی مشاهده می‌شود که درستی در برابر حملات چندگامی به‌سرعت فرو می‌ریزد، در حالی که درستی در برابر حملهٔ تک‌گامی بالا می‌ماند یا افزایش می‌یابد. در



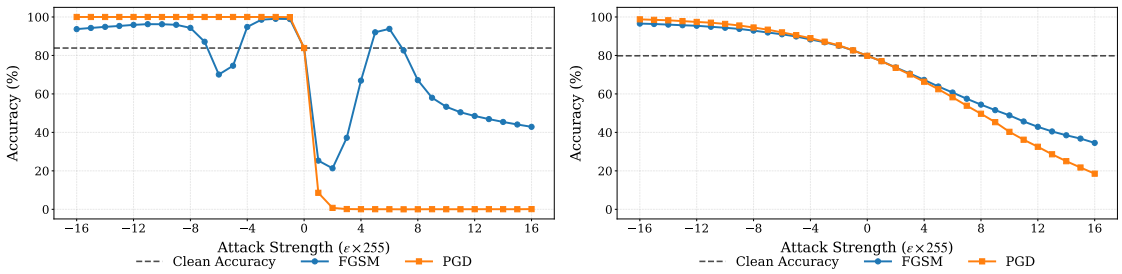
شکل ۴-۱: تحول هندسهٔ هزینه در آموزش با FGSM: از همسایگی تقریباً خطی در سمت چپ، به پیچش مرز تصمیم پیش از فروپاشی در میانه و ناحیهٔ قابل بهره‌برداری برای حملهٔ چندگامی در سمت راست. شکل، تفسیر هندسی گزارش‌شده در مقاله است و تضمینی دربارهٔ همهٔ ورودی‌ها ارائه نمی‌کند. بازنشر از شکل ۱ مقالهٔ SORA [۶].

این وضعیت، افزایش درستی تک‌گامی می‌تواند نشانهٔ ضعیف شدن مولد حمله باشد. مقالهٔ SORA این مسئله را با بررسی تغییر شکل سطح هزینه و مرز تصمیم تحلیل می‌کند [۶]. شکل ۴-۱ نشان می‌دهد که حتی پیش از خطای آشکار دسته‌بندی، مرز تصمیم می‌تواند پیرامون نقاطی که حملهٔ آموزشی به آن‌ها می‌رسد پیچ بخورد. حملهٔ چندگامی با تغییر متوالی جهت، ناحیهٔ آسیب‌پذیر بین این نقاط را پیدا می‌کند، در حالی که حملهٔ تک‌گامی از آن عبور می‌کند.

۴-۲ بیش‌برازش به اندازهٔ آشفتگی

تعریف ۴-۱ (بیش‌برازش اپسیلون) *بیش‌برازش اپسیلون، با نماد EO ، به الگوی یادگیری‌ای گفته می‌شود که در آن مدل در برابر آشفتگی‌های تولیدشده با اندازه‌های خاص، به‌ویژه اندازهٔ ثابت مورد استفاده در آموزش، عملکرد مناسبی دارد، اما در برابر اندازه‌های دیگر در همان جهت یا همسایگی، آسیب‌پذیر است. در تفسیر مقالهٔ $SORA$ ، تمرکز توزیع حمله روی دامنه‌ای محدود از اندازه و جهت، زمینهٔ این رفتار را فراهم می‌کند* [۶].

برای روشن شدن این مفهوم، جهت $p = \text{sign}(g(x))$ را ثابت و تابع تک‌متغیرهٔ $\phi(t) = \ell_\theta(x + tp)$ را در نظر می‌گیریم. اگر تقریب خطی در بازهٔ مورد نظر معتبر باشد، انتظار می‌رود افزایش کوچک t در جهت صعود، هزینه را افزایش دهد. اما ϕ ممکن است ابتدا افزایش یابد و سپس پیش از رسیدن به اندازهٔ آموزشی کاهش پیدا کند. در این حالت، مدل می‌تواند نقاط انتهایی مورد استفاده در آموزش را کم‌هزینه کند، در



(a) FGSM Adversarial Training

(b) SORA Adversarial Training

شکل ۴-۲: درستی در برابر تغییر اندازهٔ حمله برای مدل دچار بیش‌برازش فاجعه‌آمیز و مدل آموزش‌دیده با SORA. قله‌های درستی تک‌گامی در سمت چپ بیانگر محافظت یکنواخت در همسایگی نیستند. مقادیر منفی محور افقی ضریب حرکت در خلاف جهت حمله‌اند. بازنشر از شکل ۲ مقالهٔ SORA [۶].

حالی که نقاط میانی پرهزینه باقی می‌مانند. مشاهدهٔ هزینهٔ کم در انتهای گام، اطلاعات کافی دربارهٔ کل پاره‌خط یا کل کرهٔ آشفتگی نمی‌دهد.

شکل ۴-۲ این مسئله را با تغییر اندازهٔ حمله نشان می‌دهد. در مدل دچار فروپاشی، درستی FGSM نسبت به اندازهٔ گام رفتاری شدیداً نامونوا دارد. مقادیر منفی روی محور، حرکت در خلاف جهت ثابت انتخاب‌شده را نمایش می‌دهند؛ این مقادیر به معنای منفی بودن شعاع مجموعهٔ تهدید نیستند. برای بیشینه‌سازی دقیق روی مجموعه‌های تودرتو، بزرگ‌تر شدن شعاع نمی‌تواند بهترین هزینهٔ قابل دستیابی را کاهش دهد. نامونوا بودن منحنی حملهٔ تک‌گامی با این واقعیت تناقض ندارد، زیرا هر نقطهٔ منحنی حاصل یک حملهٔ تقریبی است، نه حل دقیق مسئلهٔ بیشینه‌سازی.

این تفسیر، بیش‌برازش اپسیلون را به تنوع مولد حمله مرتبط می‌کند. شروع تصادفی نقطهٔ ارزیابی شیب را جابه‌جا می‌کند و تصادفی کردن دامنه، نقاط متفاوتی در طول جهت‌های انتخاب‌شده می‌سازد. در مقابل، تکرار یک اندازهٔ ثابت ممکن است به مدل اجازه دهد تنها نواحی پرتکرار را ترمیم کند. با این حال، افزودن نویز به‌تنهایی تضمین نمی‌کند که نقاط پرهزینه نمونه‌برداری شوند. بزرگی نویز، برش نهایی و ساختار دادگان بر توزیع مؤثر نمونه‌های آموزشی اثر دارند. از این رو، توضیح هندسی باید همراه با مشخص کردن مولد واقعی آشفتگی به کار رود.

بیش‌برازش اپسیلون و بیش‌برازش فاجعه‌آمیز دو تعبیر هم‌ارز ریاضی نیستند. اولی به حساسیت نسبت به اندازه و مسیر حمله اشاره دارد و دومی با افت ناگهانی ستبری ارزیابی‌شده شناخته می‌شود. شواهد مقاله رابطهٔ نزدیکی میان آن‌ها نشان می‌دهد، ولی قضیه‌ای که وجود یکی را برای همهٔ شبکه‌ها شرط لازم و کافی دیگری بداند ارائه نمی‌کند. کاربرد این دیدگاه، توضیح یک سازوکار محتمل و طراحی نشانه‌های پایش است؛ تشخیص نهایی ستبری همچنان به حملات ارزیابی مناسب وابسته می‌ماند.

۴-۲-۱ نمونه‌های هم‌آورد غیرعادی

تعریف ۴-۲ (نمونهٔ هم‌آورد غیرعادی) *برای نقطهٔ مبنای z و گام حملهٔ δ، اگر*

$$\ell_\theta(z+\delta) < \ell_\theta(z), \tag{۴-۲}$$

برقرار باشد، خروجی حمله نسبت به این مبنا یک نمونهٔ هم‌آورد غیرعادی، با نماد AAE، نامیده می‌شود. در حالت شروع تصادفی، مبنای مقایسه می‌تواند $z = x + \eta$ باشد؛ مقایسه با ورودی پاک x باید جداگانه مشخص شود [۱۵، ۶].

واژهٔ غیرعادی به شکست هدف افزایش هزینه اشاره دارد. این تعریف مستلزم آن نیست که نمونهٔ نهایی حتماً درست دسته‌بندی شود یا نمونهٔ مبنا حتماً خطا داشته باشد؛ هزینهٔ پیوسته و برچسب پیش‌بینی‌شده دو کمیت متفاوت‌اند. همچنین حمله‌ای که هزینه را اندکی افزایش داده است می‌تواند هنوز بسیار ضعیف‌تر از حملهٔ چندگامی باشد. بنابراین سهم پایین نمونه‌های غیرعادی شرط کافی برای کیفیت مولد حمله نیست.

در هندسهٔ دارای قله و فرورفتگی، گام بلند می‌تواند از ناحیهٔ پرهزینه عبور کند و در نقطه‌ای کم‌هزینه پایان یابد. آموزش روی این نقاط ممکن است نواحی از پیش کم‌هزینه را بیشتر تقویت کند و ناحیهٔ آسیب‌پذیر میانی را دست‌نخورده بگذارد. این سازوکار، افزایش ظاهراً مطلوب درستی FGSM را توضیح می‌دهد. نرخ نمونه‌های غیرعادی نشانه‌ای قابل استفاده است، ولی ممکن است پس از شروع تغییر هندسه افزایش یابد. مقاله با همین انگیزه، مقایسهٔ شیب در دو سر گام را برای تشخیص زودتر تغییر مسیر هزینه پیشنهاد می‌کند [۶].

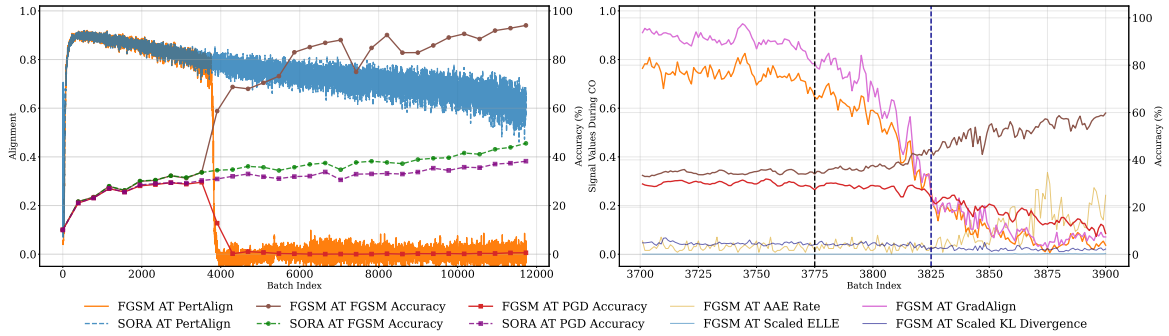
۴-۳ تعریف و محاسبهٔ هم‌راستایی آشفتگی

تعریف ۴-۳ (هم‌راستایی آشفتگی) *نقطهٔ آغاز حمله را $z = x + \eta$، جهت ثابت گام را v و اندازهٔ اسکالر آن را α می‌گیریم. برای دو شیب ناصفر $g = \nabla\ell_\theta(z)$ و $g' = \nabla\ell_\theta(z + \alpha v)$، معیار $PertAlign$ برابر است با*

$$P(z, v, \alpha) = \frac{g^\top g'}{\|g\|_2 \|g'\|_2}. \tag{۴-۳}$$

شروع تصادفی مقاله از توزیع $\eta \sim \mathcal{U}([-\epsilon, \epsilon]^d)$ انتخاب می‌شود و جهت متداول، $v = \operatorname{sign}(g)$ است [۶].

این معیار زاویهٔ میان شیب آغاز و پایان گام را اندازه می‌گیرد. مقدار نزدیک یک به معنای حفظ جهت شیب در دو نقطه است، مقدار نزدیک صفر بیانگر تقریباً عمود شدن آن‌ها و مقدار منفی بیانگر چرخش



شکل ۴-۳: پایش PertAlign در آزمایش گزارش‌شده روی CIFAR-10. در بزرگ‌نمایی سمت راست، افت معیارهای هم‌راستایی پیش از جدایی آشکار درستی تک‌گامی و چندگامی دیده می‌شود. تقدم زمانی در این نمودار یک مشاهدهٔ تجربی است و زمان هشدار ثابتی برای همهٔ تنظیمات تضمین نمی‌کند. بازنشر از شکل ۳ مقالهٔ SORA [۶].

بیش از زاویهٔ قائمه است. چون اندازهٔ شیب در مخرج حذف می‌شود، افزایش یا کاهش شدید اندازه می‌تواند پشت هم‌راستایی زیاد پنهان بماند. در عمل، حفاظت عددی از مخرج برای شیب‌های کوچک ضروری است؛ مقدار حاصل از چنین حفاظتی نباید مانند کسینوس دقیق تفسیر شود.

مزیت محاسباتی معیار از محل دسترسی به دو شیب می‌آید. شیب اول برای ساخت حمله لازم است. در گذر پس‌رو روی نمونهٔ هم‌آورد، علاوه بر مشتق پارامترها می‌توان مشتق هزینه نسبت به ورودی هم‌آورد را نیز دریافت کرد. این مشتق دوم با امتداد همان گذر تا ورودی به دست می‌آید و به حملهٔ تکراری جداگانه نیاز ندارد. این تعبیر، هزینهٔ ناچیز را نسبت به آموزش تک‌گامی توضیح می‌دهد؛ محاسبهٔ ضرب داخلی و نگهداری آرایهٔ شیب همچنان هزینهٔ محدود خود را دارند.

۴-۴ رابطهٔ محلی با هسین

لم ۴-۱ (بخش عمود کنش هسین) *فرض کنید هزینه در همسایگی z هموار، هسین آن محلی لیپشیتس و $g \neq 0$ باشد. جهت v هنگام تحلیل ثابت است. با تعریف $H = \nabla^2 \ell_\theta(z)$، $\widehat{g} = g/\|g\|_2$ و تصویر متعامد $Q_g = I - \widehat{g}\widehat{g}^\top$، برای α به‌اندازهٔ کافی کوچک داریم*

$$1 - P(z, v, \alpha) = \frac{\alpha^2}{2\|g\|_2^2} \|Q_g H v\|_2^2 + O(\alpha^3). \tag{۴-۴}$$

این بیان، صورت تصویری رابطهٔ نظری پیوست الف مقاله است [۶].

اثبات. بسط شیب در امتداد جهت ثابت می‌دهد

$$g' = g + \alpha H v + R, \qquad \|R\|_۲ = O(\alpha^۲). \tag{۵-۴}$$

اگر $k = g^{\mathsf{T}} H v / \|g\|_۲^۲$ و $\gamma = g^{\mathsf{T}} R / \|g\|_۲^۲$ باشد، صورت و مخرج کسینوس پس از تقسیم بر $\|g\|_۲^۲$ به شکل

$$P = \frac{۱ + \alpha k + \gamma}{\sqrt{۱ + ۲\alpha k + ۲\gamma + \alpha^۲ \|Hv\|_۲^۲ / \|g\|_۲^۲ + O(\alpha^۳)}} \tag{۶-۴}$$

درمی‌آیند. بسط ریشه و معکوس آن نشان می‌دهد که جمله‌های مرتبهٔ اول و سهم مشترک γ حذف می‌شوند و

$$P = ۱ - \frac{\alpha^۲}{۲}\left(\frac{\|Hv\|_۲^۲}{\|g\|_۲^۲} - k^۲\right) + O(\alpha^۳). \tag{۷-۴}$$

عبارت داخل پرانتز برابر $\|Q_g H v\|_۲^۲ / \|g\|_۲^۲$ است، زیرا Q_g مؤلفهٔ موازی g را حذف می‌کند. جایگذاری این همانی، نتیجه را می‌دهد. □

جهت حمله ممکن است از $g(z)$ ساخته شده باشد، ولی در این بسط مقدار محاسبه‌شدهٔ آن ثابت نگه داشته می‌شود. مشتق‌گیری از خود الگوریتم تولید جهت، مسئلهٔ دیگری است. افزودن شروع تصادفی نیز تنها نقطهٔ بسط را تغییر می‌دهد؛ فرض هموار باید پیرامون همان نقطه برقرار باشد. در شبکه‌های دارای فعال‌ساز تکه‌ای، عبور از مرز نواحی هموار می‌تواند اعتبار باقی‌ماندهٔ تیلور را محدود کند. بنابراین رابطهٔ بالا یک توصیف محلی از هزینه است و برای گام‌های بزرگ، بدون بررسی اضافی قابل تعمیم نیست.

۱-۴-۴ چه چیزی از هم‌راستایی زیاد نتیجه نمی‌شود؟

رابطهٔ (۴-۴) فقط به بخش عمود Hv حساس است. نزدیک بودن PertAlign به یک به معنای کوچک بودن نرم هسین، کم بودن همهٔ خمیدگی‌ها یا خطی بودن هزینه نیست. حتی استنتاج کوچک بودن بخش عمود نیز به اندازهٔ گام، اندازهٔ شیب و معتبر بودن تقریب وابسته است؛ گام بسیار کوچک می‌تواند در یک سطح پرخمیدگی هم کسینوسی نزدیک یک ایجاد کند. در مثال درجه‌دو با $H = MI$، جهت $v = g$ و $M > ۰$، رابطهٔ $g' = (۱ + \alpha M) g$ برقرار است. در نتیجه $P = ۱$، در حالی که $\|H\|_۲ = M$ می‌تواند به دلخواه بزرگ باشد.

برای $v = g$، شرط حذف جملهٔ اصلی ناهم‌راستایی به صورت $Hg = kg$ نوشته می‌شود: شیب در یک جهت ویژهٔ هسین قرار گرفته است. مقدار ویژهٔ k لزوماً کوچک نیست. همچنین کران بالایی بر ناهم‌راستایی

برحسب نرم هسین، استنتاج معکوس دربارهٔ کوچک بودن هسین را مجاز نمی‌کند. برای $v = \operatorname{sign}(g)$ نیز موضوع، کنش هسین روی جهت علامت است؛ نمی‌توان فرمول ویژهٔ جهت شیب را بی‌تغییر به آن نسبت داد.

تعبیر نیوتنی به احتیاط دیگری نیاز دارد. شرط $Hv = cg$ برای هسین وارون‌پذیر، $v = cH^{-1}g$ را نتیجه می‌دهد؛ اما برای هسین تکین، اگر $c \neq 0$ و معادله سازگار باشد، پاسخ کلی برابر است با

$$v = cH^{\dagger}g + w, \qquad w \in \ker H, \tag{۸-۴}$$

و سازگاری مستلزم $g \in \operatorname{range}(H)$ است. برای نمونه، با $H = \operatorname{diag}(1, 0)$، $g = (1, 0)^{\mathsf{T}}$ و $v = (1, 1)^{\mathsf{T}}$، رابطهٔ $Hv = g$ برقرار است، ولی v مضربی از $H^{\dagger}g = (1, 0)^{\mathsf{T}}$ نیست. در حالت $c = 0$ نیز هر جهت پوچ می‌تواند بخش عمود را صفر کند. از این رو، هم‌راستا بودن Hv و g به‌طور عمومی هم‌راستایی v و شبه‌وارون هسین ضرب در شیب را ثابت نمی‌کند. افزون بر این، جهت نیوتنی فقط با بررسی علامت خمیدگی و مسئلهٔ بیشینه‌سازی معنای بهینگی پیدا می‌کند.

۴-۵ مقایسه با هم‌راستایی شیب

معیار GradAlign کسینوس شیب در ورودی پاک و یک همسایهٔ تصادفی را بررسی می‌کند:

$$G(x, \eta) = \cos\big(\nabla \ell_\theta(x), \nabla \ell_\theta(x + \eta)\big), \qquad \eta \sim \mathcal{U}([-\epsilon, \epsilon]^d). \tag{۹-۴}$$

در روش اصلی، جملهٔ $1 - G$ با ضریبی مشخص به هدف آموزشی افزوده می‌شود تا جهت شیب در همسایگی پایدارتر شود [۵]. در مقابل، PertAlign دو سر گام حمله را مقایسه می‌کند و به‌عنوان معیار پایش به کار می‌رود. در SORA این معیار مستقیماً به هزینه افزوده نمی‌شود؛ سازگارسازی گام از آمارهٔ دیگری استفاده می‌کند که در فصل ۵ معرفی می‌شود.

از دید هندسی، لم ۴-۱ برای جابه‌جایی تصادفی کوچک نیز قابل استفاده است. پس شباهت روند دو معیار دور از انتظار نیست، ولی جهت مشاهدهٔ آن‌ها متفاوت است: یکی همسایه‌ای تصادفی را می‌بیند و دیگری مسیر منتخب حمله را. هیچ‌یک نرم کامل هسین را اندازه نمی‌گیرند. پایین‌تر بودن یکی در یک آزمایش، حکم عمومی دربارهٔ تمام جهت‌های تصادفی یا هم‌آورد ایجاد نمی‌کند؛ این موضوع به هندسهٔ مدل و توزیع نقاط وابسته است.

تمایز محاسباتی به کاربرد معیار مربوط است. منظم‌سازی با GradAlign مستلزم انتقال مشتق اثر معیار به پارامترهاست و می‌تواند مشتقات مرتبهٔ بالاتر و نگهداری گراف بیشتری بخواهد. محاسبهٔ صرف یک

کسینوس به چنین هزینه‌ای نیاز ندارد. PertAlign برای گزارش و کنترل بیرونی حمله از شیب‌های موجود استفاده می‌کند و از خود کسینوس نسبت به پارامترها مشتق نمی‌گیرد. روش‌های مبتنی بر خطی‌بودن محلی، مانند ELLE، نیز با نمونه‌برداری‌های دیگر نشانه‌های مکملی از شکل هزینه فراهم می‌کنند [۱۴]؛ یکسان دانستن همهٔ این نشانه‌ها تفاوت محل اندازه‌گیری و هزینهٔ استفادهٔ آموزشی را پنهان می‌کند.

شکل ۴-۳ شواهد مقاله برای امکان هشدار زودهنگام را نشان می‌دهد، اما آستانهٔ جهان‌شمول یا تضمین جلوگیری از فروپاشی از آن به دست نمی‌آید. میانگین یک دسته می‌تواند رفتار اقلیتی از ورودی‌ها را پنهان کند و تغییر اندازهٔ گام نیز خود مقدار معیار را تغییر می‌دهد. در نتیجه، تفسیر مناسب شامل بررسی روند هم‌راستایی در کنار درستی پاک، درستی چندگامی، اندازهٔ گام و سهم نمونه‌های غیرعادی است. این چارچوب زمینهٔ ساخت یک کنترل‌کنندهٔ کم‌هزینه برای حمله را فراهم می‌کند، بدون آنکه نقش ارزیابی مستقل ستبری را حذف کند.

فصل ۵

روش تطبیقی مرتبهٔ دوم برای آموزش سریع

۵-۱ هدف و دامنهٔ تحلیل

دیدگاه هندسی فصل ۴ نشان داد که اندازهٔ بزرگ‌تر گام لزوماً حملهٔ تک‌گامی قوی‌تری تولید نمی‌کند. اگر هزینه در امتداد جهت حمله ابتدا افزایش و سپس کاهش یابد، رسیدن به انتهای بازه می‌تواند یک نمونهٔ هم‌آورد غیرعادی بسازد. روش SORA از این مشاهده برای تنظیم دامنهٔ گام استفاده می‌کند: دو شیب موجود در آموزش، اطلاعاتی دربارهٔ تغییر محلی هزینه فراهم می‌کنند و یک کنترل‌کنندهٔ هموارشده، دامنهٔ نمونه‌برداری گام‌های بعدی را تغییر می‌دهد [۶]. در این فصل، ابتدا مسئلهٔ دقیق روی یک مدل درجه‌دو حل می‌شود و سپس فاصلهٔ این حل با قاعدهٔ عملی مقاله مشخص می‌گردد.

در سراسر استخراج محلی، برچسب و پارامترهای مدل ثابت‌اند و $\ell(z) = \mathcal{L}(f_\theta(z), y)$ نوشته می‌شود. نقطهٔ آغاز می‌تواند ورودی پاک یا نقطهٔ دارای شروع تصادفی باشد. در این نقطه، $g = \nabla \ell(z)$ و $H = \nabla^2 \ell(z)$ را تعریف می‌کنیم. هسین در استدلال حضور دارد، اما در الگوریتم عملی ساخته یا وارون نمی‌شود. این تمایز، معنای استفاده از اطلاعات مرتبهٔ دوم با هزینهٔ کم است: اثر تغییر شیب به‌طور غیرمستقیم در کنترل گام به کار می‌رود، نه اینکه یک روش کامل نیوتنی روی فضای ورودی اجرا شود.

آموزش هم‌آورد استاندارد، بیشینه‌سازی هزینه را در مجموعهٔ تهدید معین دنبال می‌کند [۳]. با این حال، مولد آموزشی SORA دقیقاً حل همین مسئلهٔ مقید با شعاع ϵ نیست؛ مطابق الگوریتم مقاله، تنها بازهٔ معتبر پیکسل‌ها برش می‌خورد. پیامد این انتخاب در بخش ۵-۵ بیان می‌شود. همچنین همهٔ شکل‌های این فصل بازنشر شواهد و تفسیر مقاله‌اند و نتیجهٔ آزمایش تازه‌ای در این متن محسوب نمی‌شوند.

۵-۲ بیشینه‌سازی اسکالر در جهت علامت شیب

جهت $p = \operatorname{sign}(g) \in \{-۱, ۰, ۱\}^d$ را پس از محاسبه ثابت می‌گیریم. برای گام اسکالر $a \geqslant ۰$، مدل درجه‌دوی هزینه برابر است با

$$q(a) = \ell(z) + a g^{\mathsf{T}} p + \frac{a^۲}{۲} p^{\mathsf{T}} H p = \ell(z) + ba + \frac{c}{۲} a^۲, \quad b = \|g\|_۱, \quad c = p^{\mathsf{T}} H p. \tag{۵-۱}$$

اگر $g \neq ۰$ باشد، $b > ۰$ است. این جمله همان انگیزهٔ مرتبهٔ اول برای انتخاب جهت علامت است [۲]. نقش جملهٔ دوم را علامت c تعیین می‌کند: خمیدگی جهت‌دار، نه مثبت یا منفی بودن همهٔ مقادیر ویژهٔ هسین. یک هسین نامعین نیز می‌تواند در این جهت خاص، خمیدگی منفی یا مثبت داشته باشد.

لم ۵-۱ (بهینهٔ محدود مدل درجه‌دو) *برای $b > ۰$ و $A > ۰$، بیشینه‌ساز $q(a)$ روی بازهٔ $[۰, A]$ برابر است با*

$$a_{\text{quad}} = \begin{cases} \min\{A, -b/c\}, & c < ۰, \\ A, & c \geqslant ۰. \end{cases} \tag{۵-۲}$$

این نتیجه، بخش دقیق استخراج اندازهٔ گام در تقریب درجه‌دوی مقاله را بیان می‌کند [۶].

اثبات. مشتق‌ها $q'(a) = b + ca$ و $q''(a) = c$ هستند. اگر $c < ۰$ باشد، تابع اکیداً مقعر است و نقطهٔ ایستای مثبت $-b/c$ بیشینهٔ نامقید آن است. محدود کردن این نقطه به بازهٔ مجاز نتیجهٔ سطر اول را می‌دهد. اگر $c = ۰$ باشد، تابع با شیب مثبت افزایش می‌یابد و انتهای بازه بهینه است. اگر $c > ۰$ باشد، برای تمام $a \geqslant ۰$ مشتق مثبت است؛ نقطهٔ ایستای منفی یک کمینهٔ خارج از بازه است و باز هم بیشینه در A رخ می‌دهد. □

در حالت مقعر، اگر رأس داخل بازه باشد، ادامهٔ حرکت پس از آن هزینه را کاهش می‌دهد. برای مدل (۵-۱)، افزایش هزینه نسبت به مبنا در بازهٔ $۰ < a < -۲b/c$ مثبت و پس از آن منفی است. بنابراین عبور از رأس فوراً به معنای غیرعادی شدن نمونه نیست، ولی گام به‌اندازهٔ کافی بلند می‌تواند حتی هزینه را از مقدار اولیه پایین‌تر ببرد. این محاسبه، رابطهٔ گام بیش از حد و نمونهٔ غیرعادی را در یک مدل ساده روشن می‌کند؛ برای سطح واقعی، جمله‌های مرتبهٔ بالاتر و برش ورودی نیز دخالت دارند.

فرض $b > ۰$ مهم است. اگر $g = ۰$ باشد، جهت علامت طبق قرارداد صفر می‌شود و مسیر انتخاب‌شده حرکت نمی‌کند. نسبت‌هایی که بر نرم شیب تقسیم می‌شوند نیز تعریف ندارند. در چنین وضعیتی، نظریهٔ حاضر توصیه‌ای برای یافتن جهت تازه از هسین ارائه نمی‌کند. نادیده گرفتن این حالت می‌تواند یک تقسیم عددی پایدارشده را به‌اشتباه به‌عنوان اندازه‌گیری معنادار خمیدگی معرفی کند.

۵-۲-۱ بازیابی خمیدگی از یک گام کاوش

اکنون فرض می‌کنیم هزینه واقعاً درجه‌دو و گام کاوش اسکالرِ معلوم $a_{\text{probe}} > ۰$ باشد. شیب انتهای همان مسیر برابر است با

$$g_{\text{probe}} = g + a_{\text{probe}} H p. \tag{۵-۳}$$

با ضرب در p^{T} و تعریف نسبت

$$r = \frac{p^{\mathsf{T}} g_{\text{probe}}}{\|g\|_{۱}} = ۱ + \frac{a_{\text{probe}} c}{b}, \tag{۵-۴}$$

علامت $r - ۱$ علامت خمیدگی جهت‌دار را مشخص می‌کند. در حالت $r < ۱$، رأس دقیق مدل برابر است با

$$a_{\text{vertex}} = -\frac{b}{c} = \frac{a_{\text{probe}}}{۱ - r}, \qquad a_{\text{quad}} = \min\left\{A, \frac{a_{\text{probe}}}{۱ - r}\right\}. \tag{۵-۵}$$

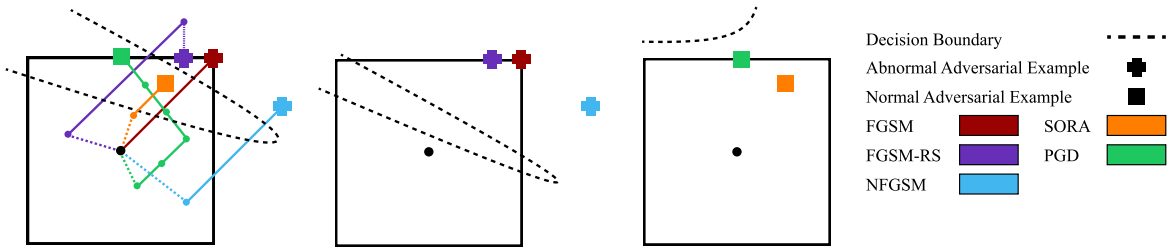
برای $r \geqslant ۱$، پاسخ محدود A است. صورت کسر در رابطهٔ دقیق، اندازهٔ همان گامی است که با آن شیب دوم اندازه‌گیری شده است. مقدار آن یک ثابت دلخواه نیست و حذف این وابستگی، همانی جبری استخراج را تغییر می‌دهد.

نسبت r با PertAlign یکسان نیست. PertAlign کسینوسی در بازهٔ $[-۱, ۱]$ است، ولی r علاوه بر جهت، اندازهٔ شیب دوم را نیز در خود دارد و ممکن است از این بازه خارج شود. حتی دو شیب کاملاً هم‌راستا می‌توانند نسبت بزرگی یا کوچکی بسازند. پس الگوریتم برای کنترل گام، فقط کسینوس فصل قبل را در فرمول قرار نمی‌دهد. تشخیص این تفاوت برای تفسیر نمودارهای پایش و اجرای درست قاعده ضروری است.

برای مقایسه، اگر جهت ثابت $v = g$ انتخاب شود، جملهٔ خطی $\|g\|_{۲}^{۲}$ و خمیدگی $g^{\mathsf{T}} H g$ خواهد بود. در آن حالت، نسبت متناظر را می‌توان به صورت

$$r_g = \frac{g^{\mathsf{T}} g_{\text{probe}}}{\|g\|_{۲}^{۲}} = \frac{\|g_{\text{probe}}\|_{۲}}{\|g\|_{۲}} \cos(g, g_{\text{probe}}) \tag{۵-۶}$$

نوشت. این رابطه نشان می‌دهد که حتی در جهت خود شیب نیز کسینوس به‌تنهایی برای تعیین اندازهٔ بهینه کافی نیست. صورت گام کاوش باید حفظ شود و کاربرد اندازهٔ گام استخراج‌شده به همان مقیاس‌بندی جهت وابسته است. جهت g و جهت علامت آن اندازه و هندسهٔ یکسانی ندارند.



(a) Before update (b) After update on AAEs (c) After update on NAEs

شکل ۵-۱: تفسیر هندسی اصلاح اندازهٔ گام: آموزش روی نمونه‌های غیرعادی ممکن است پیچش مرز تصمیم را تشدید کند، در حالی که دسترسی به نقاط پرهزینه می‌تواند مسیر بازیابی را فراهم سازد. این نمایش سازوکار پیشنهادی را توضیح می‌دهد و تضمین بازیابی پس از هر فروپاشی نیست. بازنشر از شکل ۴ مقالهٔ SORA [۶].

۵-۳ از همانی دقیق تا کنترل‌کنندهٔ عملی

مقاله برای پایداری و استفاده از اطلاعات دسته‌های گذشته، صورت کسر را با ثابت α_0 جایگزین می‌کند و قاعدهٔ عملی زیر را به کار می‌گیرد [۶]:

$$F(u) = \begin{cases} \min\left\{\alpha_{\max}, \dfrac{\alpha_0}{1-u}\right\}, & u < 1, \\ \alpha_{\max}, & u \geqslant 1. \end{cases} \tag{۵-۷}$$

در این رابطه، u آمارهٔ هموارشدهٔ نسبت است. α_0 یک پارامتر تنظیمی با مقیاس اندازهٔ گام و $\alpha_{\max}$ سقف دامنهٔ حمله است. در تنظیم عمومی گزارش‌شدهٔ مقاله، $\alpha_0 = 0.02$، $\beta = 0.05$ و $\alpha_{\max} = 2\epsilon$ انتخاب شده‌اند. این اعداد متعلق به روش منتشرشده‌اند و از حل ریاضی مسئلهٔ درجه‌دو به‌طور یکتا نتیجه نمی‌شوند.

برای u نزدیک یک، قاعده به سقف می‌رسد؛ با کاهش کافی u، دامنه کوچک می‌شود. این رفتار با پرهیز از عبور از قلهٔ محلی سازگار است. با وجود این، جایگزینی a_{probe} با α_0 به‌طور عمومی بهینگی دقیق رابطهٔ (۵-۵) را حفظ نمی‌کند. کوچک بودن ثابت نیز به‌تنهایی چنین تضمینی نمی‌دهد. تعبیر درست، یک کنترل‌کنندهٔ الهام‌گرفته از مدل درجه‌دو است که پایداری آن با میانگین‌گیری، سقف دامنه و تصادفی‌سازی تقویت می‌شود.

برای نمونهٔ صرفاً تحلیلی $q(a) = q(0) + 2a - a^2$، رأس در $a = 1$ قرار دارد. اگر گام کاوش $1/4$ باشد، نسبت $r = 3/4$ و فرمول دقیق $a_{\text{probe}}/(1-r) = 1$ است. استفاده از صورت ثابت 0.02 در همان نسبت، مقدار 0.08 را پیش از اعمال سقف می‌دهد. این مثال یک آزمایش روی دادگان نیست؛ تنها نشان می‌دهد که ثابت‌کردن صورت، نتیجهٔ جبری مسئلهٔ اصلی را به قاعده‌ای متفاوت تبدیل می‌کند.

۵-۳-۱ دامنه‌های تصادفی مؤلفه‌ای

در پیاده‌سازی مفهومی روش، سقف اسکالر A_i برای دستهٔ i تعیین می‌شود، ولی بردار دامنه برای هر نمونه و هر مؤلفه جداگانه نمونه‌برداری می‌شود:

$$a_{i,j} \sim \mathcal{U}(۰, A_i), \qquad \delta_i = a_i \odot p_i, \qquad p_i = \operatorname{sign}(g_i). \tag{۵-۸}$$

شاخص j مؤلفه‌های ورودی، شامل مکان و کانال تصویر، را می‌پیماید و $\odot$ ضرب مؤلفه‌ای است. این انتخاب با نمونه‌برداری یک عدد مشترک برای کل تصویر یا یک عدد مشترک برای هر کانال تفاوت دارد. حتی با علامت ثابت، اندازه‌های نامساوی مؤلفه‌ها جهت هندسی آشفتگی را تغییر می‌دهند. هدف، افزایش تنوع نقاط دیده‌شده و کاهش تمرکز روی یک پوستهٔ ثابت از اندازه‌هاست.

این تصادفی‌سازی نیز فاصله‌ای مشخص با قضیهٔ اسکالر دارد. در مدل درجه‌دو و بدون برش، اگر $D = \operatorname{diag}(a_i)$ باشد، شیب دوم برابر $g + HDp$ است. در نتیجه نسبت مشاهده‌شده شامل $p^{\mathsf{T}}HDp$ می‌شود، نه لزوماً $a_{\text{probe}}p^{\mathsf{T}}Hp$. تنها وقتی همهٔ دامنه‌ها برابر باشند، رابطهٔ دقیق کاوش اسکالر مستقیماً بازمی‌گردد. پس A_i سقف یک توزیع است و نباید آن را اندازهٔ واقعی یک گام بهینه برای هر ورودی نامید. با برش پیکسل‌ها، جابه‌جایی واقعی باز هم تغییر می‌کند.

۵-۴ میانگین نمایی و ترتیب زمانی الگوریتم

در شبه‌کد دسته‌ای این فصل، قرارداد تجمیع برای B نمونه، محاسبهٔ جداگانهٔ نسبت هر نمونه و سپس میانگین‌گیری است:

$$\bar{r}_i = \frac{۱}{B}\sum_{n=۱}^{B} \frac{p_{i,n}^{\mathsf{T}} g'_{i,n}}{\|g_{i,n}\|_۱}. \tag{۵-۹}$$

این نگارش، تعمیم صریح نسبت نمونه‌ای به دسته است؛ الگوریتم چاپ‌شده جزئیات این تجمیع را مشخص نمی‌کند. نسبت مجموع صورت‌ها به مجموع مخرج‌ها، به نمونه‌های دارای شیب بزرگ‌تر وزن بیشتری می‌دهد و لزوماً همان آماره نیست. هر قرارداد تجمیع باید هنگام بازتولید روش روشن باشد. برای مخرج صفر نیز باید سیاست عددی مشخصی داشت؛ رابطهٔ نظری تنها برای مخرج مثبت تعریف شده است.

میانگین نمایی با قرارداد مقاله به صورت

$$u_i = (۱ - \beta)u_{i-۱} + \beta\bar{r}_i, \qquad u_۰ = ۰/۹۹ \tag{۵-۱۰}$$

به‌روزرسانی می‌شود. بنابراین β وزن مشاهدهٔ جدید است. برای $\beta = ۰/۰۵$، کاهش وزن اطلاعات قدیمی در مقیاس چند ده دسته رخ می‌دهد؛ این هموارسازی نویز را کاهش می‌دهد، اما پاسخ به تغییر ناگهانی را

کند می‌کند. آمارهٔ مشترک، وضعیت کلی آموزش را خلاصه می‌کند و تضمین نمی‌کند که هر نمونه یا هر زیرگروه دادگان دامنهٔ مناسبی دریافت کند.

ترتیب خطوط ۱۱ و ۱۲ الگوریتم ۱ مقاله نکته‌ای تعیین‌کننده دارد. ابتدا سقف گام دستهٔ بعد با میانگین پیشین محاسبه می‌شود و سپس مشاهدهٔ دستهٔ جاری وارد میانگین می‌گردد. اگر A_i سقف استفاده‌شده در دستهٔ جاری باشد، ترتیب دقیق چنین است:

$$A_{i+1} = F(u_{i-1}), \qquad u_i = (1-\beta)u_{i-1} + \beta \bar{r}_i. \tag{۱۱-۵}$$

پس مشاهدهٔ دستهٔ i هنوز بر A_{i+1} اثر ندارد و نخست می‌تواند در A_{i+2} ظاهر شود. این یک تأخیر اضافی نسبت به قاعدهٔ «ابتدا میانگین جدید، سپس گام بعد» است. علاوه بر این تأخیر صریح، خود میانگین نمایی حافظهٔ زمانی دارد و شیب‌ها نیز با پارامترهای پیش از به‌روزرسانی جاری اندازه‌گیری شده‌اند.

شبه‌کد ۱ این ترتیب را حفظ می‌کند. برای کامل بودن آغاز اجرا، $A_1 = F(u_0)$ در نظر گرفته شده است؛ الگوریتم چاپ‌شده برای نخستین استفاده از سقف، مقداردهی جداگانهٔ روشنی نمایش نمی‌دهد. این قرارداد آغازین، تکمیل اجرایی شبه‌کد است و نباید با یک نتیجهٔ نظری مقاله اشتباه شود. در صورت استفاده از سقف آغازین دیگری، همان مقدار باید در گزارش پیاده‌سازی ثبت شود.

منطق استفاده از اطلاعات گذشته این است که تغییر پارامترها میان دو دسته معمولاً محدود و نمونه‌ها از توزیع آموزشی مشترک انتخاب می‌شوند. این منطق، انتقال اطلاعات خمیدگی میان دو ورودی متفاوت را به یک همانی دقیق تبدیل نمی‌کند. تغییر ناگهانی نرخ یادگیری، ناهمگنی دسته‌ها یا آغاز سریع فروپاشی می‌تواند اعتبار این انتقال را کاهش دهد. از سوی دیگر، حذف نیاز به کاوش تازه پیش از ساخت حمله، بخش اصلی صرفه‌جویی زمانی روش است. بنابراین تأخیر، یک مصالحهٔ اجرایی مشخص میان تازگی اطلاعات و هزینهٔ محاسباتی است.

۵-۵ مرز آموزش و مجموعهٔ تهدید ارزیابی

طبق الگوریتم ۱ مقاله، نمونهٔ آموزشی از رابطهٔ

$$\widetilde{x} = \Pi_{[0,1]^d}\left(x + \eta + a \odot p\right) \tag{۱۲-۵}$$

ساخته می‌شود. در اینجا تصویرکردن فقط روی بازهٔ معتبر پیکسل‌هاست؛ تصویرکردن اضافی روی $x + [-\epsilon, \epsilon]^d$ وجود ندارد. نقطهٔ محاسبهٔ شیب نخست، $x + \eta$، نیز در شبه‌کد چاپ‌شده پیش از آن برش نمی‌خورد. افزودن چنین برشی یا محدود کردن آشفتگی کل به کرهٔ ϵ، الگوریتم متفاوتی می‌سازد و باید به‌عنوان تغییر روش اعلام شود.

الگوریتم ۱ بازنویسی SORA با حفظ ترتیب زمانی الگوریتم مقاله [۶]

ورودی: مدل f_θ، دسته‌های آموزش، ϵ، α_0، $\alpha_{\max}$ و β.

۱. مقداردهی $u_0 \leftarrow 0.99$، $A_1 \leftarrow F(u_0)$ و $i \leftarrow 1$.

۲. برای هر دستهٔ (x_i, y_i)، مراحل ۳ تا ۱۳ را اجرا کنید.

۳. برای هر نمونه، $\eta_i \sim \mathcal{U}([-\epsilon, \epsilon]^d)$ و $z_i \leftarrow x_i + \eta_i$.

۴. محاسبه $g_i \leftarrow \nabla_{z_i} \mathcal{L}(f_\theta(z_i), y_i)$ و $p_i \leftarrow \text{sign}(g_i)$.

۵. جداسازی p_i از گراف ساخت حمله.

۶. نمونه‌برداری مستقل $a_{i,j} \sim \mathcal{U}(0, A_i)$ برای مؤلفه‌ها.

۷. ساخت $\widetilde{x}_i \leftarrow \Pi_{[0,1]^d}(x_i + \eta_i + a_i \odot p_i)$.

۸. دریافت $(g'_i, g_{\theta,i}) \leftarrow \nabla_{(\widetilde{x}_i, \theta)} \mathcal{L}(f_\theta(\widetilde{x}_i), y_i)$.

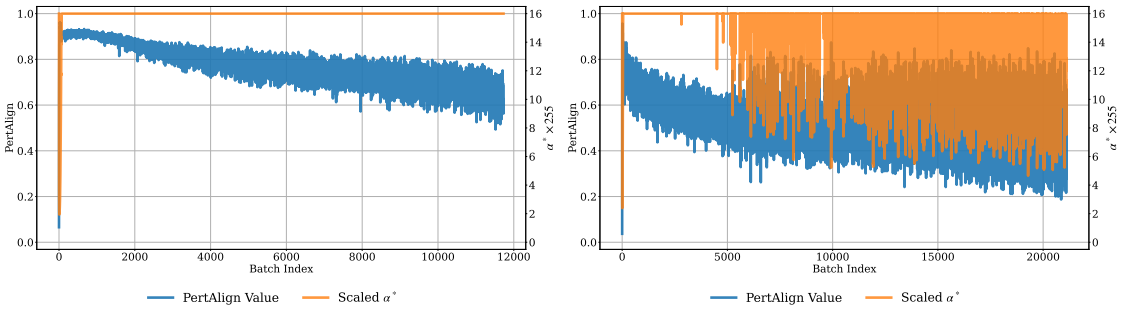
۹. به‌روزرسانی $\theta \leftarrow \text{Optimizer}(\theta, g_{\theta,i})$.

۱۰. محاسبهٔ $\bar{r}_i$ طبق رابطهٔ (۵-۹) از شیب‌های ذخیره‌شده.

۱۱. تعیین $A_{i+1} \leftarrow F(u_{i-1})$، پیش از ورود مشاهدهٔ جاری به میانگین.

۱۲. به‌روزرسانی $u_i \leftarrow (1 - \beta) u_{i-1} + \beta \bar{r}_i$.

۱۳. افزایش شمارنده: $i \leftarrow i + 1$.



(a) CIFAR-10 (b) PathMNIST

شکل ۵-۲: تغییرات PertAlign و سقف تطبیقی گام در آموزش گزارش‌شدهٔ مقاله برای CIFAR-10 و PATHMNIST. ماندن روی سقف در بخش بزرگی از نمودار نخست و تنظیم‌های مکرر در نمودار دوم، رفتار متفاوت کنترل‌کننده را نشان می‌دهد. منحنی گام عملی، بهینهٔ دقیق هر نمونه در مدل درجه‌دو نیست. بازنشر از شکل ۵ مقالهٔ SORA [۶].

چون $|\eta_j| \leqslant \epsilon$، $0 \leqslant a_j \leqslant \alpha_{\max}$ و $1 \geqslant |p_j|$، برای آشفتگی خام داریم

$$\|\eta + a \odot p\|_\infty \leqslant \epsilon + \alpha_{\max} = 3\epsilon \qquad (۱۳-۵)$$

که برابری آخر مربوط به انتخاب $\alpha_{\max} = 2\epsilon$ است. برش بازهٔ پیکسل برای $x \in [0,1]^d$ فاصلهٔ مؤلفه‌ای از x را افزایش نمی‌دهد، ولی آن را الزاماً تا ϵ کاهش نمی‌دهد. پس نمونه‌های آموزش ممکن است بیرون از کرهٔ ϵ باشند و عدد 3ϵ یک کران بالا بر دامنهٔ ممکن است، نه اندازهٔ ثابت همهٔ نمونه‌ها.

در ارزیابی ستبری، مجموعهٔ تهدید همچنان اشتراک کرهٔ ℓ_∞ با شعاع ϵ و دامنهٔ معتبر تصویر است. حملهٔ ارزیابی باید این قید را رعایت کند و درستی گزارش‌شده به همان شعاع نسبت داده شود. استفاده از دامنهٔ بزرگ‌تر در آموزش، مجوز تغییر شعاع آزمون یا ادعای حل دقیق مسئلهٔ درونی با شعاع آموزشی نیست. این تفکیک برای مقایسه با آموزش‌های مبتنی بر PGD و شروع تصادفی استاندارد ضروری است [۳، ۴، ۶].

۵-۶ پیچیدگی، اجرای مشتق و حدود اعتبار

برای هر دسته، یک گذر برای محاسبهٔ شیب ورودی در نقطهٔ شروع و یک گذر روی نمونهٔ هم‌آورد برای مشتق پارامترها لازم است. مشتق ورودی انتهایی نیز همراه گذر دوم دریافت می‌شود. هزینهٔ نمونه‌برداری، ضرب مؤلفه‌ای و تجمیع نسبت‌ها برای B نمونهٔ dبعدی از مرتبهٔ $O(Bd)$ است و حالت پایدار کنترل‌کننده تنها چند اسکالر دارد. نگهداری شیب‌ها و بردارهای حمله به حافظهٔ متناسب با ورودی نیاز دارد. در مقابل، ساخت صریح هسین حافظهٔ $O(d^2)$ و حل دستگاه مربوط به آن هزینهٔ اضافی چشمگیری می‌طلبد؛ هیچ‌یک جزء الگوریتم حاضر نیست.

ادعای اطلاعات مرتبهٔ دوم تقریباً رایگان، نسبت به گذرهای لازم در آموزش تک‌گامی بیان می‌شود. زمان و حافظه دقیقاً صفر نیستند و به چارچوب مشتق‌گیری و معماری بستگی دارند. مزیت اصلی، ثابت ماندن تعداد گذرهای شبکه و پرهیز از یک حلقهٔ چندگامی برای کاوش تازه است. در مقایسه با منظم‌سازی‌هایی که از خود معیار هم‌راستایی مشتق می‌گیرند، ذخیرهٔ گراف مشتقات مرتبهٔ بالاتر نیز لازم نیست [۵، ۶].

هنگام ساخت حمله، شیب و علامت آن باید از گراف به‌روزرسانی پارامترها جدا شوند. نمونهٔ نهایی سپس به‌عنوان ورودی مستقلی برای گذر دوم در نظر گرفته می‌شود تا هم مشتق آن ورودی و هم مشتق پارامترها قابل دریافت باشد. اگر هزینه در دسته میانگین گرفته می‌شود، مقیاس‌بندی دو شیب باید سازگار باشد؛ ضرب هر دو در یک ضریب مشترک، نسبت را تغییر نمی‌دهد، ولی ترکیب شیب مجموع و شیب میانگین نتیجه را عوض می‌کند. مشتق انتهایی باید نسبت به خود ورودی هم‌آورد باشد، نه صرفاً نسبت به

ورودی پیش از عمل برش که ممکن است مؤلفه‌های مشتق را صفر کند.

محدودیت‌های اصلی از تقریب محلی و تفاوت آن با مسیر اجرایی می‌آیند. سطح واقعی در یک گام بلند لزوماً درجه‌دو نیست؛ نمونه‌برداری مؤلفه‌ای مسیر اسکالر را تغییر می‌دهد؛ برش پیکسل‌ها هندسهٔ جابه‌جایی را عوض می‌کند؛ و میانگین گذشته متعلق به نمونه‌ها و پارامترهای دیگری است. نزدیک بودن PertAlign به یک نیز طبق بخش ۴-۴-۱ کوچک بودن هسین را ثابت نمی‌کند. در نتیجه، هیچ‌یک از این اجزا به‌تنهایی گواه ستبری یا تضمین بهینگی حمله نیست.

کارکرد روش را باید در کنار ارزیابی مستقل چندگامی، بررسی اندازهٔ واقعی آشفتگی و پایش روند آموزش سنجید. شکل‌های ۵-۱ و ۵-۲ سازوکار و رفتار گزارش‌شدهٔ مقاله را پشتیبانی می‌کنند، اما تعمیم آن‌ها به هر دادگان، معماری یا برنامهٔ آموزش نیازمند شواهد است. نتیجهٔ نظری دقیق این فصل، حل محدود مدل درجه‌دو و رابطهٔ کاوش آن است؛ نتیجهٔ روشی، تبدیل این اطلاعات به یک کنترل‌کنندهٔ تصادفی، هموارشده و دارای تأخیر برای آموزش سریع است.

فصل ۶

ارزیابی تجربی و تحلیل نتایج

۶-۱ دامنه و منشأ شواهد

هدف این فصل، بررسی این پرسش است که آیا استفاده از اطلاعات خمیدگی در آموزش سریع هم‌آورد می‌تواند، با حفظ هزینهٔ کم، از بیش‌برازش فاجعه‌بار جلوگیری کند و در دادگان و معماری‌های متفاوت کارایی قابل اتکایی داشته باشد. مبنای عددی فصل، نتایج منتشرشدهٔ مقالهٔ SORA است [۶]. در تدوین این پایان‌نامه آموزش تازه، جست‌وجوی ابرپارامتر تازه یا اندازه‌گیری سخت‌افزاری مستقلی انجام نشده است. بنابراین تعبیر «نتایج» در این فصل به گزارش و تحلیل آزمایش‌های مقاله اشاره دارد؛ جدول‌های بازآرایی‌شده نیز آزمایش تازه محسوب نمی‌شوند. این تفکیک برای جلوگیری از انتساب نادرست شواهد منتشرشده به اجرای مستقل پایان‌نامه ضروری است.

سه محور ارزیابی از یکدیگر جدا می‌شوند: نخست، درستی پاک و درستی زیر حمله‌های قوی؛ دوم، انتقال تنظیمات آموزش میان مسائل دسته‌بندی؛ و سوم، هزینهٔ محاسبات و رفتار شاخص هشدار PertAlign. درستی پاک به تنهایی نمی‌تواند موفقیت آموزش هم‌آورد را نشان دهد، زیرا ممکن است مدل روی نمونه‌های معمولی درست عمل کند ولی با آشفتگی کوچکی شکست بخورد. به همین ترتیب، درستی زیاد زیر همان حملهٔ تک‌گامی که در آموزش به کار رفته است، در حضور بیش‌برازش فاجعه‌بار شاهد کافی برای ستبری نیست. ازاین‌رو هر نتیجه باید همراه نام حمله، بودجه و معماری خوانده شود.

۲-۶ مدل تهدید و پروتکل ارزیابی

در آزمایش‌های اصلی، مهاجم در فضای ورودی و با دسترسی به مدل، هزینهٔ دسته‌بندی را افزایش می‌دهد. مجموعهٔ مجاز ارزیابی در نرم ℓ_∞ برابر است با

$$\Delta_\varepsilon(x) = \{\delta : \|\delta\|_\infty \leqslant \varepsilon, \quad x + \delta \in [۰, ۱]^d\}. \tag{۱-۶}$$

بودجه باید نسبت به مقیاس پیکسل پیش از نرمال‌سازی تفسیر شود؛ برای نمونه، ۸/۲۵۵ سهمی از دامنهٔ شدت در بازهٔ $[۰, ۱]$ است. این مدل تهدید، دستکاری محدود عددی را می‌سنجد و معادل همهٔ تغییرات طبیعی، تغییر دستگاه تصویربرداری یا حمله‌های معنایی نیست. صورت کمینه‌سازی و بیشینه‌سازی آموزش هم‌آورد و جایگاه حملهٔ چندگامی در این چارچوب در پژوهش مادری و همکاران مطرح شده است [۳].

درستی پاک سهم نمونه‌های درست دسته‌بندی‌شده بدون حمله است؛ درستی هم‌آورد سهم نمونه‌هایی است که پس از حمله نیز درست دسته‌بندی می‌شوند. FGSM حمله‌ای تک‌گامی است و PGD-10 ده بار جهت حرکت را با استفاده از شیب به‌روزرسانی می‌کند. AutoAttack، با اختصار AA، ارزیابی ترکیبی قوی‌تری فراهم می‌کند که وابستگی نتیجه به تنظیم یک حملهٔ منفرد را کاهش می‌دهد [۷]. ترکیب استاندارد آن شامل APGD-CE، APGD-DLR، FAB و Square Attack است و حمله‌های مبتنی بر شیب و جست‌وجوی بدون شیب را کنار هم قرار می‌دهد. این توضیح دربارهٔ چارچوب مرجع است؛ مقالهٔ SORA نسخه و تمام جزئیات پیکربندی ارزیابی را در متن چاپی مشخص نمی‌کند. هیچ‌یک از این سنجه‌های تجربی گواهی ریاضی ستبری نیستند. همچنین عدد PGD-10 را نمی‌توان به جای عدد AA گذاشت یا اختلاف آن‌ها را صرفاً نوسان تصادفی نامید.

مقاله در صفحهٔ ۸ بودجهٔ پیش‌فرض را ۸/۲۵۵ اعلام می‌کند، اما پیوست D در صفحهٔ ۳۱ برای تصاویر خاکستری TissueMNIST بودجه را به ۳/۲۵۵ کاهش می‌دهد تا تغییرات تصویری بیش از اندازه نشوند. شکل ۱۲ در صفحهٔ ۳۹ نیز سقف گام متناسب با این استثنا را نمایش می‌دهد. در این فصل استثنای پیوست صریحاً حفظ شده است. این اعداد به معنای نامحسوس‌بودن اثبات‌شدهٔ آشفتگی برای همهٔ بیماران یا همهٔ انواع تصویر نیستند؛ چنین ادعایی به ارزیابی تخصصی مستقل نیاز دارد.

جدول ۶-۱: ویژگی دادگان بر اساس جدول ۳ و پیوست D مقاله، صفحات ۳۰ تا ۳۳ [۶]. ستون بودجه از توضیح صفحهٔ ۳۱ افزوده شده است؛ جدول بازتدوین‌شده از مقاله است.

دادگان	ابعاد ورودی	دسته‌ها	آموزش	آزمون	ε
CIFAR-10	$3 \times 32 \times 32$	10	50,000	10,000	8/255
CIFAR-100	$3 \times 32 \times 32$	100	50,000	10,000	8/255
TinyImageNet	$3 \times 64 \times 64$	200	100,000	10,000	8/255
ImageNet-100	$3 \times 224 \times 224$	100	117,000	5,000	8/255
PathMNIST	$3 \times 28 \times 28$	9	89,996	7,180	8/255
TissueMNIST	$1 \times 28 \times 28$	8	165,466	47,280	3/255

۶-۳ دادگان، معماری‌ها و تنظیمات آموزش

۶-۳-۱ تنوع مسائل دسته‌بندی

جدول ۶-۱ ابعاد و اندازهٔ مجموعه‌های مورد استفاده را نشان می‌دهد. CIFAR-10 و CIFAR-100 به دلیل اندازهٔ کوچک تصاویر و رواج در مطالعات آموزش سریع، نقطهٔ شروع مناسبی هستند [۲۱]. افزایش شمار کلاس‌ها در CIFAR-100 و افزایش وضوح و تنوع در TinyImageNet امکان بررسی دشواری‌هایی را فراهم می‌کند که در مسئلهٔ ده‌کلاسه آشکار نمی‌شوند. ImageNet-100 نیز گسترش آزمایش به تصاویر ۲۲۴×۲۲۴ را می‌آزماید، ولی نمونه‌ای از کل ImageNet است و نباید به عنوان ارزیابی هزارکلاسه معرفی شود.

دو مجموعهٔ پزشکی از MedMNIST انتخاب شده‌اند [۲۲]. PathMNIST شامل تصاویر بافت‌شناسی رنگی مرتبط با دسته‌بندی بافت در سرطان روده و TissueMNIST شامل تصاویر خاکستری سلول‌های قشر کلیه است. مقاله برای اولی ۱۰٫۰۰۴ نمونهٔ اعتبارسنجی و برای دومی ۲۳٫۶۴۰ نمونهٔ اعتبارسنجی نیز ذکر می‌کند. اختلاف دامنهٔ این تصاویر با تصاویر طبیعی، آزمایش انتقال تنظیمات را معنادار می‌سازد. منظور از تعمیم در اینجا، عمدتاً توانایی یک روش آموزش با تنظیمات ثابت برای آموزش مدل‌های جداگانه روی مسائل مختلف است؛ مدل آموزش‌دیده روی CIFAR مستقیماً روی بافت پزشکی آزموده نشده است.

مطابق شکل ۸ مقاله، توزیع کلاس‌ها در دادگان طبیعی متوازن‌تر است، درحالی‌که دو دادگان پزشکی نامتوازن‌اند و این وضعیت در TissueMNIST شدیدتر است. بافت ریز و شباهت بیشتر میان کلاس‌ها نیز در تفسیر نویسندگان از دشواری آموزش نقش دارد. بااین‌حال آزمایش عاملی مستقلی که اثر عدم توازن را از

اثر بافت جدا کند گزارش نشده است. بنابراین نسبت‌دادن تمام افت ستبری به یکی از این عوامل، از شواهد موجود فراتر می‌رود. درستی کلی نیز جای سنجه‌های هر کلاس یا تحلیل خطاهای بالینی را نمی‌گیرد.

۶-۳-۲ تنظیمات مشترک و تفاوت‌های ضروری

چهار معماری اصلی عبارت‌اند از PreActResNet-18، ResNet-18، WideResNet-28-10 و SENet-18. این انتخاب به ترتیب امکان مقایسهٔ پیش‌فعال‌سازی، اتصال باقیمانده، افزایش عرض و توجه کانالی را فراهم می‌کند [۲۳، ۲۴، ۲۵، ۲۶]. اشتراک خانوادگی برخی از این شبکه‌ها سبب می‌شود تنوع معماری را کامل ندانیم. آزمایش‌های ViT-Small در صفحات ۵۷ و ۵۸ مقاله تکمیلی‌اند و به علت مقیاس محدود دادگان و نبود آزمایش پیش‌آموزش بزرگ، جای ارزیابی فراگیر مبدل‌های بینایی را نمی‌گیرند.

بهینه‌ساز اصلی SGD با تکانهٔ ۰/۹ و افت وزن ۵×۱۰^{-۴} است. برای دادگان طبیعی، برنامهٔ چرخه‌ای نرخ یادگیری از ۰/۰۱ تا ۰/۲ و سپس بازگشت به ۰/۰۱ گزارش شده است. برای دو دادگان پزشکی، کاهش کسینوسی از ۰/۰۵ تا حداقل $۱۰^{-۳}$ به کار می‌رود. در CIFAR حاشیه‌گذاری چهارپیکسلی، برش تصادفی و بازتاب افقی؛ در TinyImageNet حاشیه‌گذاری هشت‌پیکسلی؛ و در دادگان پزشکی چرخش تصادفی ده‌درجه‌ای و بازتاب افقی ذکر شده است. پس «تنظیم ثابت» به معنای یکسان‌بودن همهٔ جزئیات آماده‌سازی دادگان نیست.

ابرپارامترهای اصلی SORA برابر $\alpha = ۰/۰۲$، $\beta = ۰/۰۵$ و $\alpha_{\max} = ۲\varepsilon$ هستند. بر اساس صفحات ۷ و ۳۵، در بخش عمدهٔ آموزش CIFAR سقف گام انتخاب می‌شود، ولی در PathMNIST نیاز به کاهش گام بیشتر است. این رفتار با انگیزهٔ سازگارکردن حمله با هندسهٔ هزینه سازگار است؛ به خودی خود اثبات نمی‌کند که برآورد خمیدگی در هر دسته دقیق است. جزئیات وقفه در انتقال اطلاعات میان دسته‌ها، تفاوت PertAlign با ضریب کنترل گام و محدودیت مشخصات بازتولید در پیوست آ آمده‌اند.

۶-۳-۳ مقایسهٔ منصفانه و معنای تنظیم ثابت

خطوط مبنا از روش‌های سادهٔ FGSM و FGSM-RS تا روش‌های دارای منظم‌سازی، چندشروعی یا گام سازگار را دربرمی‌گیرند. PGD-2، PGD-10 و TRADES نیز مراجع چندگامی‌اند. هدف اصلی مقایسه، بررسی کارایی عملی آموزش سریع است که در آن هزینهٔ جست‌وجوی مکرر ابرپارامترها نیز اهمیت دارد [۴]. بااین‌حال باید میان هزینهٔ یک اجرای آموزش و هزینهٔ کل انتخاب تنظیمات تمایز گذاشت؛ مقاله برای هزینهٔ کل جست‌وجوی همهٔ روش‌ها زمان عددی جامعی ارائه نمی‌کند.

پیوست M.3، صفحهٔ ۶۰، توضیح می‌دهد که تنظیمات پیشنهادی مقالات مبنا استفاده و در مسائل

جدول ۶-۲: نتایج اصلی PreActResNet-18 با $\varepsilon = ۸/۲۵۵$؛ بازنویسی جدول ۱ مقاله، صفحهٔ ۹ [۶]. همهٔ مقادیر درصدند.

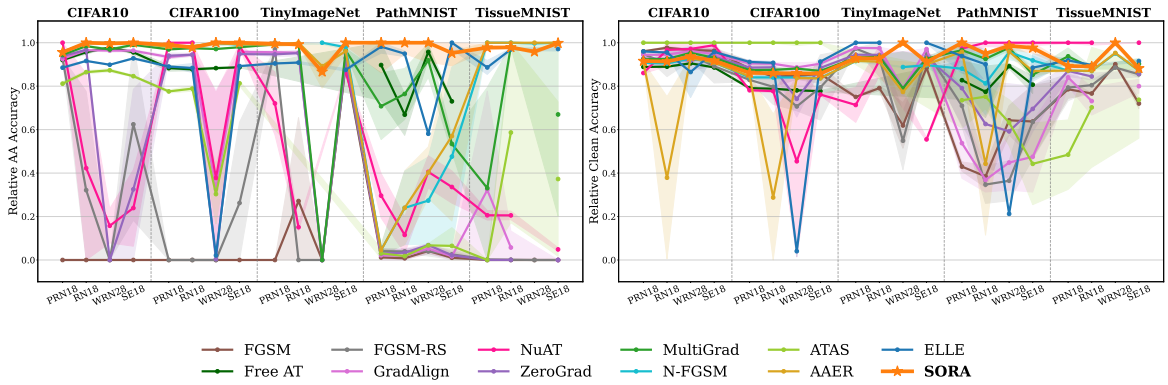
	PathMNIST		ImageNet-100	
روش	پاک	AA	پاک	AA
FGSM	46.06	0.42	15.94	0.00
N-FGSM	74.89	1.65	49.40	15.52
AAER	83.54	2.48	48.26	17.18
SORA	85.93	32.91	57.26	18.56

جدید اصلاحات مستدل اعمال شده‌اند. جست‌وجوی عمده به CIFAR-10/100 و دو معماری متداول محدود بوده و آزمایش‌های محدودی روی PathMNIST نیز برای SORA و خطوط مبنا انجام شده است. سپس پارامترهای روش برای ارزیابی‌های دیگر ثابت شده‌اند. بنابراین تعبیر دقیق، استفاده از یک مجموعهٔ نهایی مشترک پس از تنظیم محدود است؛ تعبیر «روش بدون هیچ تنظیمی ساخته شده است» درست نیست. از سوی دیگر، این پروتکل پاسخ مسئلهٔ انتقال تنظیمات را می‌دهد و الزاماً بهترین نتیجهٔ ممکن هر روش پس از جست‌وجوی نامحدود را نمی‌سنجد.

۶-۴ نتایج اصلی روی دو مسئلهٔ دشوار

جدول ۶-۲ اعداد جدول ۱ مقاله را با همان معیارها بازنویسی می‌کند. در PathMNIST، SORA به درستی پاک ۸۵/۹۳ و درستی AA برابر ۳۲/۹۱ درصد می‌رسد. اختلاف با N-FGSM در معیار AA برابر ۳۱/۲۶ واحد درصد و با AAER برابر ۳۰/۴۳ واحد درصد است. این اختلاف‌ها واحد درصد هستند؛ بیان آن‌ها به صورت درصد رشد نسبی معنای متفاوتی دارد. روی ImageNet-100 نیز مقدار AA از ۱۵/۵۲ برای N-FGSM و ۱۷/۱۸ برای AAER به ۱۸/۵۶ درصد برای SORA افزایش یافته است.

در این دو مسئله، بهبود ستبری در گزارش اصلی با افت درستی پاک همراه نشده است. این نکته نشان می‌دهد که در این مقایسه، ستبری مدل صرفاً با محدودکردن شدید ظرفیت یا قربانی‌کردن درستی پاک حاصل نشده است. بااین‌حال صفحهٔ ۵۹ تصریح می‌کند که آزمایش ImageNet-100 به دلیل هزینهٔ زیاد تنها یک اجرا داشته است. از این گزارش نمی‌توان پراکندگی میان بذرها، فاصلهٔ اطمینان یا معناداری آماری اختلاف ۱/۳۸ واحد درصدی با AAER را استنتاج کرد. برای سایر آزمایش‌ها سه بذر گزارش شده، اما این امر عدم قطعیت نتیجهٔ تک‌اجرایی را برطرف نمی‌کند.



شکل ۶-۱: تعمیم تنظیمات میان دادگان و معماری‌ها؛ بازنشر شکل ۶ مقاله، صفحهٔ ۸ [۶]. درستی AA و پاک نسبت به بهترین مقدار هر مسئله نرمال شده‌اند؛ جزئیات نرمال‌سازی در صفحهٔ ۴۷ مقاله آمده است.

گزارش اصلی را باید از نتایج تجمیعی پیوست جدا نگه داشت. برای نمونه، جدول ۳۲ صفحهٔ ۵۳ برای SORA روی همان نام دادگان و معماری، پاک ۸۴/۸۸ ± ۰/۹۹ و AA برابر ۳۵/۵۴ ± ۱/۵۵ می‌دهد. متن مقاله رابطهٔ دقیق این مقادیر با پاک ۸۵/۹۳ و AA برابر ۳۲/۹۱ در جدول ۱ را روشن نمی‌کند. این فصل هر دو گزارش را با منشأ مستقل حفظ می‌کند؛ نه میانگین‌گیری تازه انجام می‌دهد و نه یکی را اصلاح عدد دیگر معرفی می‌کند. تشخیص نقش بذر، ایست بازرسی یا تنظیم دقیق به فرادادهٔ اجرای اصلی نیاز دارد.

۶-۵ خوانش تفصیلی نتایج و حدود تعمیم

شکل ۶-۱ نمای کلی مقاله را نشان می‌دهد. در هر مسئله، درستی هر روش بر بیشترین درستی همان مسئله تقسیم شده است؛ بنابراین عدد نزدیک یک نشانهٔ نزدیکی به بهترین نتیجهٔ آن ستون است. این نمایش برای یافتن شکست‌های بزرگ مفید است، ولی مقادیر مطلق و اندازهٔ اختلاف‌های کوچک را پنهان می‌کند. همچنین بیشترین درستی پاک و بیشترین درستی هم‌آورد ممکن است متعلق به دو روش متفاوت باشند. ازاین‌رو نباید دو میلهٔ نسبی را به عنوان دو ویژگی یک مدل ایده‌آل مشترک تفسیر کرد.

جدول ۶-۳ نمونه‌هایی از نتایج مطلق را برای PreActResNet-18 کنار هم می‌آورد. روی CIFAR-10، درستی AA روش SORA برابر ۴۳/۸۳ درصد است؛ N-FGSM و AAER به ترتیب ۴۳/۹۵ و ۴۳/۹۶ درصد دارند و NuAT به ۴۵/۹۰ درصد می‌رسد، اما درستی پاک آن کمتر است. در CIFAR-100 نیز ۲۱/۵۶ درصد SORA بیشترین مقدار جدول نیست. این اعداد از یک مبادلهٔ عملی میان پاک، ستبر و هزینه پشتیبانی می‌کنند، ولی گزارهٔ برتری مطلق در همهٔ ستون‌ها را تأیید نمی‌کنند.

اهمیت تفکیک حمله‌ها در نمونهٔ FGSM-RS روی CIFAR-100 روشن است: جدول ۲۴ درستی

جدول ۶-۳: گزیدهٔ درستی‌های گزارش‌شده برای PreActResNet-18، از جدول‌های ۲۰، ۲۴ و ۲۸ مقاله در صفحات ۴۸، ۵۰ و ۵۲ [۶]. این چینش تازه از مقاله فقط مقادیر مرکزی را نشان می‌دهد؛ مؤلفه‌های ± منبع برای اختصار حذف شده‌اند.

دادگان	روش	پاک	PGD-10	AA
CIFAR-10	FGSM-RS	82.61	47.16	42.48
	NuAT	75.09	50.28	45.90
	N-FGSM	79.05	48.73	43.95
	AAER	79.38	48.59	43.96
	SORA	79.90	48.64	43.83
	PGD-10	79.37	50.60	46.15
CIFAR-100	FGSM-RS	52.70	0.00	0.00
	NuAT	49.66	27.81	22.13
	N-FGSM	53.43	26.25	21.75
	SORA	54.74	26.12	21.56
	PGD-10	53.57	27.64	22.88
TinyImageNet	FGSM-RS	47.46	19.67	14.95
	N-FGSM	44.66	20.18	15.77
	AAER	44.72	19.94	15.71
	SORA	45.30	20.07	15.38

جدول ۶-۴: نمونه‌های وابستگی نتیجه به معماری؛ چینش تازه از جدول‌های ۲۶، ۳۰، ۳۵، ۳۶ و ۳۸ مقاله، صفحات ۵۱، ۵۳، ۵۵ و ۵۶ [۶]. فقط مقادیر مرکزی درصدی آمده‌اند؛ بودجهٔ TissueMNIST مطابق صفحهٔ ۳۱ برابر ۳/۲۵۵ است.

دادگان	معماری	روش	پاک	PGD-10	AA
CIFAR-100	WRN-28	N-FGSM	57.28	27.82	23.74
	WRN-28	SORA	58.58	27.93	23.77
TinyImageNet	WRN-28	N-FGSM	48.47	21.21	16.58
	WRN-28	SORA	54.59	18.73	14.31
PathMNIST	SENet-18	ELLE	76.45	44.10	39.88
	SENet-18	SORA	85.32	41.21	34.76
TissueMNIST	PreAct-18	N-FGSM	57.47	49.25	48.15
	PreAct-18	SORA	58.86	48.55	47.06
TissueMNIST	WRN-28	AAER	57.83	50.00	48.95
	WRN-28	SORA	60.68	47.91	45.92

FGSM را ۵۵/۰۲ درصد گزارش می‌کند، درحالی‌که PGD-10 و AA هر دو صفرند. چنین فاصله‌ای نمونهٔ بارز شکست ارزیابی تک‌گامی است. در مقابل، برای SORA نیز PGD-10 بزرگ‌تر از AA است؛ این اختلاف یادآوری می‌کند که جلوگیری از فروپاشی کامل، هم‌معنای حل مسئلهٔ ستبری در برابر همهٔ حمله‌ها نیست. شدت ارزیابی باید همراه نتیجه باقی بماند.

جدول ۶-۴ مواردی را نشان می‌دهد که تغییر معماری رتبه‌بندی را عوض می‌کند. در TinyImageNet/WideResNet، درستی پاک SORA بیشتر ولی AA آن کمتر از N-FGSM است. در PathMNIST/SENet، ELLE درستی AA بیشتری دارد، اما درستی پاک آن کمتر است. در TissueMNIST نیز بعضی خطوط مبنا از نظر AA اندکی بهترند. حفظ این موارد در گزارش از انتخاب گزینشی نتایج جلوگیری می‌کند و مفهوم تعمیم را به پایداری قابل قبول در مجموعه‌ای از مسائل محدود می‌سازد، نه بردن تک‌تک مقایسه‌ها.

برای سنجش فاصله با آموزش چندگامی، جدول ۶-۵ مفید است. در گزارش تجمیعی PathMNIST، SORA با درستی پاک ۸۴/۸۸ از PGD-10 با ۷۷/۶۲ بالاتر است، ولی AA آن ۳۵/۵۴ در برابر ۵۰/۷۰ درصد است. بنابراین انتخاب روش به اولویت کاربرد بستگی دارد: اگر بیشترین ستبری تجربی هدف اصلی باشد و هزینه محدودیت نباشد، آموزش چندگامی همچنان گزینهٔ جدی است. متن محدودیت‌های مقاله نیز همین مرز را در صفحهٔ ۵۹ می‌پذیرد.

جدول ۶-۵: گزارش تفصیلی مستقل PathMNIST/PreActResNet-18 از جدول ۳۲ مقاله، صفحهٔ ۵۳ [۶]. علامت ± عیناً از منبع نقل شده و در این پایان‌نامه فاصلهٔ اطمینان تازه‌ای محاسبه نشده است.

روش	پاک	PGD-10	AA
N-FGSM	74.86 ± 6.14	18.84 ± 4.14	1.90 ± 0.77
ELLE	79.80 ± 6.67	40.52 ± 2.38	34.60 ± 1.05
SORA	84.88 ± 0.99	43.56 ± 1.66	35.54 ± 1.55
PGD-2	83.49 ± 0.34	47.50 ± 0.51	40.84 ± 0.23
PGD-10	77.62 ± 1.45	54.47 ± 0.89	50.70 ± 0.53
TRADES	75.25 ± 0.73	51.94 ± 0.88	48.28 ± 0.74

جدول ۶-۶: حذف مؤلفه‌ها در PathMNIST؛ جدول ۲ مقاله، صفحهٔ ۹ [۶]. این گزارش PGD-10 با پاک پایهٔ ۸۴٫۶۹ مستقل از جدول اصلی AA است.

تنظیم	پاک	FGSM	PGD-10
SORA (پایه)	84.69	57.51	45.56
بدون نمونه‌گیری تصادفی	85.67	58.89	45.35
برش اندازه گام	86.82	52.02	34.08
بدون گام تطبیقی	89.93	28.30	17.23

۶-۶ حذف مؤلفه‌ها و حساسیت ابرپارامترها

۶-۶-۱ سهم سازگاری و تنوع آشفتگی

جدول ۶-۶ دقیقاً به آزمایش حذف مؤلفه‌های جدول ۲ مقاله تعلق دارد. مقدار پایهٔ پاک ۸۴٫۶۹ است و ارزیابی ستبری با PGD-10 انجام شده است. این آزمایش را نباید ادامهٔ همان اجرای جدول ۶-۲ دانست که پاک ۸۵٫۹۳ و معیار AA دارد. نام مشترک روش و معماری برای یکسان‌انگاشتن تنظیمات یا ایست بازرسی کافی نیست. در اینجا تفسیر اختلاف‌ها تنها درون خود جدول حذف مؤلفه‌ها انجام می‌شود.

حذف انتخاب گام بهینه، درستی PGD-10 را از ۴۵٫۵۶ به ۱۷٫۲۳ درصد می‌رساند، درحالی‌که درستی پاک افزایش می‌یابد. این نتیجه با نقش گام سازگار در جلوگیری از تولید نمونه‌های آموزشی ضعیف سازگار است. محدودکردن گام در گونهٔ موسوم به Clamping Step-Size نیز مقدار را به ۳۴٫۰۸ کاهش می‌دهد. در مقابل، حذف نمونه‌گیری تصادفی تنها افت ۰٫۲۱ واحد درصدی دارد. چون جدول پراکندگی یا تکرارهای این مقایسه را مشخص نمی‌کند، این اختلاف کوچک به تنهایی شاهد معناداری آماری نقش نمونه‌گیری

جدول ۶-۷: برش‌های جست‌وجوی ابرپارامتر SORA؛ چینش تازه از جدول‌های ۵ تا ۱۰ مقاله، صفحات ۳۵ و ۳۶ [۶]. هر سطر یک تنظیم گزارش‌شده است و معیار ستبری PGD-10 است.

دادگان	β	α_0	$\alpha_{\max}/\varepsilon$	پاک	PGD-10
CIFAR-10	0.05	0.02	1.5	83.97	45.70
CIFAR-10	0.05	0.02	2.0	79.84	48.70
CIFAR-10	0.05	0.02	2.5	75.87	49.36
CIFAR-100	0.05	0.02	1.5	58.41	24.63
CIFAR-100	0.05	0.02	2.0	54.06	26.29
CIFAR-100	0.05	0.02	2.5	50.98	27.05
PathMNIST	0.05	0.01	2.0	85.06	44.01
PathMNIST	0.05	0.02	2.0	84.69	45.56
PathMNIST	0.05	0.05	2.0	90.42	19.90
PathMNIST	0.02	0.02	2.0	87.26	35.84
PathMNIST	0.10	0.02	2.0	84.94	44.47

نیست؛ اثر بزرگ‌تر سازگاری گام پشتوانهٔ عددی روشن‌تری دارد.

۶-۶-۲ حساسیت به سقف و ضریب گام

جدول ۶-۷ برش‌های مشخصی از جست‌وجوی ابرپارامترهای پیوست F را ارائه می‌کند. افزایش $\alpha_{\max}$ در CIFAR-10 با $\beta = ۰/۰۵$ و $\alpha_0 = ۰/۰۲$، درستی PGD-10 را از ۴۵/۷۰ به ۴۹/۳۶ درصد افزایش می‌دهد، اما پاک را از ۸۳/۹۷ به ۷۵/۸۷ کاهش می‌دهد. بنابراین انتخاب ε۲ صرفاً انتخاب بیشترین عدد ستبری نیست و مصالحهٔ میان دو معیار را منعکس می‌کند. روی PathMNIST، تغییر α_0 اثر شدیدتری دارد؛ این امر با فعال‌شدن بیشتر سازوکار سازگار در آن دادگان سازگار است.

نمونهٔ $\alpha_0 = ۰/۰۵$ روی PathMNIST مهم است: پاک ۹۰/۴۲ همراه با PGD-10 برابر ۱۹/۹۰ گزارش می‌شود. بنابراین ثابت‌ماندن مجموعهٔ نهایی پارامترها نباید با بی‌حساسیتی روش به همهٔ مقادیر اشتباه شود. شواهد نشان می‌دهند یک تنظیم مشترک مفید وجود دارد، اما پیرامون آن نواحی ضعیف نیز دیده می‌شوند. علاوه بر این، انتخاب نهایی بخشی از شواهد همان مطالعه است؛ ارزیابی روی مسائل واقعاً تازه برای آزمودن دامنهٔ انتقال ضروری خواهد بود.

جدول ۶-۸: حساسیت به بودجهٔ آموزش در CIFAR-10، از جدول ۱۱ مقاله، صفحهٔ ۳۶ [۶]. هر خانه به ترتیب پاک و PGD-10 است؛ فقط مقادیر مرکزی منبع نقل شده‌اند.

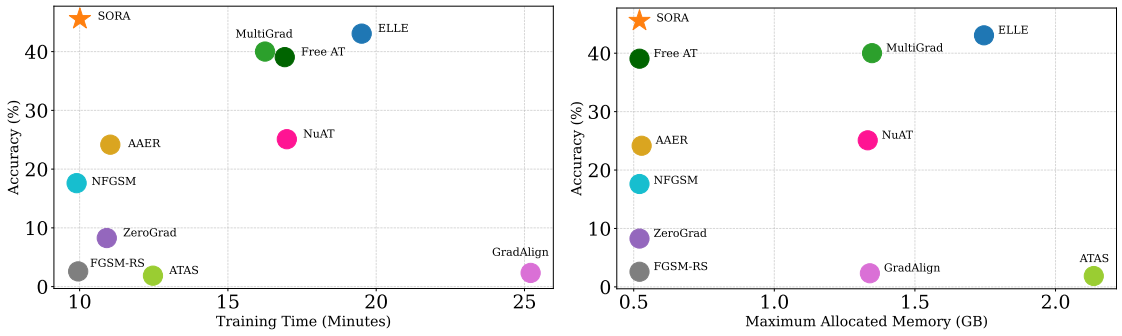
روش	4/255	8/255	12/255	16/255
ATAS	90.63 / 61.53	87.25 / 41.91	86.89 / 12.08	83.89 / 8.86
N-FGSM	87.40 / 66.44	79.05 / 48.73	69.36 / 37.54	61.20 / 29.23
SORA	87.85 / 66.86	79.90 / 48.64	72.18 / 37.32	67.66 / 27.12

۶-۷ بودجهٔ آشفتگی و اندازهٔ دسته

جدول ۶-۸ نتایج تغییر بودجهٔ آموزش در CIFAR-10 را نقل می‌کند. در بودجهٔ ۴/۲۵۵، SORA هم پاک و هم PGD-10 بیشتری از N-FGSM دارد؛ اما در ۱۶/۲۵۵، درستی PGD-10 آن ۲۷/۱۲ در برابر ۲۹/۲۳ درصد است. بنابراین نتیجهٔ دقیق این است که روش از فروپاشی کامل در بودجه‌های گزارش‌شده دور مانده، نه اینکه همیشه بیشترین ستبری را دارد. کاهش درستی پاک با افزایش بودجه نیز نشان می‌دهد مقایسهٔ روش‌ها در بودجه‌های متفاوت بدون ذکر محدودیت حمله گمراه‌کننده است.

تغییر بودجه در زمان آزمون پرسش دیگری است: در جدول ۱۲ صفحهٔ ۳۷، برای SORA مقادیر PGD در بودجه‌های ۳/۲۵۵، ۵/۲۵۵، ۹/۲۵۵، ۱۳/۲۵۵ و ۱۷/۲۵۵ به ترتیب ۶۸/۹۷، ۶۲/۷۲، ۴۳/۹۷، ۲۸/۴۵ و ۱۴/۱۷ درصدند. در بودجهٔ کوچک نخست، ATAS با ۷۴/۲۶ بالاتر است و در بودجهٔ آخر N-FGSM با ۱۴/۲۱ اندکی بالاتر قرار می‌گیرد. عنوان ستون منبع در این جدول PGD است؛ تعداد گام را از جدول‌های دیگر به آن تحمیل نمی‌کنیم. این داده‌ها نباید با آزمایش آموزش مدل‌های جداگانه در بودجه‌های متفاوت ادغام شوند.

پیوست F.1، صفحهٔ ۳۵، حساسیت اندازهٔ دسته را نیز گزارش می‌کند. برای SORA، افزایش اندازه از ۳۲ به ۱۲۸، پاک را از ۷۴/۷۴ به ۷۹/۹۰ و PGD-10 را از ۴۶/۳۸ به ۴۸/۶۴ درصد می‌رساند؛ در اندازهٔ ۵۱۲ این دو مقدار ۷۹/۸۶ و ۴۷/۰۰ هستند. پس بزرگ‌ترکردن دسته تضمین بهبود یکنواخت نیست. این آزمایش برای روشی که اطلاعات دستهٔ قبلی را به کار می‌برد اهمیت دارد، زیرا تغییر اندازهٔ دسته هم نوسان تخمین و هم شمار به‌روزرسانی‌ها را عوض می‌کند. داده‌های موجود اثر مستقل این دو عامل را جدا نمی‌کنند.



(a) Time (b) Memory

شکل ۶-۲: زمان آموزش و بیشینهٔ حافظهٔ تخصیص‌یافته در برابر درستی PGD-10؛ بازنشر شکل ۷ مقاله، صفحهٔ ۸ [۶]. تنظیم: PathMNIST، PreActResNet-18، ۳۰ دوره و RTX 4090. این اندازه‌گیری متعلق به مقاله است.

۶-۸ کارایی محاسباتی و حافظه

شکل ۶-۲ اندازه‌گیری مقاله روی PathMNIST/PreActResNet-18 را نشان می‌دهد. مبنای زمانی، آموزش ۳۰ دوره روی NVIDIA GeForce RTX 4090 است و محور عمودی درستی PGD-10 را نمایش می‌دهد. طبق صفحهٔ ۵۹، زمان حلقهٔ اصلی آموزش سنجیده شده و ذخیره و بارگذاری ایست‌های بازرسی کنار گذاشته شده‌اند. تکرار اندازه‌گیری زمان و کنترل تداخل فرایندها نیز توسط نویسندگان گزارش شده است. بااین‌حال مقدار دقیق زمان هر روش، تعداد تکرارها و پراکندگی عددی آن‌ها در جدول چاپی ارائه نشده‌اند؛ این فصل از خواندن تقریبی نقاط نمودار برای ساختن زمان دقیق خودداری می‌کند.

دادهٔ شمارش گذرها، برخلاف مختصات نمودار زمان، به صورت عددی در جدول ۱۹ صفحهٔ ۴۸ موجود است. SORA به دو گذر پیشرو و دو گذر پسرو در هر دسته نیاز دارد؛ PGD-10 یازده گذر از هر نوع و TRADES دوازده گذر پیشرو و یازده گذر پسرو دارد. این شمارش دلیل ساختاری کم‌هزینه‌بودن روش را توضیح می‌دهد، اما نسبت ۱۱/۲ را نمی‌توان نسبت شتاب واقعی نامید: اندازهٔ گراف، اندازهٔ دسته و استفاده از حافظه بر زمان مؤثرند. جدول دقیق شمارش و استثنای بازپخش Free AT در پیوست آمده است.

قید حافظه نیز بخشی از نتیجه است. صفحهٔ ۴۷ مقاله گزارش می‌کند که نیاز حافظهٔ ATAS مانع اجرای آن روی TinyImageNet با سخت‌افزار موجود شده است. نبود سطر یک روش در جدول به معنای صفر بودن درستی آن نیست. همچنین ناپایداری عددی ELLE در بعضی تنظیمات WideResNet، طبق صفحهٔ ۴۸، باید از بیش‌برازش فاجعه‌بار متمایز شود. هر دو ممکن است نتیجهٔ نامطلوب بسازند، اما سازوکار شکست و راه اصلاح یکسانی ندارند.

۶-۹ اعتبار شاخص هشدار و زمان پیش‌آگاهی

شواهد PertAlign در صفحات ۴۴ تا ۴۶ مقاله، روند چند سنجه را با مسیر آموزش مقایسه می‌کنند. در نمونهٔ مشخص FGSM، افت PertAlign و GradAlign حدود دستهٔ ۳۷۷۵ آغاز می‌شود، درحالی‌که جدایی آشکار درستی FGSM و PGD حدود دستهٔ ۳۸۲۵ دیده می‌شود. بنابراین این نمونه تقریباً ۵۰ دسته پیش‌آگاهی دارد. این اختلاف یک مشاهدهٔ نموداری در یک مسیر مشخص است؛ نه میانگین زمان هشدار برای همهٔ اجراها و نه تضمین یک مهلت ثابت پیش از هر فروپاشی است.

پیوست J.1 توضیح می‌دهد که ELLE نیز پس از انتقال و مقیاس‌بندی لگاریتم می‌تواند در همان حوالی واکنش نشان دهد، هرچند اوج آن دیرتر است و محاسبهٔ سنجه هزینهٔ بیشتری دارد. در نتیجه، مزیت اصلی PertAlign ترکیب واکنش زودهنگام با استفادهٔ مجدد از شیب‌های موجود است، نه ادعای اینکه هیچ سنجهٔ دیگری زود واکنش نمی‌دهد. نرخ نمونه‌های هم‌آورد نامتعارف و واگرایی خروجی‌ها در مثال مقاله دیرتر تغییر می‌کنند. این تفاوت ترتیب زمانی با فرض تغییر هندسهٔ هزینه پیش از افت آشکار درستی سازگار است.

شکل ۱۵ مقاله همراهی افت شاخص و افت ستبری را در چند ترکیب دادگان، معماری و روش نشان می‌دهد و حتی نمونهٔ افت، بازیابی و افت دوباره دارد. بااین‌حال مقاله نرخ هشدار کاذب، حساسیت آماری، آستانهٔ ازپیش‌تعیین‌شده یا توزیع زمان پیش‌آگاهی را به صورت عددی گزارش نمی‌کند. ازاین‌رو نمی‌توان PertAlign را احتمال کالیبره‌شدهٔ وقوع بیش‌برازش دانست. برای استفادهٔ عملی به عنوان سامانهٔ هشدار، تعریف رویداد، انتخاب آستانه روی اعتبارسنجی و آزمون مستقل آن لازم است؛ این‌ها در این پایان‌نامه اجرا نشده‌اند.

۶-۱۰ برداشت نهایی از شواهد

مجموع نتایج از سودمندی سازگاری گام برای جلوگیری از شکست‌های بزرگ آموزش سریع پشتیبانی می‌کند، به‌ویژه در PathMNIST که بسیاری از خطوط مبنا با تنظیمات متداول ستبری اندکی دارند. آزمایش حذف مؤلفه‌ها نیز نقش انتخاب گام را روشن‌تر از اثر کوچک حذف نمونه‌گیری نشان می‌دهد. بااین‌حال درستی AA در برخی مسائل برای خطوط مبنا بیشتر است و آموزش چندگامی روی مسئلهٔ دشوار پزشکی فاصلهٔ قابل توجهی دارد. نتیجهٔ مناسب، مصالحهٔ مطلوب و انتقال‌پذیری تنظیم نهایی در دامنهٔ آزموده‌شده است.

محدودیت‌های شواهد شامل تک‌اجرایی‌بودن ImageNet-100، پوشش ناقص برخی ترکیب‌ها بر اثر حافظه، مشخص‌نبودن همهٔ جزئیات ارزیابی در متن مقاله و تفاوت چند گزارش عددی میان متن و پیوست است. این موارد با افزودن رقم، فرض‌کردن تنظیمات رایج یا ساختن فاصلهٔ اطمینان حل نمی‌شوند. پیوست

فنی، نگاشت ادعاها به صفحات منبع و مشخصات لازم برای بازتولید آینده را ثبت می‌کند تا مرز میان دادهٔ منتشرشده، محاسبهٔ ساده از آن داده و پیشنهاد ارزیابی آینده روشن بماند.

فصل ۷

جمع‌بندی و مسیرهای آینده

۷-۱ پاسخ به پرسش پژوهش

این پایان‌نامه مسئله پیش‌بینی بیش‌برازش فاجعه‌بار در آموزش هم‌آورد سریع را از دیدگاه هندسه تابع هزینه بررسی کرد. نقطه آغاز آن، شکاف میان درستی زیاد در برابر حمله تک‌گامی و درستی اندک در برابر حمله چندگامی بود. این شکاف نشان می‌دهد یک مولد نمونه آموزشی ممکن است به‌تدریج از حل مسئله درونی بازبماند، درحالی‌که فرایند آموزش همچنان روی خروجی آن پیشرفت ظاهری نشان می‌دهد.

بیش‌برازش اپسیلون چارچوبی برای توضیح بخشی از این رفتار فراهم کرد: یادگیری روی اندازه‌ها و جهت‌های محدود آشفتگی می‌تواند نقاطی با هزینه کم در انتهای حرکت بسازد و نقاط آسیب‌پذیر میان آن‌ها را پوشش ندهد. شواهد تصویری مقاله از این تفسیر پشتیبانی می‌کنند، ولی این پدیده به‌عنوان علت کافی و یگانه همه موارد بیش‌برازش فاجعه‌بار اثبات نشده است.

برای پایش، شاخص PertAlign با مقایسه جهت شیب در آغاز و پایان حمله تعریف شد. تحلیل محلی نشان داد افت آن با بخشی از تغییر شیب که بر شیب اولیه عمود است ارتباط دارد. ازاین‌رو، این شاخص نشانه‌ای از نامعتبرشدن تقریب خطی در مسیر حمله فراهم می‌کند. اطلاعات لازم عمدتاً در همان دو مرحله تولید نمونه و به‌روزرسانی مدل حضور دارد؛ بنابراین، نیاز به ساخت هسین کامل یا اجرای منظم حمله چندگامی برای هر دسته کاهش می‌یابد.

۷-۲ از پایش تا اصلاح آموزش

در روش SORA، اختلاف دو شیب برای تقریب خمیدگی جهتی به کار رفت و یک قانون عملی برای کران بالای اندازه گام ساخته شد. میانگین‌گیری نمایی، تخمین را در برابر تغییر دسته‌ها هموار می‌کند و نمونه‌برداری مؤلفه‌ای اندازه گام، تنوع را حفظ می‌کند. این ترکیب، پیش‌بینی را به یک سازوکار اصلاحی پیوند می‌دهد: مدل تنها درباره افت هندسی هشدار نمی‌گیرد، بلکه توزیع ورودی آموزشی نیز تغییر می‌کند.

تمایز میان استدلال نظری و الگوریتم عملی در این نتیجه اهمیت دارد. حل دقیق یک مدل درجه دوم روی یک جهت ثابت، مبنای طراحی است. ثابت‌کردن صورت کسر، استفاده از تخمین دسته‌های گذشته، گام‌های مؤلفه‌ای و برش دامنه پیکسل، انتخاب‌های عملی‌اند. موفقیت تجربی این انتخاب‌ها، تضمین بهینگی سراسری مسئله آموزش یا حل دقیق بیشینه‌سازی درونی را نتیجه نمی‌دهد.

۷-۳ برداشت از نتایج

نتایج مقاله مشترک، روی مجموعه‌ای از دادگان طبیعی و زیست‌پزشکی و معماری‌های گوناگون، نشان می‌دهد SORA در بسیاری از تنظیم‌ها بده‌بستان مطلوبی میان درستی پاک، درستی هم‌آورد و هزینه ایجاد می‌کند [۶]. اهمیت دادگان زیست‌پزشکی آن است که برخی روش‌های موفق در معیارهای رایج، در این تنظیم‌ها با افت جدی روبه‌رو می‌شوند. بنابراین، محدودکردن ارزیابی به یک معیار تصویری می‌تواند تفاوت روش‌ها را پنهان کند.

بااین‌حال، جدول‌های تفصیلی مقاله نشان می‌دهند برتری عددی در همه معیارها و همه ترکیب‌ها برقرار نیست. در نتیجه، برداشت مناسب، پایداری و رقابت‌پذیری گسترده در تنظیم‌های بررسی‌شده است. همچنین، اعداد متن اصلی، حذف مؤلفه‌ها و پیوست باید در زمینه آزمایش خود خوانده شوند؛ اختلاف آن‌ها را نمی‌توان بدون گزارش خام و مشخصات نقطه کنترل به یک نتیجه واحد تبدیل کرد.

۷-۴ محدودیت‌های باقی‌مانده

نخست، هشدار زودهنگام هنوز نیازمند ارزیابی آماری مستقل است. افت پیش از فروپاشی در یک نمودار، وجود یک آستانه عمومی با نرخ هشدار کاذب کنترل‌شده را اثبات نمی‌کند. به‌ویژه، تغییرات طبیعی شیب در آغاز آموزش یا تغییر نرخ یادگیری می‌تواند بر شاخص اثر بگذارد. برای استفاده عملی، باید مشخص شود چه افتی معنادار است و چه مدت تداوم لازم دارد.

دوم، شاخص یک خلاصه جهت‌وابسته است. ممکن است شیب در راستای خود به‌شدت تغییر بزرگی دهد ولی هم‌راستا باقی بماند؛ یا خمیدگی در جهت‌های بررسی‌نشده زیاد باشد. ترکیب PertAlign با نسبت بزرگی شیب، هزینه و یک ارزیابی چندگامی کم‌تواتر می‌تواند تصویری کامل‌تر بدهد، اما هزینه و سود چنین ترکیبی باید اندازه‌گیری شود.

سوم، استفاده از آمار دسته‌های گذشته به شباهت توزیعی و تغییرات نسبتاً آرام مدل متکی است. در دسته‌های نامتوازن، یادگیری پیوسته یا تغییر ناگهانی توزیع، یک ضریب جهانی ممکن است رفتار همه نمونه‌ها را به‌خوبی بازنمایی نکند. همچنین، دامنه آشفتگی آموزش SORA با کره تهدید ارزیابی یکسان نیست؛ هر مقایسه آینده باید این نکته را آشکارا گزارش کند.

۵-۷ پیشنهادهای ادامه پژوهش

یک مسیر مشخص، تبدیل شاخص هندسی به پیش‌بین واسنجی‌شده است. باید رویداد بیش‌برازش با قاعده‌ای مستقل از خود شاخص تعریف شود، آستانه روی داده اعتبارسنجی تعیین شود و سپس نرخ هشدار درست، هشدار کاذب و زمان پیش‌آگاهی روی اجراهای کنارگذاشته‌شده گزارش شود. چند بذر تصادفی و چند معماری برای جداکردن یک الگوی پایدار از نوسان یک اجرا ضروری است.

مسیر دوم، مطالعه کنترل در سطح نمونه یا گروه است. به‌جای یک میانگین جهانی، می‌توان توزیع شاخص را در هر دسته یا در دسته‌های معنایی دنبال کرد. این کار ممکن است برای داده نامتوازن سودمند باشد، اما افزایش حافظه، نوسان و وابستگی به شناسه نمونه را به همراه دارد. مقایسه منصفانه باید نشان دهد آیا سود ستبری، هزینه این پیچیدگی را توجیه می‌کند.

مسیر سوم، مطالعه جداگانه نقش تنوع، دامنه آشفتگی و تطبیق هندسی است. مقایسه روش‌ها با دامنه آموزش یکسان و نیز با بودجه محاسباتی یکسان کمک می‌کند سهم هریک روشن شود. ارزیابی در برابر بودجه‌های دیده‌نشده، حملات متفاوت و جابه‌جایی توزیع نیز می‌تواند حدود تعمیم را دقیق‌تر مشخص کند.

در نهایت، پیوند با کران‌های نظری ستبری و با شبکه‌های غیرهموار همچنان باز است. تحلیل فعلی توضیحی محلی برای یک سنجه و یک قانون کنترل فراهم می‌کند. توسعه آن به تضمین‌هایی درباره درستی دسته‌بندی یا پایداری کل فرایند یادگیری، به فرض‌های تازه و تحلیل مستقل نیاز دارد. ارزش عملی مسیر حاضر، نشان‌دادن امکان استفاده از اطلاعات هندسی موجود در آموزش برای کاهش شکست یک تقریب سریع است.

Bibliography

[1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus. Intriguing properties of neural networks. In *International Conference on Learning Representations*, 2014.

[2] I. J. Goodfellow, J. Shlens, and C. Szegedy. Explaining and harnessing adversarial examples. In *International Conference on Learning Representations*, 2015.

[3] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, and A. Vladu. Towards deep learning models resistant to adversarial attacks. In *International Conference on Learning Representations*, 2018.

[4] E. Wong, L. Rice, and J. Z. Kolter. Fast is better than free: Revisiting adversarial training. In *International Conference on Learning Representations*, 2020.

[5] M. Andriushchenko and N. Flammarion. Understanding and improving fast adversarial training. In *Advances in Neural Information Processing Systems*, volume 33, pages 16048–16059, 2020.

[6] M. Teymourian, R. Moslemi, F. Rahmani, and M. H. Rohban. SORA: Free second-order attacks in fast adversarial training. In *Proceedings of the 43rd International Conference on Machine Learning*, volume 306 of *Proceedings of Machine Learning Research*, 2026.

[7] F. Croce and M. Hein. Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks. In *International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 2206–2216, 2020.

[8] L. Rice, E. Wong, and J. Z. Kolter. Overfitting in adversarially robust deep learning. In *International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 8093–8104, 2020.

[9] H. Zhang, Y. Yu, J. Jiao, E. Xing, L. El Ghaoui, and M. Jordan. Theoretically principled trade-off between robustness and accuracy. In *International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 7472–7482, 2019.

[10] D. Tsipras, S. Santurkar, L. Engstrom, A. Turner, and A. Madry. Robustness may be at odds with accuracy. In *International Conference on Learning Representations*, 2019.

[11] A. Shafahi, M. Najibi, M. A. Ghiasi, Z. Xu, J. Dickerson, C. Studer, L. S. Davis, G. Taylor, and T. Goldstein. Adversarial training for free! In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[12] P. de Jorge Aranda, A. Bibi, R. Volpi, A. Sanyal, P. Torr, G. Rogez, and P. Dokania. Make some noise: Reliable and efficient single-step adversarial training. In *Advances in Neural Information Processing Systems*, volume 35, pages 12881–12893, 2022.

[13] G. Sriramanan, S. Addepalli, A. Baburaj, and R. V. Babu. Towards efficient and effective adversarial training. In *Advances in Neural Information Processing Systems*, volume 34, pages 11821–11833, 2021.

[14] E. A. Rocamora, F. Liu, G. Chrysos, P. M. Olmos, and V. Cevher. Efficient local linearity regularization to overcome catastrophic overfitting. In *International Conference on Learning Representations*, 2024.

[15] R. Lin, C. Yu, and T. Liu. Eliminating catastrophic overfitting via abnormal adversarial examples regularization. In *Advances in Neural Information Processing Systems*, volume 36, pages 67866–67885, 2023.

[16] Z. Huang, Y. Fan, C. Liu, W. Zhang, Y. Zhang, M. Salzmann, S. Süsstrunk, and J. Wang. Fast adversarial training with adaptive step size. *IEEE Transactions on Image Processing*, 32:6102–6114, 2023.

[17] Z. Nie, Y. Lin, S. Ren, and L. Zhang. Adaptive perturbation adversarial training: Based on reinforcement learning, 2021.

[18] J.-C. Zhao, J. Ding, Y.-Z. Sun, P. Tan, J.-E. Ma, and Y.-T. Fang. Avoiding catastrophic overfitting in fast adversarial training with adaptive similarity step size. *PLOS ONE*, 20(1):e0317023, 2025.

[19] Z. Golgooni, M. Saberi, M. Eskandar, and M. H. Rohban. ZeroGrad: Costless conscious remedies for catastrophic overfitting in the FGSM adversarial training. *Intelligent Systems with Applications*, 19:200258, 2023.

[20] S.-M. Moosavi-Dezfooli, A. Fawzi, J. Uesato, and P. Frossard. Robustness via curvature regularization, and vice versa. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.

[21] A. Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

[22] J. Yang, R. Shi, D. Wei, Z. Liu, L. Zhao, B. Ke, H. Pfister, and B. Ni. MedMNIST v2: A large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, 10(1):41, 2023.

[23] K. He, X. Zhang, S. Ren, and J. Sun. Identity mappings in deep residual networks. In *European Conference on Computer Vision*, pages 630–645, 2016.

[24] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016.

[25] S. Zagoruyko and N. Komodakis. Wide residual networks. In *British Machine Vision Conference*, 2016.

[26] J. Hu, L. Shen, and G. Sun. Squeeze-and-excitation networks. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2018.

واژه‌نامه

معادل‌های پایه این واژه‌نامه با مراجعه به واژه‌نامه پردازش سیگنال IPL انتخاب شده‌اند. برای اصطلاحات ترکیبی ویژه این پژوهش، معادل توصیفی یکسان به کار رفته است. عنوان پایان‌نامه، واژه «تخاصمی» را مطابق پیشنهاد اولیه حفظ می‌کند؛ در متن، برابر «هم‌آورد» به کار می‌رود.

آ و ا

آشفتگی ..... Perturbation

آموزش هم‌آورد ..... Adversarial training

آموزش هم‌آورد سریع ..... Fast adversarial training

آغاز تصادفی ..... Random start

آستانه ..... Threshold

اعتبارسنجی ..... Validation

امید ریاضی ..... Expectation

ابرپارامتر ..... Hyperparameter

آنتروپی متقاطع ..... Cross-entropy

آزمایش حذف مؤلفه‌ها ..... Ablation study

ب

پس‌انتشار ..... Backpropagation

بهینه‌سازی ..... Optimization

بیش‌برازش ..... Overfitting

بیش‌برازش اپسیلون ..... Epsilon overfitting

بیش‌برازش فاجعه‌بار ..... Catastrophic overfitting

بیش‌برازش ستبر ..... Robust overfitting

بودجه آشفتگی ..... Perturbation budget

برش ..... Clipping

بده‌بستان ..... Trade-off

بیشینه هموار ..... Softmax

پ و ت

پیش‌بینی ..... Prediction

پیچیدگی محاسباتی ..... Computational complexity

تصویرکردن ..... Projection

تعمیم ..... Generalization

بازتولیدپذیری ..... Reproducibility

توزیع آموزش ..... Training distribution

توزیع یکنواخت ..... Uniform distribution

بسط تیلور ..... Taylor expansion

تجزیه ویژه ..... Eigendecomposition

ج و ح و خ

جعبه سفید ..... White-box

جعبه سیاه ..... Black-box

حمله ..... Attack

حمله چندگامی ..... Multi-step attack

حمله تک‌گامی ..... Single-step attack

خمیدگی ..... Curvature

خمیدگی جهتی ..... Directional curvature

محلی خطی ..... Locally linear

د و ر

دادگان ..... Dataset

دسته‌بندی ..... Classification

دسته‌بند ..... Classifier

دسته کوچک ..... Minibatch

درستی ..... Accuracy

درستی پاک ..... Clean accuracy

درستی هم‌آورد ..... Robust accuracy

دوره ..... Epoch

بذر تصادفی ..... Random seed

س و ش

ستبری ..... Robustness

سربار ..... Overhead

شیب ..... Gradient

نرم شیب ..... Gradient norm

شبه‌کد ..... Pseudocode

شباهت کسینوسی ..... Cosine similarity

شبکه باقی‌مانده ..... Residual network

ک و گ

واسنجی ..... Calibration

هزینه ..... Loss

چشم‌انداز هزینه ..... Loss landscape

اندازه گام ..... Step size

صعود شیب ..... Gradient ascent

نزول شیب تصویرشده ..... Projected gradient descent

م و ن

مدل تهدید ..... Threat model

منظم‌سازی ..... Regularization

میانگین متحرک نمایی ..... Exponential moving average

نقطه کنترل ..... Checkpoint

نمونه هم‌آورد ..... Adversarial example

نمونه هم‌آورد غیرعادی ..... Abnormal adversarial example

نمونه‌برداری مؤلفه‌ای ..... Elementwise sampling

تکانه ..... Momentum

نامتوازن‌بودن دسته‌ها ..... Class imbalance

مرز تصمیم ..... Decision boundary

هـ و و

هسین ..... Hessian

هم‌راستایی ..... Alignment

هم‌راستایی شیب ..... Gradient alignment

هم‌راستایی آشفتگی ..... Perturbation alignment

هشدار زودهنگام ..... Early warning

واگرایی کولبک–لایبلر ..... Kullback–Leibler divergence

کاهش وزن ..... Weight decay

ترادیسنده بینایی ..... Vision transformer

پیوست آ

مشخصات فنی، بازتولید و ردگیری منابع

آ‌ـ۱ کارکرد پیوست و قرارداد گزارش

این پیوست، مشخصات قابل استخراج از مقالهٔ SORA را برای خواندن و بازتولید آیندهٔ آزمایش‌ها یکجا گرد می‌آورد [۶]. جدول‌های نمادها، تنظیمات و نگاشت منبع در اینجا تازه تدوین شده‌اند، ولی دادهٔ تجربی تازه‌ای تولید نمی‌کنند. هرجا مقدار یا جزئیاتی در متن مقاله مشخص نیست، همان ناتمامی ثبت شده است. این شیوه از جایگزین‌کردن فرض‌های متداول پیاده‌سازی به جای مشخصات واقعی آزمایش جلوگیری می‌کند و امکان ممیزی اعداد فصل ۶ را فراهم می‌سازد.

واحد همهٔ درستی‌های عددی، مگر آنکه خلاف آن گفته شود، درصد نمونه‌هاست. تفاضل دو درستی بر حسب واحد درصد بیان می‌شود. نشانهٔ $\pm$ در جدول‌های برگرفته از پیوست مقاله عیناً نقل شده است؛ در این پایان‌نامه از روی آن فاصلهٔ اطمینان، آزمون معناداری یا خطای معیار تازه‌ای ساخته نشده است. صفحهٔ ۵۹ مقاله سه بذر تصادفی را برای بیشتر آزمایش‌ها و یک اجرا را برای ImageNet-100 ذکر می‌کند. مقدار بذرها و فرادادهٔ دقیق هر اجرای جدول‌ها از متن چاپی به تنهایی بازیابی نمی‌شود.

آ‌ـ۲ نمادها و کمیت‌های قابل مشاهده

جدول آ‌ـ۱ نمادهای لازم برای خواندن الگوریتم و تنظیمات را فهرست می‌کند. تمایز میان شاخص کسینوسی PertAlign و کمیتی که مستقیماً در کنترل گام استفاده می‌شود اهمیت دارد. اولی صرفاً جهت دو شیب را مقایسه می‌کند و دوم، برای جهت علامت شیب، نسبت $p^{\top} g' / \|g\|_{۱}$ است. این دو کمیت

جدول آ_۱: جدول نمادها، تدوین تازه بر اساس رابطهٔ ۲، الگوریتم ۱ و پیوست A مقاله، صفحات ۵، ۶ و ۱۷ تا ۲۲ [۶]؛ جدول اصلی مقاله نیست.

نماد	معنا
x, y	ورودی و برچسب دسته‌بندی، با d مؤلفهٔ ورودی و C کلاس
$f_\theta, \mathcal{L}$	خروجی پیش از تبدیل به احتمال و هزینهٔ آنتروپی متقاطع
ε	بودجهٔ آشفتگی در مدل تهدید ارزیابی
η	شروع تصادفی؛ در الگوریتم اصلی از $U(-\varepsilon, \varepsilon)^d$
g	شیب هزینه نسبت به ورودی در نقطهٔ شروع تصادفی
p	جهت $\operatorname{sign}(g)$
g'	شیب هزینه نسبت به ورودی در نمونهٔ هم‌آورد
H	هسین هزینه نسبت به ورودی؛ در اجرای روش صریحاً ساخته نمی‌شود
$\alpha_0, \alpha_{\max}$	صورت ثابت فرمول گام و سقف گام
α^*	سقف سازگار برای نمونه‌گیری مؤلفه‌های گام
β	وزن مشاهدهٔ جدید در میانگین نمایی ضریب کنترل
c	نماد این پیوست برای میانگین متحرک ضریب خطی‌بودن؛ در الگوریتم مقاله v نام دارد
$\Pi_{[0,1]}$	محدودکردن پیکسل به بازهٔ معتبر شدت
$\odot$	ضرب مؤلفه‌به‌مؤلفه

مرتبط‌اند، اما برابر نیستند. در نتیجه جایگزین‌کردن یکی با دیگری، بدون تغییر فرمول، بازتولید همان الگوریتم محسوب نمی‌شود.

برای نمونهٔ دارای شروع تصادفی $\widetilde{x} = x + \eta$، تعریف پایش به صورت

$$A = \frac{g^\top g'}{\|g\|_2 \|g'\|_2}, \qquad g = \nabla_{\widetilde{x}} \mathcal{L}(f_\theta(\widetilde{x}), y), \qquad g' = \nabla_{x^{\mathrm{adv}}} \mathcal{L}(f_\theta(x^{\mathrm{adv}}), y) \tag{آ_۱}$$

نوشته می‌شود. تقریب مرتبهٔ دوم مقاله نشان می‌دهد که برای گام کوچک در جهت دلخواه v، ناهم‌راستایی به مؤلفهٔ Hv عمود بر g وابسته است. این رابطهٔ محلی، توضیحی برای حساسیت شاخص به تغییر جهت شیب فراهم می‌کند، اما هسین کامل یا تمام انحناهای پیرامون نمونه را بازسازی نمی‌کند. به همین علت مقدار نزدیک یک به تنهایی گواهی ستبری در کل گوی تهدید نیست و نباید جای ارزیابی مستقل با حملهٔ قوی قرار گیرد.

آ‌ـ۳ مشخصات عملی گام سازگار

برای جهت علامت شیب، فرم عملی الگوریتم ۱ صفحهٔ ۶ را می‌توان با نماد c چنین ثبت کرد:

$$r_t = \frac{p_t^\top g'_t}{\|g_t\|_۱}, \qquad c_{\text{new}} = (۱-\beta)c_{\text{old}} + \beta r_t, \qquad (آ‌ـ۲)$$

$$\alpha^*(c) = \begin{cases} \min\{\alpha_{\max}, \alpha_۰/(۱-c)\}, & c < ۱, \\ \alpha_{\max}, & c \geqslant ۱, \end{cases} \qquad c_{\text{init}} = ۰/۹۹. \qquad (آ‌ـ۳)$$

سپس مؤلفه‌های گام از بازهٔ $[۰, \alpha^*]$ نمونه‌گیری و ورودی به صورت

$$x^{\text{adv}} = \Pi_{[۰,۱]}\big(x + \eta + a \odot \operatorname{sign}(g)\big), \qquad a_j \sim U(۰, \alpha^*) \qquad (آ‌ـ۴)$$

ساخته می‌شود. پارامترهای نهایی گزارش‌شده $\beta = ۰/۰۵$، $\alpha_۰ = ۰/۰۲$ و $\alpha_{\max} = ۲\varepsilon$ هستند. این فرمول، توصیف مقاله است و در این پایان‌نامه به کد اجرایی تبدیل نشده است.

اطلاعات g' هنگام پس‌انتشار هزینهٔ نمونهٔ هم‌آورد به دست می‌آید و برای تعیین گام دسته‌های بعدی استفاده می‌شود. بنابراین آموزش فعلی نمی‌تواند به شیبی وابسته باشد که هنوز در همان دسته محاسبه نشده است. در بازتولید، ترتیب دقیق به‌روزرسانی اهمیت دارد: در الگوریتم چاپی، محاسبهٔ گام بعدی پیش از سطر به‌روزرسانی میانگین آمده است. هم‌زمان متن روش از استفاده از اطلاعات دستهٔ قبلی سخن می‌گوید. بدون بررسی کد متناظر با نسخهٔ مقاله، نباید این ترتیب را به طور خاموش جابه‌جا و اجرای حاصل را عین الگوریتم منتشرشده معرفی کرد.

همچنین شروع تصادفی و سقف گام آموزش را نباید با قید سخت ارزیابی اشتباه گرفت. الگوریتم ۱ تصویر نهایی را به $[۰, ۱]$ می‌برد و تصویرکردن صریح به گوی ℓ_∞ با شعاع ε در آن دیده نمی‌شود. پیش از محدودکردن شدت، جمع شروع تصادفی با دامنهٔ ε و گام با سقف ۲ε می‌تواند در یک مؤلفه تا ۳ε برسد. این یک کران جبری از فرمول است و اندازه‌گیری آشفتگی‌های واقعی نیست. استدلال صفحهٔ ۳۵ که میانگین گام نمونه‌گیری‌شده تقریباً نصف سقف است، جای قید سخت روی آشفتگی کل را نمی‌گیرد.

ابهام دیگری در دانه‌بندی تصادفی‌سازی وجود دارد: الگوریتم نمونه‌گیری مؤلفه‌ای را نشان می‌دهد، درحالی‌که متن صفحات ۶ و ۳۵ از تنوع به ازای کانال نیز استفاده می‌کند. این تفاوت ممکن است بر هم‌بستگی آشفتگی‌های پیکسل‌ها اثر بگذارد. افزون بر آن، جزئیات عددی محافظت از تقسیم بر نرم صفر در شبه‌کد ذکر نشده است. این پیوست این موارد را به عنوان سؤال باز بازتولید ثبت می‌کند و سازوکار فرضی به منبع نسبت نمی‌دهد.

جدول آ‌ـ۲: مشخصات بازتولید موجود در مقاله؛ تدوین تازه از صفحات ۷، ۸، ۲۳ تا ۲۶، ۳۱ تا ۳۳ و ۵۹ [۶]. این جدول توضیحی، جدول اصلی مقاله نیست.

مؤلفه	مشخصات گزارش‌شده
بهینه‌ساز	SGD، تکانهٔ ۰٫۹، افت وزن ۵×۱۰^{-۴}
نرخ دادگان طبیعی	چرخهٔ خطی ۰٫۰۱ → ۰٫۲ → ۰٫۰۱
نرخ دادگان پزشکی	کاهش کسینوسی از ۰٫۰۵، حداقل $۱۰^{-۳}$
افزایش دادهٔ CIFAR	حاشیهٔ ۴، برش تصادفی، بازتاب افقی
افزایش دادهٔ TinyImageNet	حاشیهٔ ۸، برش تصادفی، بازتاب افقی
افزایش دادهٔ پزشکی	چرخش تصادفی ۱۰ درجه، بازتاب افقی
اندازهٔ دستهٔ ImageNet-100	۳۲، مطابق صفحهٔ ۳۲
تکرار آماری	سه بذر در گزارش عمومی؛ یک اجرا برای ImageNet-100
زمان‌سنجی شکل‌های ۷ و ۱۶	۳۰ دوره، RTX 4090، حلقهٔ اصلی بدون ذخیره و بارگذاری
استثنای Free AT	$m = ۸$ بازپخش، ۱۰ دوره، بیشینهٔ نرخ ۰٫۰۴
گام آموزش چندگامی	PGD-2: ۴/۲۵۵؛ PGD-10: ۲/۲۵۵

آ‌ـ۴ تنظیمات آموزش و استثناهای خطوط مبنا

جدول آ‌ـ۲ حداقل مشخصات موجود در متن را گرد می‌آورد. نرمال‌سازی با میانگین و انحراف معیار دادگان آموزش ذکر شده است، ولی مقادیر عددی این بردارها در صفحات مربوط درج نشده‌اند. در پیاده‌سازی باید روشن باشد که حمله در فضای پیکسل اعمال می‌شود یا در فضای نرمال‌شده و قیدها چگونه تبدیل می‌شوند. افزودن آشفتگی ۸/۲۵۵ به مختصات نرمال‌شده، بدون تبدیل متناسب، الزاماً همان مدل تهدید منتشرشده نیست.

خطوط مبنا کاملاً بدون استثنا تنظیم نشده‌اند. در پیوست B، ضریب NuAT به دلیل دشواری یادگیری در تعداد کلاس زیاد به یک کاهش یافته است؛ آستانهٔ ZeroGrad برای CIFAR-10 برابر ۰٫۳۵ و برای مسائل دیگر ۰٫۴۵ است. GradAlign با ضریب ۰٫۲، MultiGrad با سه کپی و گام ۲ε، و ELLE با ضریب ۱۰۰۰ گزارش شده‌اند. این‌ها بخشی از پروتکل مقایسه‌اند و باید همراه نتیجه نقل شوند. یکسان‌سازی مصنوعی همهٔ این تنظیمات برای ساده‌ترشدن روایت، وفاداری به آزمایش اصلی را از بین می‌برد.

برای N-FGSM، شروع تصادفی در $[-۲\varepsilon, ۲\varepsilon]$ و گام ε؛ برای AAER، گونهٔ N-AAER با ضرایب $(۱, ۱/۵, ۰/۱۵)$؛ و برای ATAS مقادیر $\beta = ۰/۵$، $c = ۰/۰۱$ و $\gamma = ۲c\varepsilon$ ذکر شده‌اند. نماد c در ATAS متعلق به همان روش است و با نماد کمکی ضریب متحرک در رابطهٔ آ‌ـ۳ یکی نیست. ضریب TRADES

جدول آ‌ـ۳: انتقال‌پذیری تنظیم خطوط مبنا؛ تدوین تازه از جدول‌های ۱۶ و ۱۷ مقاله، صفحهٔ ۴۲ [۶]. معیار ستبری PGD-10 است.

روش و تنظیم	دادگان	پاک	PGD-10
N-FGSM: $k = 2\varepsilon, \alpha = \varepsilon$	PathMNIST	74.86	18.84
N-FGSM: $k = 2\varepsilon, \alpha = 0.5\varepsilon$	PathMNIST	85.16	37.08
N-FGSM: $k = 2\varepsilon, \alpha = \varepsilon$	CIFAR-10	79.05	48.73
N-FGSM: $k = 2\varepsilon, \alpha = 0.5\varepsilon$	CIFAR-10	86.57	39.84
ELLE: $\lambda = 1000$	PathMNIST	79.80	40.52
ELLE: $\lambda = 4000$	PathMNIST	83.52	43.08
ELLE: $\lambda = 1000$	CIFAR-10	83.74	45.10
ELLE: $\lambda = 4000$	CIFAR-10	81.12	44.27

نیز به صورت $\beta = 1/\lambda = 6$ گزارش شده است. مقایسهٔ منصفانه مستلزم حفظ همین تفاوت‌های روش‌شناختی است.

پیوست H به روشنی نشان می‌دهد که تنظیم بیشتر همواره انتقال بهتر نمی‌سازد. برای مثال، با کاهش گام N-FGSM از ε به 0.5ε و ثابت‌بودن نویز 2ε، PGD-10 در PathMNIST از ۱۸٫۸۴ به ۳۷٫۰۸ درصد افزایش می‌یابد، ولی در CIFAR-10 از ۴۸٫۷۳ به ۳۹٫۸۴ می‌رسد. این مقایسه، دشواری یافتن تنظیم مشترک را نشان می‌دهد؛ اثبات نمی‌کند که هیچ تنظیم دیگری در کل فضای پیوسته وجود ندارد. شبکهٔ محدود جست‌وجو نمی‌تواند چنین ادعای سراسری را تضمین کند.

آ‌ـ۵ هزینهٔ محاسبات و معنای کم‌هزینه‌بودن

جدول آ‌ـ۴ شمار گذرهای منتخب از جدول ۱۹ مقاله را ثبت می‌کند. واحد شمارش، هر دسته در هر دوره است؛ بنابراین برای Free AT باید تعداد کمتر دوره‌ها و بازپخش‌ها همزمان دیده شوند. از سوی دیگر، گذر پسرویی که به ورودی نیاز دارد الزاماً همان هزینهٔ گذر پسرو برای همهٔ پارامترها را ندارد. عدد گذرها معیار ساختاری مفیدی است، اما برای پیش‌بینی دقیق ثانیه یا گیگابایت کفایت نمی‌کند.

منظور از تقریباً رایگان‌بودن PertAlign این است که دو شیب مورد نیاز آن در فرایند معمول تولید نمونه و به‌روزرسانی مدل موجودند و نیازی به تشکیل صریح هسین نیست. محاسبهٔ ضرب داخلی، نرم و نگهداری ورودی‌های لازم همچنان عملیات دارد. از عبارت مقاله نباید هزینهٔ دقیق صفر در هر چارچوب

جدول آ‌ـ۴: شمار گذرها و مرتبهٔ حافظه، برگرفته از جدول ۱۹ مقاله، صفحهٔ ۴۸ [۶]. B اندازهٔ دسته و D اندازهٔ دادگان است؛ مرتبه‌ها اندازه‌گیری حافظه بر حسب بایت نیستند.

روش	گذر پیشرو	گذر پسرو	مرتبه حافظه
Benign	1	1	$O(B)$
FGSM-RS	2	2	$O(B)$
Free AT	m	m	$O(B)$
GradAlign	3	2	$\approx O(3B)$
NuAT	4	2	$\approx O(3B)$
MultiGrad	2	2	$O(NB)$
ATAS	2	2	$O(B+D)$
ELLE	3	2	$O(3B)$
SORA	2	2	$O(B)$
PGD-2	3	3	$O(B)$
PGD-10	11	11	$O(B)$
TRADES	12	11	$\approx O(3B)$

نرم‌افزاری یا سخت‌افزار را نتیجه گرفت. همچنین نمودارهای کارایی مقاله زمان انتهابه‌انتهای آماده‌سازی دادگان، انتخاب ابرپارامتر و ارزیابی نهایی را اندازه نمی‌گیرند؛ این مرز اندازه‌گیری در مقایسهٔ عملی باید حفظ شود.

آ‌ـ۶ نگاشت آزمایش‌ها به منابع

در جدول آ‌ـ۵ هر گروه ادعا به صفحه و شناسهٔ منبع وصل شده است. شماره‌ها، شمارهٔ صفحهٔ چاپ‌شدهٔ همین نسخهٔ ۶۰صفحه‌ای مقاله‌اند. همهٔ نمودارهای فصل نتایج از مقاله‌اند؛ هیچ نمودار سمینار به عنوان نتیجهٔ عددی آزمایش‌های نهایی استفاده نشده است. جدول‌های توضیحی این پیوست نیز گردآوری تازهٔ مشخصات مقاله‌اند. این جداسازی مهم است، زیرا طرح اولیهٔ یک ایده و نتیجهٔ ارزیابی گستردهٔ آن دو سطح متفاوت از شواهد را تشکیل می‌دهند.

جدول آ‌ـ۵: نگاشت آزمایش و منبع؛ تدوین تازه برای این پایان‌نامه بر اساس مقاله [۶]، نه جدول اصلی مقاله یا سمینار.

موضوع	شناسه در مقاله	صفحه
نتایج اصلی دو دادگان	جدول ۱، پاک و AA	۹
حذف مؤلفه‌ها	جدول ۲، پاک، FGSM و PGD-10	۹
نمای تعمیم و کارایی	شکل‌های ۶ و ۷	۸
خواص دادگان و معماری	جدول ۳، پیوست‌های D و E	۳۰ تا ۳۴
اندازهٔ دسته و ابرپارامتر	جدول‌های ۴ تا ۱۰، پیوست F	۳۵ و ۳۶
بودجهٔ آموزش و آزمون	جدول‌های ۱۱ و ۱۲	۳۶ و ۳۷
رفتار گام سازگار	شکل ۱۲	۳۹
تنظیم خطوط مبنا	جدول‌های ۱۳ تا ۱۷، پیوست H	۴۱ و ۴۲
اعتبار شاخص هشدار	شکل‌های ۱۴ و ۱۵، پیوست J	۴۴ تا ۴۶
هزینه و نتایج تفصیلی	جدول‌های ۱۹ تا ۳۹، پیوست K	۴۷ تا ۵۶
آزمایش مبدل بینایی	جدول‌های ۴۰ تا ۴۲، پیوست L	۵۷ و ۵۸
محدودیت و بازتولید	پیوست‌های M.1 تا M.3	۵۹ و ۶۰

آ‌ـ۷ تفاوت گزارش‌ها و مسائل حل‌نشده

مهم‌ترین تفاوت عددی، سه گزارش PathMNIST/PreActResNet-18 است: جدول اصلی ۱، جدول حذف مؤلفه‌ها و جدول تجمیعی ۳۲. جدول آ‌ـ۶ آن‌ها را کنار هم نگه می‌دارد، اما خانهٔ گزارش‌نشده را با عدد جدول دیگر پر نمی‌کند. برای مقایسهٔ بازتولید آینده، انتخاب یکی از این گزارش‌ها باید پیش از اجرا مشخص شود؛ در غیر این صورت جابه‌جایی پسینی میان گزارش‌ها می‌تواند ظاهری نادرست از تطابق ایجاد کند.

جدول آ‌ـ۶: گزارش‌های متمایز SORA روی PathMNIST/PreActResNet-18؛ تدوین تازه از جدول‌های ۱ و ۲ صفحهٔ ۹ و جدول ۳۲ صفحهٔ ۵۳ مقاله [۶]. خط تیره یعنی مقدار در همان جدول نیامده است.

منبع گزارش	پاک	PGD-10	AA
جدول ۱ متن اصلی، ص ۹	85.93	—	32.91
جدول ۲ متن اصلی، ص ۹	84.69	45.56	—
جدول ۳۲ پیوست، ص ۵۳	84.88 ± 0.99	43.56 ± 1.66	35.54 ± 1.55

اختلاف بودجه نیز باید شفاف بماند: پیش‌فرض عمومی صفحهٔ ۸ برابر ۸/۲۵۵ است، درحالی‌که صفحهٔ ۳۱ بودجهٔ TissueMNIST را ۳/۲۵۵ تعیین می‌کند. به همین علت در فصل نتایج، بودجهٔ این دادگان به طور جداگانه ذکر شد. این انتخاب در روایت بر توضیح اختصاصی پیوست تکیه دارد، ولی جای بررسی پیکربندی‌های متناظر با جدول‌های ۳۶ تا ۳۹ را نمی‌گیرد. بودجهٔ آموزشی روش نیز به دلیل نبود تصویرکردن صریح به گوی، با محدودیت سخت ارزیابی یکسان نیست؛ این دو اختلاف ماهیت متفاوت دارند.

مورد دیگر در جدول ۱۱ صفحهٔ ۳۶ است: مقدار PGD-10 برای MultiGrad در $\varepsilon = ۸/۲۵۵$ برابر ۴۳/۳۳ ± ۰/۲۵ درج شده، درحالی‌که جدول ۲۰ صفحهٔ ۴۸ مقدار PGD-10 را ۴۸/۲۲ ± ۰/۲۷ و AA را ۴۳/۳۳ ± ۰/۲۵ می‌دهد. تطابق عدد اول با ستون AA جدول دوم، به تنهایی مجوز تصحیح برچسب یا مقدار نیست. این پایان‌نامه آن سطر را برای استنتاج حساسیت انتخاب نکرده و اختلاف را برای مراجعه به دادهٔ اصلی ثبت می‌کند.

در بعضی سطرهای دیگر نیز ترتیب معمول شدت حمله‌ها برقرار نیست. برای مثال در جدول ۳۶ صفحهٔ ۵۵، NuAT دارای PGD-10 برابر ۵/۱۷ و AA برابر ۹/۹۱ درصد است. حمله‌های محدود عددی لزوماً ترتیب نظری تضمین‌شده‌ای ندارند، اما این وضعیت نیازمند بررسی تنظیم ارزیابی است و نباید بی‌توضیح به برتری قطعی یک پروتکل تعبیر شود. همچنین سطر AAER/ResNet-18/CIFAR-10 در جدول ۲۱ صفحهٔ ۴۹، پاک ۳۳/۰۳ و AA برابر ۴۳/۹۶ دارد؛ بدون اطلاعات بیشتر نمی‌توان آن‌ها را آمار همان اجرای منطبق فرض کرد. این موارد در جدول‌های گزیده به عنوان شاهد برتری به کار نرفته‌اند.

آ‌ـ۸ الزامات بازتولید آینده و حدود استنتاج

بازتولید قابل ممیزی باید نسخهٔ کد، شناسهٔ دادگان، فهرست کلاس‌های ImageNet-100، بذرها، تنظیمات هر مدل و انتخاب ایست بازرسی را ثبت کند. صفحهٔ ۳۲ برای زیرمجموعهٔ صدکلاسه به مخزن ilee0022/ImageNet100 اشاره می‌کند و صفحهٔ ۱ نشانی کد https://github.com/SecondOrderAT/SORA را می‌دهد. این ارجاع‌ها وجود مسیر بازیابی را نشان می‌دهند، ولی در این کار نسخهٔ مشخص کد اجرا یا صحت پیکربندی‌های آن تأیید نشده است. بنابراین این پیوست دستور اجرای آزموده‌شده یا ادعای بازتولید کامل ارائه نمی‌کند.

برای ارزیابی ستبری باید دست‌کم تعداد گام، اندازهٔ گام، تعداد شروع‌های مجدد، تابع هزینه، زیرمجموعهٔ آزمون، حالت ارزیابی شبکه و نسخه و تنظیم AutoAttack ثبت شوند. اعداد گام ۴/۲۵۵ و ۲/۲۵۵ در پیوست B.11 مربوط به تولید حمله هنگام آموزش‌اند؛ انتقال خودکار آن‌ها به ارزیابی نهایی

مجاز نیست. همچنین تعداد نمونه‌های هر مجموعهٔ آزمون در جدول دادگان، به تنهایی ثابت نمی‌کند که هر نمودار و هر سنجه دقیقاً روی تمام آن نمونه‌ها محاسبه شده است. این تمایزها برای سنجش حمله‌های قوی اهمیت مستقیم دارند [۷].

برای بازتولید هشدار PertAlign نیز باید مسیر زمانی شاخص و درستی‌ها روی یک مبنای نمونه‌گیری مشترک ثبت شود. نمونهٔ حدود ۵۰ دسته در صفحات ۵ و ۴۵ مقاله فقط فاصلهٔ دو رویداد دیداری در یک مسیر است. تعیین توزیع پیش‌آگاهی نیازمند چند مسیر مستقل، تعریف دقیق آغاز بیش‌برازش و اندازه‌گیری هشدار کاذب است. تبدیل آن مشاهده به ثانیه، دوره یا احتمال وقوع، بدون این اطلاعات قابل دفاع نیست. هیچ‌یک از این سنجش‌های تکمیلی در تدوین حاضر انجام نشده است.

در نهایت، نتایج پزشکی موجود دربارهٔ درستی دسته‌بندی تحت آشفتگی عددی‌اند و به تنهایی دربارهٔ حساسیت تشخیصی، عملکرد زیرگروه‌های بیماران یا ایمنی کاربرد بالینی حکمی نمی‌دهند. محدودیت تعداد اجراها و تنوع معماری نیز پابرجاست. ارزش عملی شواهد موجود در نشان‌دادن یک سازوکار کم‌هزینه و قابل انتقال برای آموزش سریع است؛ دامنهٔ اعتبار آن همان مسائل، معیارها و تنظیمات مستند مقاله باقی می‌ماند. هر آزمایش آینده باید به صورت نتیجهٔ تازه، با مشخصات و منشأ جدا، به این مجموعه افزوده شود.

Abstract

Adversarial training improves the robustness of neural networks but incurs substantial computational cost when adversarial examples are generated using iterative attacks. Fast single-step alternatives can suffer from catastrophic overfitting: accuracy against multi-step attacks abruptly collapses despite high single-step accuracy. This thesis studies inexpensive prediction and mitigation of this failure through the geometry of the input loss landscape.

First, epsilon overfitting characterizes the model's sensitivity to restricted perturbation magnitudes and directions. Second, perturbation alignment (PertAlign) measures the cosine similarity between input gradients before and after the attack. A local Taylor analysis relates its decrease to the component of the Hessian-transformed attack direction orthogonal to the initial gradient. Reusing gradients from adversarial-example generation and parameter-update backpropagation enables inexpensive monitoring without explicitly computing a Hessian.

These insights motivate Second-Order Adaptive (SORA) training. SORA uses a directional curvature estimate, exponential averaging, and elementwise random step sizes to adapt its training perturbations. Published experiments cover natural and biomedical image datasets and multiple architectures with fixed method-specific hyperparameters. For PreActResNet-18 under AutoAttack at an evaluation budget of 8/255, the reported robust accuracies are 32.91% on PathMNIST and 18.56% on ImageNet-100. The thesis develops and contextualizes results from the joint ICML 2026 paper rather than reporting newly executed training experiments. It also discusses the local nature of the approximation, the distinct training and evaluation perturbation sets, and the need for statistical calibration of early warnings.

Keywords: Fast adversarial training, catastrophic overfitting, epsilon overfitting, perturbation alignment, second-order optimization, adversarial robustness.



Sharif University of Technology

Department of Computer Engineering

M.Sc. Thesis

Predicting Catastrophic Overfitting in Fast Adversarial Training

By:

Farzan Rahmani

Supervisor:

Dr. Mohammad Hossein Rohban

Defense date: ...