



فرم تعریف پروژه کارشناسی ارشد

تاریخ:
 شماره:
 پیوست:

نام و نام خانوادگی: فرزانه رحمانی
 گرایش: هوش مصنوعی و رباتیک
 استاد راهنمای همکار: -
 شماره دانشجویی: ۴۰۳۲۱۰۷۲۵
 تعداد واحدهای گذرانده: ۹
 تعداد واحد پروژه: ۶
 معدل: ۲۰/۰۰
 استاد راهنما: دکتر محمد حسین رهبان
 استاد ممتحن: نام استاد ممتحن

عنوان کامل پروژه:

فارسی: پیش‌بینی بیش‌برازش فاجعه‌بار در آموزش تخصصی سریع

انگلیسی: Predicting Catastrophic Overfitting in Fast Adversarial Training

نوع پروژه: کاربردی ■ نظری ■

شرح مختصر پروژه: (با تأکید بر اهمیت موضوع، مشکلات موجود، تعریف مسئله، کاربردها، دادگان مورد استفاده (در صورت نیاز) و نحوه ارزیابی در حدود ۲۵۰ کلمه)

شبکه‌های عصبی عمیق همچنان در برابر حملات خصمانه (Adversarial Attacks) بسیار آسیب‌پذیر هستند - اختلالات کوچک و با دقت طراحی شده که عملکرد مدل را به طور قابل توجهی کاهش می‌دهند. آموزش خصمانه (AT)، به ویژه با استفاده از روش‌های چند مرحله‌ای مانند PGD، مؤثر اما از نظر محاسباتی پرهزینه است. آموزش خصمانه سریع (FAT)، با استفاده از FGSM تک مرحله‌ای، سرعت و هزینه کم محاسباتی را ارائه می‌دهد اما از بیش‌برازش فاجعه‌بار (Catastrophic Overfitting) رنج می‌برد: مدل‌ها پس از چند دوره (epoch) آموزشی، به طور ناگهانی در برابر حملات چند مرحله‌ای، استحکام خود را از دست می‌دهند.

این پروژه پیش‌بینی کارآمد وقوع بیش‌برازش فاجعه‌بار در FAT را بررسی می‌کند. با وجود روش‌های جلوگیری کننده موجود - مانند GradAlign، FGSM با نویز اضافه، N-FGSM و AAER - اثربخشی آنها در مجموعه داده‌ها و معماری‌های گوناگون متناقض است و اغلب به روش‌های اکتشافی گران‌قیمت نیاز دارند. چالش اصلی پیش‌بینی زمان و دلیل وقوع بیش‌برازش فاجعه‌بار است، نه صرفاً واکنش پس از وقوع آن.

ما پیشنهاد می‌کنیم در طول آموزش، معیارهای پیش‌بینی‌کننده‌ای ایجاد کنیم که بیش‌برازش فاجعه‌بار قریب‌الوقوع را نشان دهند. این موارد ممکن است شامل تناظر گرادیان (gradient alignment)، الگوهای گرادیان، تجزیه و تحلیل دینامیک‌های آموزش یا معیارهای انحنای مشتق شده از تجزیه و تحلیل چشم‌انداز تابع زیان (loss landscape) باشد. با استفاده از مجموعه داده‌های معیار مانند CIFAR-10/100 و Tiny-ImageNet با معماری‌های استاندارد (مثلاً انواع ResNet)، این شاخص‌ها را در کنار معیارهای دقت مستحکم (robust accuracy) پیگیری خواهیم کرد.

کاربردها: با پیش‌بینی بیش‌برازش فاجعه‌بار، الگوریتم‌های آموزشی می‌توانند به صورت پویا ابرپارامترها، میزان منظم‌سازی (regularization) یا مراحل اختلال (perturbation stages) را تنظیم کنند - که منجر به مدل‌های مستحکم‌تر و کارآمدتر می‌شود. این امر پیامدهای مستقیمی در کاربردهای حساس به امنیت مانند سیستم‌های خودمختار، تشخیص پزشکی و امور مالی دارد.

ارزیابی: این پروژه پیش‌بینی‌های ما از بیش‌برازش فاجعه‌بار را در برابر رویدادهای واقعی بیش‌برازش فاجعه‌بار در مجموعه داده‌های اعتبارسنجی، با استفاده از معیارهایی مانند میزان دقت و مقادیر تابع ضرر در حملات تک مرحله‌ای مانند FGSM و حملات چند مرحله‌ای مانند PGD، محک خواهد زد. موفقیت با زمان هشدار زود هنگام، کاهش وقوع بیش‌برازش فاجعه‌بار و بهبود در بده‌بستان دقت مستحکم-تمیز (robust-clean accuracy trade-off) اندازه‌گیری می‌شود.

کلمات کلیدی: Adversarial Robustness - Fast Adversarial Training (FAT) - Catastrophic Overfitting



فرم تعریف پروژه کارشناسی ارشد

تاریخ:

شماره:

پیوست:

مراحل انجام پروژه و زمان بندی آن:

۱	مطالعه پژوهش های پیشین	۳ ماه
۲	بررسی نقاط ضعف روش ها و مدل های پیشین	۲ ماه
۳	طراحی ایده های جدید و پیاده سازی آنها	۵ ماه
۴	بررسی و ارزیابی روش های ارائه شده	۲ ماه
۵	نگارش پایان نامه و دفاع از پروژه	۳ ماه

مراجع:

- [1] M. H. Mirza, M. R. Briglia, F. Bartolucci, S. Beadini, G. Lisanti, and I. Masi, "Understanding adversarial training with energy-based models," *arXiv preprint arXiv:2505.22486*, 2025.
- [2] R. Lin, C. Yu, and T. Liu, "Eliminating catastrophic overfitting via abnormal adversarial examples regularization," *Advances in Neural Information Processing Systems*, vol. 36, pp. 67 866–67 885, 2023.
- [3] P. de Jorge Aranda, A. Bibi, R. Volpi, *et al.*, "Make some noise: Reliable and efficient single-step adversarial training," *Advances in Neural Information Processing Systems*, vol. 35, pp. 12 881–12 893, 2022.
- [4] M. Andriushchenko and N. Flammarion, "Understanding and improving fast adversarial training," *Advances in Neural Information Processing Systems*, vol. 33, pp. 16 048–16 059, 2020.
- [5] E. Wong, L. Rice, and J. Z. Kolter, "Fast is better than free: Revisiting adversarial training," *arXiv preprint arXiv:2001.03994*, 2020.

دروس مورد نیاز:

تخصصی (ارتباط موضوع پروژه با دروسی که دانشجو گذرانده یا باید بگذراند)			جبرانی		
باید بگذراند	نمره	گذرانده	باید بگذراند	نمره	گذرانده
	۲۰	یادگیری ماشین			
	۲۰	تحلیل هوشمند تصاویر زیست پزشکی			

استاد راهنما: تاریخ تحویل فرم به مدیر گروه: امضای استاد راهنما:	نظر گروه: تاریخ جلسه گروه: امضای مدیر گروه:	نظر کمیته تحصیلات تکمیلی دانشکده: تاریخ جلسه کمیته: امضای معاون تحصیلات تکمیلی:
---	---	---

توجه: فرم تعریف پروژه بایستی یک روز قبل از جلسه گروه توسط استاد راهنما تحویل مدیر گروه شود.