

دانشگاه صنعتی شریف | دانشکدهٔ مهندسی کامپیوتر

دفاع پایان‌نامهٔ کارشناسی ارشد هوش مصنوعی و رباتیک

پیش‌بینی بیش‌برازش فاجعه‌بار در آموزش تخاصمی سریع

فرزان رحمانی | شمارهٔ دانشجویی: 403210725

استاد راهنما: دکتر محمدحسین رهبان

مسیر دفاع: از مشاهدهٔ شکست تا کنترل گام

۱. مسئله: چرا درستی زیادِ تک‌گامی می‌تواند گمراه‌کننده باشد؟
۲. تحلیل و روش: هندسهٔ هزینه، PertAlign و کنترل‌کنندهٔ SORA.
۳. شواهد: ستبری، انتقال تنظیمات، هزینه و حدود اعتبار.

مبنای علمی: مقالهٔ مشترک SORA در ICML 2026 [۱]؛ فصل‌های ۱ تا ۷ و پیوست پایان‌نامه.

پرسش عملی و مدل تهدید

- می‌خواهیم شکست تقریب تک‌گامی را با اطلاعات موجود آموزش زودتر ببینیم و اصلاح کنیم.
- مهاجمِ بدون هدف و جعبه‌سفید، هزینهٔ دسته‌بندی تصویر را افزایش می‌دهد.
- معیار، درستی تجربی در برابر حملهٔ قوی است؛ گواهی ریاضی ستبری نیست.

$$\Delta_\infty(x,\epsilon) = \{\delta : \|\delta\|_\infty \le \epsilon, \quad x+\delta \in [۰,۱]^d\}$$

مبانی مدل تهدید و ارزیابی: [۲، ۳].

آموزش هم‌آورد: دو مسئلهٔ درهم‌تنیده

$$\min_{\theta} \mathbb{E}_{(x,y)\sim\mathcal{D}} \left[\max_{\delta\in\Delta_\infty(x,\epsilon)} \mathcal{L}(f_\theta(x+\delta), y) \right]$$

- مسئلهٔ درونی: یافتن نمونه‌ای با هزینهٔ زیاد برای مدل فعلی.
- مسئلهٔ بیرونی: به‌روزرسانی وزن‌ها روی همان نمونه.
- آموزش سریع هزینهٔ حل درونی را کم می‌کند؛ کیفیت این تقریب باید پایش شود.

صورت‌بندی: [۲]؛ آموزش سریع: [۴].

یک شیب در برابر بازبینی چندبارهٔ جهت

حملهٔ علامت شیب سریع؛ تقریب مرتبهٔ اول:

$$g = \nabla_x \ell(x), \qquad x_{\text{FGSM}} = \Pi_{[۰,۱]^d}(x + \epsilon\,\text{sign}(g))$$

حملهٔ چندگامی با تصویرشدن؛ PGD:

$$\delta^{t+۱} = \Pi_{\Delta_\infty(x,\epsilon)}\left(\delta^t + a\,\text{sign}\left(\nabla_x \ell(x+\delta^t)\right)\right)$$

- FGSM جهت آغاز را ثابت نگه می‌دارد؛ PGD تغییر جهت را می‌بیند.
- بودجهٔ ϵ و اندازهٔ گام a دو کمیت متفاوت‌اند.

FGSM: [۵]؛ PGD: [۲].

بیش‌برازش فاجعه‌بار: موفقیت ظاهریِ حل‌کننده

- درستی زیر حملهٔ چندگامی در زمانی کوتاه فرو می‌ریزد.
- درستی زیر حملهٔ تک‌گامی آموزش ممکن است همچنان زیاد بماند.
- هزینهٔ کم در انتهای حمله، بیشینهٔ هزینه در همسایگی را تضمین نمی‌کند.

پیام اصلی

باید اعتبار مولد نمونهٔ آموزشی را بسنجیم؛ ارزیابی با همان حملهٔ آموزش کافی نیست.

تعریف و تحلیل پدیده: [۴، ۶].

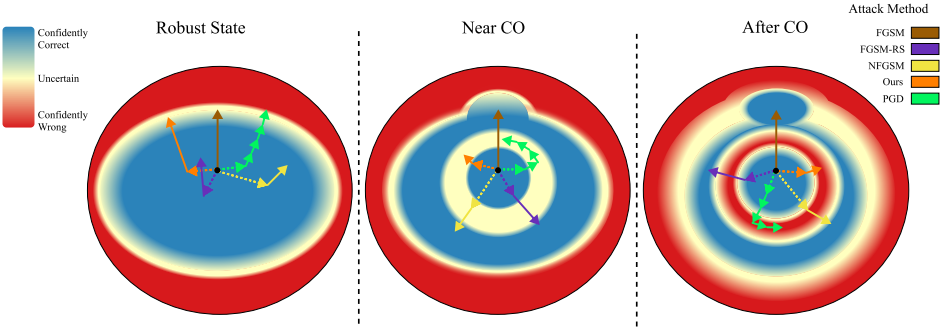
روش‌های پیشین چه چیزی را تغییر می‌دهند؟

خانواده	نمونه	سازوکار و پرسش باز
تنوع آشفتگی	FGSM-RS, N-FGSM	تنوع آغاز و دامنه؛ انتقال تنظیمات؟
منظم‌سازی	GradAlign, NuAT, ELLE	کنترل هندسه؛ هزینهٔ محاسبات؟
نمونهٔ غیرعادی	AAER	کنترل افت هزینه؛ زمان ظهور نشانه؟
گام تطبیقی	ATAS	استفاده از بزرگی شیب؛ اطلاعات خمیدگی؟

تدوین تازه از مرور بخش ۲ مقالهٔ SORA [۱]؛ این جدول در اصل مقاله یا سمینار وجود ندارد.

منابع روش‌ها: [۷، ۶، ۸، ۹، ۱۰، ۱۱].

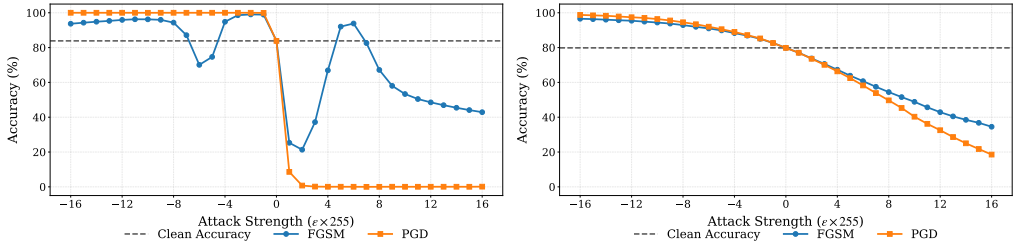
هندسه: یک گام می‌تواند از ناحیهٔ آسیب‌پذیر عبور کند



پیچش مرز تصمیم و تغییر سطح هزینه؛ بازنشر شکل ۱ مقالهٔ SORA [۱].

نقطهٔ انتهاییِ کم‌هزینه، نقاط پرهزینهٔ مسیر را پنهان می‌کند.

بیش‌برازش اپسیلون؛ حساسیت به اندازهٔ آشفتگی



(a) FGSM Adversarial Training

(b) SORA Adversarial Training

درستی در اندازه‌های مختلف حمله؛ بازنشر شکل ۲ مقالهٔ SORA [۱].

- یادگیری در اندازه‌های خاص، محافظت یکنواخت در همسایگی نیست.
- ضریب منفی محور، حرکت خلاف جهت است؛ شعاع تهدید منفی نیست.

نمونهٔ هم‌آورد غیرعادی؛ نشانه‌ای از عبور از قله

$$z = x + \eta, \qquad \ell(z+\delta) < \ell(z)$$

- حمله برای افزایش هزینه ساخته شده، ولی در انتها هزینه را کاهش داده است.
- غیرعادی بودنِ AAE دربارهٔ هزینه است؛ الزاماً دربارهٔ درست‌بودن برچسب نیست.
- جهت شیب می‌تواند پیش از رخ‌دادن این افت هزینه تغییر کند.

پیام اصلی

مقایسهٔ دو شیب می‌تواند اطلاعاتی زودتر از مقایسهٔ دو هزینه بدهد.

تعریف AAE: [۱۰]؛ انگیزهٔ پایش هندسی: [۱].

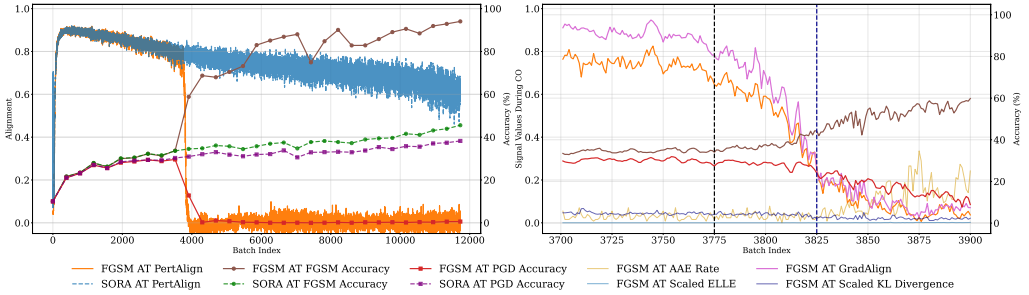
هم‌راستایی آشفتگی؛ دو شیبِ در دسترس

$$g = \nabla \ell(z), \quad g' = \nabla \ell(z+\delta), \qquad P = \frac{g^{\mathrm{T}} g'}{\|g\|_2 \|g'\|_2}$$

- PertAlign جهت شیب ابتدا و انتهای حمله را مقایسه می‌کند.
- شیب اول برای حمله و شیب دوم همراه پس‌انتشار روی نمونهٔ هم‌آورد موجود است.
- مقدار نزدیک یک: حفظ جهت دو شیب؛ به‌تنهایی گواهِ خمیدگی کم نیست.

رابطهٔ ۲، صفحهٔ ۵ مقالهٔ SORA [۱]؛ تعریف برای شیب‌های ناصفر.

شواهد هشدار: حدود ۵۰ دسته در یک مسیر مشخص



افت هم‌راستایی پیش از جدایی درستی‌ها؛ بازنشر شکل ۳ مقالهٔ SORA [۱].

- در مثال FGSM: افت حدود دستهٔ ۳۷۷۵؛ جدایی آشکار حدود ۳۸۲۵.
- این فاصله، میانگین عمومی یا مهلت تضمین‌شده نیست؛ آستانه و نرخ هشدار کاذب گزارش نشده‌اند.

رابطهٔ هندسی: بخش عمودِ کنش هسین

برای $g \neq 0$، جهت ثابت v و گام کوچک α:

$$H = \nabla^2 \ell(z), \qquad Q_g = I - \frac{gg^{\mathrm{T}}}{\|g\|_2^2}$$

$$1 - P = \frac{\alpha^2}{2\|g\|_2^2} \|Q_g H v\|_2^2 + O(\alpha^3)$$

- فرض: همواری محلی و هسین محلی لیپشیتس؛ جهت در بسط ثابت است.
- $P \approx 1$ کوچک‌بودن $\|H\|$ را نتیجه نمی‌دهد؛ تغییر موازیِ شیب دیده نمی‌شود.

صورت تصویریِ بازنویسی‌شده در فصل هندسه، بر پایهٔ پیوست A مقاله [۱].

بخش دقیق نظری: بهینهٔ اسکالر یک مدل درجه‌دو

$$p = \mathrm{sign}(g), \quad q(a) = \ell(z) + ba + \tfrac{1}{2}ca^2, \quad b = \|g\|_1 > 0,\ c = p^{\mathrm{T}} H p$$

$$\arg\max_{0 \le a \le A} q(a) = \begin{cases} \min\{A, -b/c\}, & c < 0, \\ A, & c \ge 0. \end{cases}$$

- در جهت مقعر، حرکت پس از رأس هزینه را کاهش می‌دهد.
- این جوابِ دقیقِ مدل اسکالر است؛ سطح واقعی الزاماً درجه‌دو نیست.

استخراج فصل روش، بر پایهٔ تحلیل مرتبهٔ دوم مقالهٔ SORA [۱].

اطلاعات خمیدگی از همان گام کاوش

در مدل درجه‌دو، بدون برش و با گام اسکالر $a_{\text{probe}} > 0$:

$$g_{\text{probe}} = g + a_{\text{probe}} Hp, \qquad r = \frac{p^{\mathrm{T}} g_{\text{probe}}}{\|g\|_1} = 1 + \frac{a_{\text{probe}} c}{b}$$

$$r < 1 \quad \Longrightarrow \quad a_{\text{quad}} = \min\left\{A, \frac{a_{\text{probe}}}{1 - r}\right\}$$

- صورت کسر، همان گامی است که شیب دوم با آن اندازه‌گیری شده است.
- نسبت r با کسینوس PertAlign برابر نیست؛ بزرگی شیب نیز در آن نقش دارد.

بازنویسی دقیق فصل روش از استخراج مقالهٔ SORA [۱].

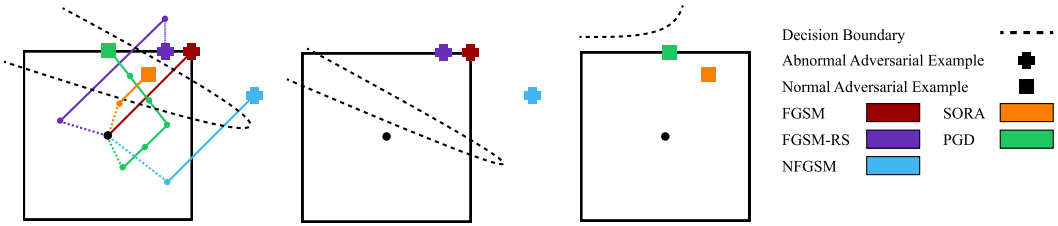
قاعدهٔ عملی: کنترل دامنه، الهام‌گرفته از مدل درجه‌دو

$$F(u) = \begin{cases} \min\left\{\alpha_{\max}, \dfrac{\alpha_{\cdot}}{1-u}\right\}, & u < 1, \\ \alpha_{\max}, & u \geq 1, \end{cases} \qquad a_j \sim \mathcal{U}(0, A_i)$$

- u میانگین نماییِ نسبت؛ A_i سقف توزیع گام مؤلفه‌هاست.
- جایگزینی گام کاوش با $\alpha_{\cdot}$، همانی دقیقِ اسلاید قبل را تغییر می‌دهد.
- تصادفی‌سازی مؤلفه‌ای و استفاده از گذشته نیز انتخاب‌های اجرایی‌اند.

الگوریتم ۱ مقاله [۱]: $\alpha_{\cdot} = 0.02$، $\beta = 0.05$، $\alpha_{\max} = 2\epsilon$.

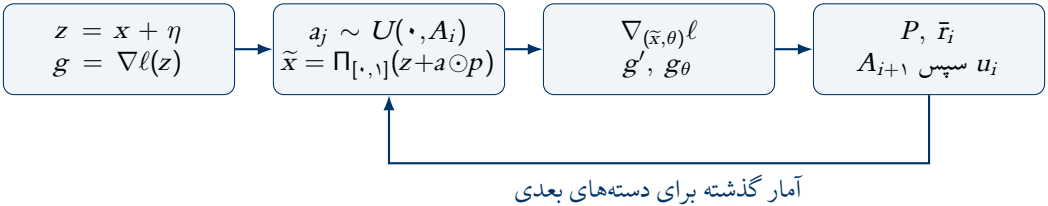
چرا اصلاح گام می‌تواند مفید باشد؟



تفسیر هندسی اصلاح گام؛ بازنشر شکل ۴ مقالهٔ SORA [۱].

دسترسی به نقاط پرهزینه می‌تواند آموزش را به ناحیهٔ آسیب‌پذیر بازگرداند.

جریان SORA: استفادهٔ دوباره از دو گذر



نمودار تازه‌تدوین‌شده از الگوریتم ۱ مقاله [۱]؛ این نمودار در اصل مقاله یا سمینار نیست.

- گذر دوم، هم مشتق وزن‌ها و هم شیب ورودی انتهایی را می‌دهد.
- PertAlign برای پایش است؛ نسبت r وارد کنترل گام می‌شود.

شبه‌کد و تأخیر مهمِ ترتیب چاپ‌شده

۱. آغاز: $u_{\cdot} = ۰.۹۹$، $A_{۱} = F(u_{\cdot})$؛ برای هر دسته، $\eta \sim U([-\epsilon, \epsilon]^d)$.
۲. $g = \nabla \ell(x + \eta)$، $p = \mathrm{sign}(g)$؛ جداسازی جهت از گراف حمله.
۳. $a_j \sim U(۰, A_i)$؛ $\widetilde{x} = \Pi_{[۰,۱]^d}(x + \eta + a \odot p)$.
۴. دریافت (g', g_θ)؛ به‌روزرسانی وزن‌ها؛ محاسبهٔ $\bar{r}_i$ از نسبت‌های نمونه‌ای.

$$\boxed{A_{i+۱} = F(u_{i-۱})} \quad \text{سپس} \quad u_i = (۱ - \beta) u_{i-۱} + \beta \bar{r}_i$$

مشاهدهٔ دستهٔ i نخست می‌تواند روی سقفِ دستهٔ $i + ۲$ اثر بگذارد.

بازنویسی الگوریتم ۱، صفحهٔ ۶ [۱]؛ مقداردهی $A_{۱}$ و میانگین نسبت‌ها قرارداد صریح فصل روش‌اند.

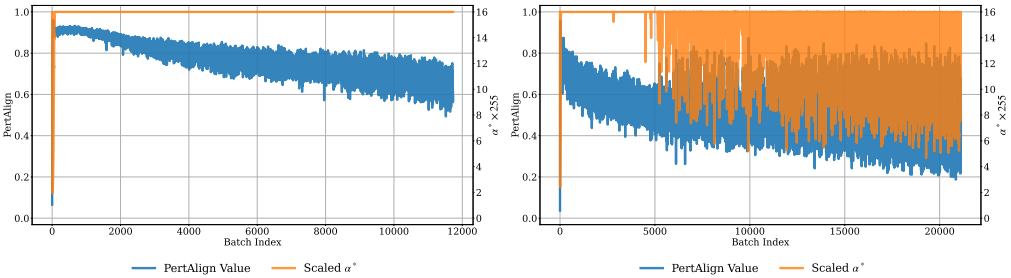
دامنهٔ آموزش با کرهٔ تهدید ارزیابی یکسان نیست

$$\widetilde{x} = \Pi_{[۰,۱]^d}(x + \eta + a \odot p), \qquad \|\eta + a \odot p\|_\infty \le \epsilon + \alpha_{\max} = ۳\epsilon$$

- آموزش: فقط برش پیکسل به $[۰, ۱]$؛ بدون تصویرشدن به کرهٔ ϵ.
- ۳ϵ کرانِ آشفتگی خام است؛ اندازهٔ ثابتِ همهٔ نمونه‌ها نیست.
- ارزیابی: کرهٔ ϵ و دامنهٔ پیکسل؛ معمولاً ۸/۲۵۵، برای TissueMNIST برابر ۳/۲۵۵.

الگوریتم ۱ و پیوست D، صفحهٔ ۳۱ مقاله [۱].

رفتار تطبیقی روی دو دادگان متفاوت است



(a) CIFAR-10 (b) PathMNIST

هم‌راستایی و سقف گام؛ بازنشر شکل ۵ مقالهٔ SORA [۱].

در CIFAR-10 سقف اغلب فعال است؛ در PathMNIST کاهش گام بیشتر رخ می‌دهد.

تنظیم و دامنهٔ ارزیابی

- دادگان: CIFAR-10/100، TinyImageNet، ImageNet-100، PathMNIST و TissueMNIST.
- معماری‌ها: PreActResNet-18، ResNet-18، WRN-28-10 و SENet-18؛ مدل‌ها جداگانه آموزش می‌بینند.
- SGD: تکانهٔ ۰.۹، افت وزن ۵×۱۰^{-۴}؛ نرخ طبیعی چرخه‌ای، پزشکی کسینوسی.

پیام اصلی

«تنظیم ثابت» یعنی مجموعهٔ نهایی مشترک پس از تنظیم محدود؛ آماده‌سازی داده و همهٔ جزئیات آموزش یکسان نیستند.

بخش ۶ و پیوست‌های D, E, M.3 مقاله، صفحات ۳۰ تا ۳۴ و ۶۰ [۱].

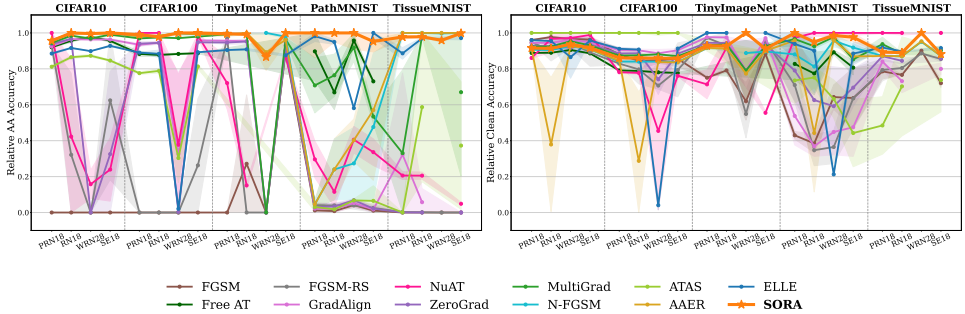
نتیجهٔ اصلی؛ دو مسئلهٔ دشوار

	PathMNIST		ImageNet-100	
روش	پاک	AA	پاک	AA
FGSM	46.06	0.42	15.94	0.00
N-FGSM	74.89	1.65	49.40	15.52
AAER	83.54	2.48	48.26	17.18
SORA	**85.93**	**32.91**	**57.26**	**18.56**

بازنشر داده‌های جدول ۱، صفحهٔ ۹ مقاله [۱]؛ PreActResNet-18، $\epsilon = ۸/۲۵۵$؛ همهٔ مقادیر درصد.

بهبود AA نسبت به N-FGSM: به‌ترتیب ۳۱.۲۶ و ۳.۰۴ واحد درصد.

تعمیم تنظیمات؛ تصویر کلیِ عملکرد نسبی



بازنشر شکل ۶، صفحهٔ ۸ مقاله [۱]؛ نرمال‌سازی نسبت به بهترین مقدار هر مسئله، طبق صفحهٔ ۴۷.

- مقدار نزدیک یک یعنی نزدیکی به بهترین نتیجهٔ همان ستون.
- مقادیر مطلق و اختلاف‌های کوچک در این نمایش پنهان می‌شوند.

جدول‌های تفصیلی؛ برتری در همهٔ ستون‌ها برقرار نیست

دادگان و مدل	روش	پاک	PGD-10	AA
CIFAR-10 / PreAct-18	N-FGSM	79.05	48.73	43.95
	SORA	79.90	48.64	43.83
CIFAR-100 / PreAct-18	N-FGSM	53.43	26.25	21.75
	SORA	54.74	26.12	21.56
TinyImageNet / WRN-28-10	N-FGSM	48.47	21.21	**16.58**
	SORA	54.59	18.73	14.31

چینش تازه از جدول‌های ۲۰، ۲۴ و ۳۰، صفحات ۴۸، ۵۰ و ۵۳ مقاله [۱]؛ فقط مقادیر مرکزی درصدی، با حذف ±؛ جدول اصلی مقاله نیست.

برداشت: بده‌بستان پاک، ستبر و هزینه؛ رتبه‌بندی به مسئله وابسته است.

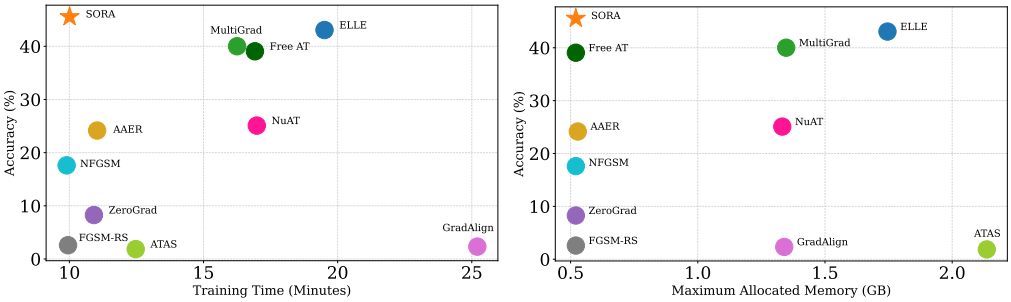
حذف مؤلفه‌ها؛ گزارش مستقلِ PGD-10

تنظیم	پاک	FGSM	PGD-10
SORA (پایه)	84.69	57.51	45.56
بدون نمونه‌گیری تصادفی	85.67	58.89	45.35
برش اندازه گام	86.82	52.02	34.08
بدون گام تطبیقی	89.93	28.30	17.23

جدول ۲، صفحهٔ ۹ مقاله [۱]؛ PathMNIST/PreActResNet-18، درصد؛ مستقل از گزارش اصلی AA.

حذف سازگاری گام افت بزرگی دارد؛ افت ۰.۲۱ با حذف نمونه‌گیری، به‌تنهایی شاهد معناداری آماری نیست.

کارایی؛ زمان و حافظه در یک تنظیم مشخص



(a) Time (b) Memory

بازنشر شکل ۷، صفحهٔ ۸ مقاله [۱]؛ PathMNIST/PreActResNet-18، ۳۰ دوره، RTX 4090؛ درستی: PGD-10.

حدود شواهد و نکات قابل دفاع

- هشدار: مشاهدهٔ تقدم زمانی داریم؛ پیش‌بین واسنجی‌شده و نرخ هشدار کاذب نداریم.
- نظریه: تحلیل محلی و جهت‌وابسته است؛ تصادفی‌سازی، برش و تأخیر فاصله‌ای با مدل دقیق دارند.
- ارزیابی: ImageNet-100 تک‌اجرایی است؛ جزئیات کامل حمله‌ها و رابطهٔ بعضی گزارش‌ها روشن نیست.

فصل‌های نتایج و جمع‌بندی و پیوست پایان‌نامه؛ پیوست‌های J, M مقاله [۱].

دستاورد؛ اتصال پایش هندسی به اصلاح آموزش

۱. تفسیر بیش‌برازش اپسیلون: اهمیت پوشش اندازه‌ها و جهت‌های متنوع آشفتگی.
۲. PertAlign: پایش تغییر جهت شیب با استفاده از محاسبات موجود و تفسیر هندسی محلی.
۳. SORA: کنترل سقف توزیع گام با اطلاعات دو شیب؛ بده‌بستان رقابتی در دامنهٔ ارزیابی‌شده.

دستاوردهای پژوهش مشترک [۱]؛ سهم این ارائه، روایت و تحلیل مستند فصل‌های کامل‌شدهٔ پایان‌نامه است.

ادامهٔ پژوهش؛ از نشانه تا پیش‌بین قابل سنجش

- تعریف مستقل رویداد فروپاشی، تعیین آستانه روی اعتبارسنجی و سنجش هشدار کاذب و پیش‌آگاهی در چند اجرا.
- کنترل نمونه‌ای یا گروهی برای دادگان نامتوازن؛ سنجش سود در برابر نوسان و هزینه.
- جداسازی اثر دامنه، تنوع و تطبیق با بودجهٔ محاسباتی و دامنهٔ آموزش یکسان.

پیام اصلی

دو شیبِ موجود می‌توانند هم نشانهٔ هشدار و هم مبنای اصلاح گام باشند؛ ارزیابی مستقلِ ستبری همچنان ضروری است.

مسیرهای پیشنهادی فصل جمع‌بندی؛ محدودیت‌های مطالعهٔ مشترک [۱].

پشتیبان: منشأ گزارش‌ها و اختلاف حل‌نشده

- جدول اصلی ۱، صفحهٔ ۹: PathMNIST، پاک ۸۵.۹۳ و AA برابر ۳۲.۹۱.
- جدول حذف مؤلفه‌های ۲، صفحهٔ ۹: پاک ۸۴.۶۹ و PGD-10 برابر ۴۵.۵۶؛ معیار مستقل.
- جدول ۳۲، صفحهٔ ۵۳: پاک ۰.۹۹ ± ۸۴.۸۸ و AA برابر ۱.۵۵ ± ۳۵.۵۴؛ گزارش مستقلِ پیوست.

همه متعلق به PathMNIST/PreActResNet-18 در مقاله‌اند [۱]؛ رابطهٔ دقیق اجراها روشن نیست. اعداد ادغام یا میانگین‌گیری نشده‌اند.

پشتیبان: بازتولید و هزینهٔ ساختاری

روش	گذر پیشرو	گذر پسرو
FGSM-RS / SORA	2	2
GradAlign / ELLE	3	2
PGD-2	3	3
PGD-10	11	11
TRADES	12	11

گزینش و چینش تازه از جدول ۱۹، صفحهٔ ۴۸ مقاله [۱]؛ واحد: هر دسته؛ این جدول عین جدول اصلی نیست.

- لازم برای بازتولید: بذر، نقطهٔ کنترل، نسخه و تنظیم AA، گام و بازآغازهای حمله.
- تجمیع نسبت‌ها، مخرج صفر، سقف آغاز و ترتیب EMA باید صریح ثبت شوند.

واژه‌نامهٔ کوتاه: مسئله و ارزیابی

English	فارسی
Adversarial	هم‌آورد
Perturbation	آشفتگی
Dataset	دادگان
Accuracy	درستی
Robustness	ستبری
Catastrophic Overfitting (CO)	بیش‌برازش فاجعه‌بار

واژه‌نامهٔ تازه‌تدوین‌شده مطابق واژه‌گزینی پایان‌نامه و اصطلاحات مقاله [۱]؛ جدول اصلی مقاله نیست.

واژه‌نامهٔ کوتاه: هندسه و روش

English	فارسی
Gradient	شیب
Curvature	خمیدگی
Loss	هزینه
Perturbation Alignment (PertAlign)	هم‌راستایی آشفتگی
Abnormal Adversarial Example (AAE)	نمونهٔ هم‌آورد غیرعادی
Exponential Moving Average (EMA)	میانگین نمایی

واژه‌نامهٔ تازه‌تدوین‌شده از اصطلاحات مقاله [۱] و واژه‌گزینی پایان‌نامه؛ جدول اصلی مقاله نیست.

منابع منتخب I

[1] Mazdak Teymourian, Ramtin Moslemi, Farzan Rahmani, and Mohammad Hossein Rohban.
SORA: Free second-order attacks in fast adversarial training.
In *Proceedings of the 43rd International Conference on Machine Learning*, volume 306 of *Proceedings of Machine Learning Research*, 2026.

[2] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu.
Towards deep learning models resistant to adversarial attacks.
In *International Conference on Learning Representations*, 2018.

[3] Francesco Croce and Matthias Hein.
Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks.
In *International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 2206–2216, 2020.

منابع منتخب II

[4] Eric Wong, Leslie Rice, and J. Zico Kolter.
Fast is better than free: Revisiting adversarial training.
In *International Conference on Learning Representations*, 2020.

[5] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy.
Explaining and harnessing adversarial examples.
In *International Conference on Learning Representations*, 2015.

[6] Maksym Andriushchenko and Nicolas Flammarion.
Understanding and improving fast adversarial training.
In *Advances in Neural Information Processing Systems*, volume 33, pages 16048–16059, 2020.

[7] Pau de Jorge Aranda, Adel Bibi, Riccardo Volpi, Amartya Sanyal, Philip Torr, Grégory Rogez, and Puneet Dokania.
Make some noise: Reliable and efficient single-step adversarial training.
In *Advances in Neural Information Processing Systems*, volume 35, pages 12881–12893, 2022.

منابع منتخب III

[8] Gaurang Sriramanan, Sravanti Addepalli, Arya Baburaj, and R. Venkatesh Babu.
Towards efficient and effective adversarial training.
In *Advances in Neural Information Processing Systems*, volume 34, pages 11821–11833, 2021.

[9] Elias Abad Rocamora, Fanghui Liu, Grigorios Chrysos, Pablo M. Olmos, and Volkan Cevher.
Efficient local linearity regularization to overcome catastrophic overfitting.
In *International Conference on Learning Representations*, 2024.

[10] Runqi Lin, Chaojian Yu, and Tongliang Liu.
Eliminating catastrophic overfitting via abnormal adversarial examples regularization.
In *Advances in Neural Information Processing Systems*, volume 36, pages 67866–67885, 2023.

[11] Zhichao Huang, Yanbo Fan, Chen Liu, Weizhong Zhang, Yong Zhang, Mathieu Salzmann, Sabine Süsstrunk, and Jue Wang.
Fast adversarial training with adaptive step size.
IEEE Transactions on Image Processing, 32:6102–6114, 2023.